

# Clasificación Del Microbioma previo y tras la infección por *Helicobacter Pylori* Mediante Modelos de Redes Neuronales (Junio 2026)

David F. Marin Rosas, Diego E. Morales Granados, Laura C. Girón Pinto, Nicolás Martínez López, Sergio I. Motta Doncel., Facultad de Ingeniería, Universidad Nacional de Colombia

**Abstract**—This project explores the use of shallow and deep neural networks for the classification of *Helicobacter pylori* infection using gastric microbiome data obtained from 16S rRNA sequencing. The study applies compositional data analysis techniques, including CLR transformations and exploratory multivariate analysis, to address the statistical properties of microbiome datasets. Due to the limited number of real samples, a Generative Adversarial Network (GAN) was implemented to generate synthetic microbiome profiles for model training. Several neural architectures, including MLPs, ResNet Tabular, and TabNet, were evaluated on real biological samples. Results showed that deep learning approaches, particularly residual architectures, achieved strong predictive performance and demonstrated the potential of combining microbiome analysis, data augmentation, and neural networks for biomedical classification tasks.

**Index Terms**—Shallow Neural Networks, MLP, Autoencoder, GAN, AC-GAN, Gastric Microbiome, *Helicobacter pylori*, Data Augmentation, Deep Neural Networks, Classification.

## I. INTRODUCCIÓN

La infección por *Helicobacter pylori* constituye un factor de riesgo importante en el desarrollo de diversas enfermedades gastrointestinales, como la gastritis, la úlcera péptica y el cáncer gástrico. Su presencia no solo implica la colonización de la mucosa gástrica, sino también alteraciones en la estructura y composición de la microbiota asociada, lo que ha llevado a considerar estos cambios como posibles indicadores del estado de infección. El análisis de este tipo de sistemas representa un desafío, ya que las interacciones entre sus componentes suelen ser no lineales y difíciles de capturar mediante enfoques tradicionales.

El presente acercamiento propone abordar el problema de clasificación del estado de infección por *Helicobacter pylori* mediante el uso de redes neuronales superficiales y profundas. Este tipo de modelos permite explorar relaciones no lineales y capturar estructuras relevantes, ofreciendo una alternativa computacional para el análisis de sistemas biológicos complejos. De esta manera, se busca evaluar su potencial en la identificación de patrones asociados al estado de infección y aportar una perspectiva complementaria a los métodos convencionales.

## II. OBJETIVO Y ALCANCE DEL PROYECTO

El objetivo del presente proyecto es evaluar si los modelos de aprendizaje automático no lineales, incluyendo redes neuronales multicapa, aportan un valor predictivo e interpretativo adicional frente a métodos estadísticos clásicos en la clasificación de la infección por *Helicobacter pylori* utilizando datos de microbiota gástrica obtenidos mediante secuenciación 16S rRNA de biopsias humanas.

El proyecto se centrará exclusivamente en microbiota gástrica en humanos adultos, comparando individuos infectados contra no infectados. Se procesamiento uniforme de datos de secuenciación para evitar batch effect, modelado supervisado y análisis de

interpretabilidad. No se pretende establecer causalidad ni mecanismos funcionales profundos, sino evaluar capacidad predictiva y estructura microbiana asociada al estado de infección.

## III. REVISIÓN DE LITERATURA

### A. Definiciones Básicas

- 1) *Helicobacter pylori*: bacteria gramnegativa microaerófila que coloniza la mucosa gástrica y se asocia con gastritis, úlcera péptica y cáncer gástrico.
- 2) Microbiota gástrica: Comunidad microbiana residente en la mucosa del estómago.
- 3) Perfil taxonómico: Identificación y cuantificación de especies, géneros o distintos taxones presentes en una muestra para determinar la composición y abundancia relativa de una muestra de microbiota.
- 4) Abundancia relativa: Proporción de un taxón o especie respecto al número total de taxones o especies en un área definida.
- 5) Secuenciación 16S rRNA: Técnica de secuenciación de regiones variables del gen 16S para caracterización taxonómica bacteriana.
- 6) Datos composicionales: Datos donde las abundancias son proporciones relativas y requieren transformaciones adecuadas (ej. CLR).

### B. Revisión

El cáncer gástrico constituye una de las principales causas de mortalidad por cáncer a nivel mundial, con alta carga global y local (Zeng et al., 2024; SICC, DANE). Una de las mayores causas de la muerte por esta enfermedad es la detección tardía, cuando el cáncer se encuentra en sus etapas más avanzadas (Mohamed et al., 2025; Zeng et al., 2024). Su etiología es altamente heterogénea, lo que ha dificultado el desarrollo de metodologías de diagnóstico y tratamiento tempranos (Atherton, 2006; Wang et al., 2024). Adicionalmente, uno de los factores de mayor efecto en el inicio de este tipo de cáncer es la infección por *Helicobacter pylori*, bacteria gramnegativa microaerófila que coloniza la mucosa gástrica y cuya prevalencia global se estima cercana al 50% de la población. La infección crónica se asocia con inflamación persistente, alteraciones en la secreción ácida y modificaciones del microambiente gástrico y alrededor del 3% de la población puede llegar a desarrollar cáncer gástrico, aunque la prevalencia y el riesgo asociado varían según la región geográfica, la edad y la cepa adquirida (La Placa et al., 2025; Zeng et al., 2024).

El papel de este microorganismo en el desarrollo del cáncer no está establecido con claridad, pero se considera que la alteración de su comportamiento en el nicho actúa como disparador de la disbiosis, la inflamación y los cambios en el pH gástrico que permiten la colonización del estómago por microbiota oral e intestinal (Kusters et al., 2006; Zeng et al., 2024). Se han descrito cambios en diversidad, desplazamientos en la composición taxonómica y variaciones en comunidades no-*H. pylori*, lo que sugiere que la infección no solo implica la presencia del patógeno, sino una reorganización del ecosistema microbiano local (Eun et al., 2014; Park et al., 2019; Wang et al., 2024; Yang et al., 2016). Adicionalmente, se ha determinado que pacientes con ciertas abundancias de taxones orales

específicos presentan una menor supervivencia al cáncer gástrico en comparación con otros (Lehr et al., 2023), lo que refuerza la idea de que la composición microbiana asociada al estado de infección podría tener implicaciones clínicas más amplias. Por otra parte, la actividad metabólica de estas comunidades tras la disbiosis se ha convertido en un foco central de estudio por su vínculo con la transición hacia lesiones precancerosas y tumor. Estos hallazgos en conjunto sugieren que la infección por *H. pylori* deja una huella microbiana característica que potencialmente podría ser detectada como un patrón de clasificación, lo que abriría la posibilidad de desarrollar herramientas diagnósticas no invasivas basadas en la composición del microbioma gástrico (Durán et al., 2021; Topçuoğlu et al., 2020).

Sin embargo, los resultados entre estudios muestran heterogeneidad considerable, atribuida en parte a diferencias en el sitio de muestreo (antro, cuerpo gástrico), tipo de muestra (biopsia, jugo gástrico), baja biomasa bacteriana y posibles problemas de contaminación (Sgamato et al., 2024; Sung et al., 2016; Zaramella et al., 2024; Zeng et al., 2024). Adicional a estas fuentes de variabilidad, existen limitaciones metodológicas relacionadas con el modo en que se generan y representan computacionalmente los datos de microbiota.

En estudios basados en secuenciación 16S rRNA, la comunidad microbiana se cuantifica mediante matrices de conteo de variantes de secuencia o taxones generadas a partir de pipelines bioinformáticos, que suelen luego transformarse en abundancias relativas para su análisis comparativo (Chiu y Miller, 2019). Sin embargo, estas abundancias no representan cantidades absolutas de microorganismos, sino proporciones dentro de cada muestra, por lo que están restringidas por una suma constante. Esto implica que un incremento relativo en un taxón necesariamente conlleva una disminución proporcional en otros, incluso si sus cantidades reales no han variado. Debido a esto, los datos derivados de 16S constituyen datos composicionales, cuya estructura puede generar asociaciones artificiales cuando se aplican métodos estadísticos convencionales directamente sobre proporciones. Por ello, se recomienda el uso de transformaciones log-ratio que permitan analizar los datos en un espacio adecuado para inferencia estadística y modelado predictivo (Gloor et al., 2017; Weiss et al., 2017).

Esta representación numérica permite modelar cada muestra como un vector en un espacio multivariado, sobre el cual pueden aplicarse técnicas estadísticas y de aprendizaje automático. Este enfoque, sin embargo, ha mostrado dificultades de reproducibilidad entre cohortes y contextos clínicos, posiblemente debido a la naturaleza composicional de los datos (Gloor et al., 2017), la alta variabilidad interindividual, el efecto dominante de *H. pylori* en individuos infectados, que puede alterar de manera desproporcionada la estructura relativa de la comunidad (Meyer et al., 2022; Lee & Lee, 2024; Wang et al., 2024). Adicionalmente, no existe consenso sobre si las variables más informativas para caracterizar el estado de infección corresponden exclusivamente a abundancias taxonómicas o si patrones de interacción entre microorganismos y características funcionales del ecosistema aportan mayor estabilidad y capacidad predictiva (Zeng et al., 2024).

En este contexto, los enfoques de aprendizaje automático han comenzado a utilizarse para explorar patrones complejos en datos de microbioma, dado que en sistemas ecológicos como el microbioma gástrico las relaciones entre microorganismos pueden ser no lineales y depender de combinaciones multivariadas de abundancias que los métodos estadísticos tradicionales no logran capturar (Chang et al., 2020; Akpoigbe et al., 2022; Zhao et al., 2024). Durán y colaboradores (2021) ha demostrado que la comparación de técnicas lineales y no lineales en datos de microbioma gástrico de pacientes *H. pylori* positivos y negativos permite revelar estructuras de agrupamiento que los métodos lineales no detectan, lo que respalda la pertinencia de este tipo de análisis. Sin embargo, su aplicación en la clasificación del estado de infección por *H. pylori* utilizando

microbiota gástrica humana aún es limitada y requiere evaluación rigurosa en términos de reproducibilidad, control de sesgos técnicos y comparación sistemática frente a modelos lineales clásicos. De manera complementaria, en función de la disponibilidad de información en los conjuntos de datos seleccionados, el análisis podría extenderse en dos direcciones adicionales. Por un lado, la variabilidad en la virulencia de *H. pylori*, determinada por factores como los genotipos *cagA* y *vacA*, podría modular el impacto de la bacteria sobre la comunidad microbiana gástrica, por lo que su integración permitiría explorar si existen diferencias microbianas asociadas no solo al estado de infección, sino también al perfil de virulencia del patógeno (La Placa et al., 2025; Zeng et al., 2024). Por otro lado, dado que la composición microbiana asociada a la infección y distintas cepas de *H. pylori* han mostrado vínculos con la supervivencia al cáncer gástrico (Lehr et al., 2023), podría explorarse si los patrones clasificatorios identificados guardan relación con desenlaces clínicos relevantes.

#### IV. CASO DE ESTUDIO

Durán et al., 2021 (PMID: 33771992). El presente artículo analiza datos de microbioma gástrico en pacientes infectados y no infectados por *Helicobacter pylori*, comparando enfoques analíticos lineales y no lineales para explorar las diferencias estructurales entre los dos escenarios en la comunidad microbiana. Estos autores observan que los enfoques no lineales revelan estructuras no reveladas por otros métodos, pero no evalúan formalmente la capacidad predictiva de dichos patrones. El presente proyecto busca extender este avance mediante la implementación y evaluación comparativa de modelos de aprendizaje automático de redes profundas para caracterizar la microbiota antes y después de la infección con *H. pylori*.

Klymchuk et al., 2017. En este paper se generaron datos de microbiota gástrica obtenida mediante secuenciación 16S rRNA en biopsias humanas, incluyendo individuos infectados y no infectados por *Helicobacter pylori*, con información adicional sobre el estado de virulencia (*CagA*). El estudio caracteriza diferencias en la composición microbiana asociadas al estado de infección, pero no implementa modelos supervisados para evaluar capacidad predictiva. El presente proyecto utilizará este conjunto de datos como base experimental para formular una tarea de clasificación binaria (infectado contra no infectado) y evaluar si los patrones multivariados de la comunidad microbiana permiten discriminar el estado de infección mediante modelos de aprendizaje automático.

#### V. CONJUNTO DE DATOS DE ENTRENAMIENTO

El dataset de entrenamiento a utilizar proviene del paper de Klymchuk y colaboradores (2017), recopilado en la base de datos Sequence Read Archive (SRA) con el código de acceso PRJEB22107. Este cuenta con información de 29 pacientes dentro de tres categorías: no infectados con *H. pylori* (*H.p.*-), infectado con *H. pylori* sin el factor de virulencia *CagA* (*H.p.*+/*CagA*-) e infectado con *H. pylori* con el factor de virulencia *CagA* (*H.p.*+/*CagA*+). Para cada uno de los casos se cuenta con 10 muestras, entre pacientes masculinos y femeninos con una media de edad de aproximadamente 50 años. Estas muestras fueron sometidas a procesamiento por pirosecuenciación 16S rRNA y análisis metagenómico, por lo que se obtienen valores de abundancia de distintos phylum, clases, órdenes, familias y especies bacterianas encontradas en el lumen de los distintos individuos.

El conjunto de datos está estructurado como una matriz de abundancia taxonómica en la que cada una de las muestras corresponde a un vector numérico de características, representando la abundancia relativa de los distintos taxones identificados. El número de características dependerá del nivel taxonómico seleccionado (phylum, clase, orden, familia o género), con el fin de reducir la dimensionalidad y mejorar la estabilidad del modelo dada la relación

entre número de muestras y número de variables. Por otro lado, las abundancias mencionadas se utilizarán como variables de entrada para el modelo y la variable objetivo corresponderá al estado de infección por *Helicobacter pylori*, inicialmente formulado como un problema de clasificación binaria (H.p.+ contra H.p.-). Se explorará además la posibilidad de discriminar entre subgrupos según el estado de virulencia (CagA+ vs CagA-), sujeto a estabilidad estadística del modelo.

El dataset presenta un balance casi equitativo entre categorías, lo cual favorece la evaluación comparativa de modelos supervisados mediante validación cruzada estratificada, pero puede verse limitado para la implementación de arquitecturas complejas debido a su tamaño muestral. Para lidiar con ello, se emplearán estrategias de regularización y validación repetida para minimizar el riesgo de sobreajuste. Adicional a esto, dado que los datos de microbiota son composicionales, se aplicarán transformaciones log-ratio apropiadas antes del entrenamiento de los modelos para asegurar una representación adecuada en el espacio multivariado.

## VI. PREPROCESAMIENTO Y ANÁLISIS EXPLORATORIO DE LOS DATOS

Como se mencionó previamente, las abundancias derivadas de secuenciación 16S rRNA son proporciones relativas restringidas a sumar una constante, lo que exige transformaciones específicas antes de cualquier análisis estadístico o entrenamiento de modelos (Gloor et al., 2017). En el presente trabajo se implementaron dos variantes del enfoque log-ratio para abordar esta restricción: la Centered Log-Ratio (CLR) y su versión robusta (rCLR), complementadas por el análisis de distancias de Aitchison.

### A. Transformación CLR

La transformación CLR (Gloor et al., 2017; Aitchison, 1986) mapea cada composición desde el simplex  $S^{D-1}$  al espacio euclidiano RD expresando la abundancia de cada taxón relativa a la media geométrica de la muestra:

$$\text{clr}(x)_i = \log(x_i + \delta) - (1/D) \cdot \sum \log(x_j + \delta)$$

donde D es el número de géneros y  $\delta = 0.5/11\ 200 \approx 4.46 \times 10^{-5}$  es un pseudoconteo que desplaza los ceros para evitar  $\log(0)$ , escalado a la unidad de abundancia relativa definida por la rarefacción a 11 200 lecturas. Tras la transformación, cada fila de la matriz suma exactamente cero (desviación máxima observada:  $4.21 \times 10^{-12}$ ), verificando la propiedad de suma cero que garantiza la correcta implementación del algoritmo. Las propiedades fundamentales de CLR son: (i) invariancia de escala: produce los mismos valores sobre conteos crudos o abundancias relativas; (ii) equivalencia con la distancia de Aitchison: la distancia euclidiana en espacio CLR es igual a la distancia de Aitchison en el simplex; y (iii) equivalencia con el Logratio Analysis (LRA): la PCA sobre la matriz CLR es algebraicamente equivalente al análisis de todos los log-ratios por pares entre géneros.

La propiedad de suma cero implica que la matriz CLR tiene rango D - 1: la restricción composicional consume un grado de libertad, por lo que el número de componentes principales no redundantes es como máximo  $\min(n - 1, D - 1) = 28$  para este conjunto de datos. Esto se refleja en la configuración del algoritmo PCA, cuyo parámetro  $n\_components$  se establece como  $\min(n - 1, D - 1)$  y no como D.

### B. Transformación rCLR

### C. Distancia de Aitchison y PCA como LRA

### D. UMAP

El análisis exploratorio se implementó en dos versiones paralelas: una que incorpora *Helicobacter pylori* en la tabla OTU y otra que lo elimina antes de cualquier transformación. Esta decisión responde a una consecuencia directa de la naturaleza composicional de los datos: Cuando un taxón domina la composición de un grupo de muestras, como ocurre con *Helicobacter pylori* en muestras H.p.+ (80-90% de

lecturas), la restricción de suma constante fuerza que todas las demás abundancias relativas sean pequeñas, independientemente de si los taxones correspondientes cambiaron biológicamente o no. Tras la transformación CLR, este efecto se traduce en que la media geométrica de la muestra queda deprimida por la presencia de ~130 géneros a nivel de pseudoconteo, lo que infla el valor CLR de *Helicobacter pylori* (+9.73 en el análisis con *H. pylori*) y simultáneamente empuja hacia valores negativos los CLR de prácticamente todos los demás géneros en muestras H.p.+ Gloor y colaboradores (2017), formalizaron este mecanismo: un incremento en un componente genera señales de depleción artefactuales en todos los demás debido a la restricción de suma constante. El resultado observado es que un test estadístico de abundancia diferencial entre grupos detecta diferencias aparentes en el 72.5% de los géneros (132/182), un valor biológicamente inverosímil que refleja el artefacto y no reorganización real del microbioma.

Eliminar *Helicobacter pylori* de la tabla OTU sin renormalizar produce sumas de fila de 0.02–0.20 en muestras H.p.+ , lo que viola la definición de datos composicionales y hace que las abundancias restantes representen fracciones del total original en lugar de proporciones de la comunidad no-*Helicobacter*. La renormalización es por tanto obligatoria:

$$x'_i = x_i / \sum_{k \neq \text{Helicobacter pylori}} x_k$$

donde la suma en el denominador recorre todos los géneros excepto *Helicobacter pylori*. Tras este paso, todas las sumas de fila son exactamente 1.0, y la CLR calculada sobre la tabla renormalizada tiene la interpretación correcta: *log-ratio* de cada género respecto a la media geométrica de la comunidad no-*Helicobacter pylori*. Las sumas de fila del análisis sin renormalización en el análisis con *H. pylori* oscilan entre 0.9986 y 1.0000, diferencia que refleja taxones de la tabla original no capturados en el pivoteo y que es irrelevante para el análisis dado que el assert de control pasa en todos los casos.

Los cambios en las métricas clave entre ambos análisis cuantifican directamente el tamaño del artefacto de supresión (Tabla 1). La reducción del máximo CLR de +9.73 a +8.22 es la huella directa de que la eliminación de *Helicobacter pylori* eleva la media geométrica de referencia de cada muestra H.p.+ , comprimiendo todos los valores CLR hacia cero. De forma análoga, la caída de PC1 del 31.3% al 21.0% cuantifica que aproximadamente 10 puntos porcentuales de la varianza total del dataset están asociados exclusivamente a la presencia o ausencia de *Helicobacter pylori*, no a ninguna estructura del resto de la comunidad. Finalmente, la disminución de géneros significativos de 132 a 19 indica que el 89.5% del microbioma restante exhibía diferencias estadísticas artefactuales inducidas por la dominancia del patógeno.

TABLA 1.  
COMPARACIÓN DE MÉTRICAS CLAVE ENTRE EL ANÁLISIS CON Y SIN  
*HELICOBACTER PYLORI*.

| Métrica                               | Con <i>H. pylori</i> | Sin <i>H. pylori</i> |
|---------------------------------------|----------------------|----------------------|
| Géneros en tabla OTU                  | 182                  | 181                  |
| Género tras filtro $\geq 30\%$        | 60                   | 59                   |
| Sparcidad                             | 72.4%                | 72.8%                |
| Rango CLR                             | -1.51 a +9.73        | -1.66 a +8.22        |
| Rango rCLR                            | -4.16 a +8.76        | -4.18 a +6.47        |
| PC1 varianza explicada                | 31.3%                | 21.0%                |
| PC2 varianza explicada                | 17.6%                | 8.8%                 |
| Géneros significativos ( $p < 0.05$ ) | 132/182 (72.5%)      | 19/181 (10.5%)       |

La reducción en el rango CLR, la varianza explicada por PCA y el número de géneros significativos cuantifica el artefacto de supresión composicional generado por la dominancia de *Helicobacter pylori* en muestras positivas.

Walsh y colaboradores (2024), establecen que conocer los datos antes de modelar es un paso crítico e ineludible, y el set de datos se explica en Figura 1. El panel A verifica que las sumas de abundancias por muestra son  $\approx 1.0$ , confirmando que el pivoteo de la tabla OTU no eliminó taxones silenciosamente. El panel B muestra el balance de clases: 9 muestras H.p.- frente a 20 H.p.+ , una ratio de 1:2.2. Este desequilibrio implica que la exactitud global no es una métrica de evaluación adecuada para los modelos de clasificación, y que deben reportarse por separado la precisión y el recall de cada clase, o métricas integradas como el F1-score o el área bajo la curva ROC. El panel C desglosa los subgrupos CagA dentro de H.p.+ (10 CagA- y 10 CagA+) de forma informativa: aunque ambos subgrupos se colapsan en una sola categoría H.p.+ para el clasificador binario, su distribución en las proyecciones de ordenación permite evaluar si los métodos de reducción dimensional los separan, lo que indicaría que el estado CagA también estructura la comunidad microbiana. Por otra parte, el análisis de los 20 géneros de mayor abundancia media revela la asimetría central del dataset (Figura 2): en el análisis con *H. pylori*, *Helicobacter pylori* representa en promedio  $\approx 56\%$  de las lecturas totales, más que todos los demás géneros combinados. En el análisis sin *H. pylori*, los géneros dominantes son *Streptococcus*, *Prevotella* y *Actinomyces*, todos con abundancias medias inferiores al 10%. Esta visualización establece cuantitativamente por qué cualquier modelo entrenado sobre la comunidad completa tenderá a clasificar el estado de infección detectando la presencia de *Helicobacter pylori* directamente, sin necesidad de capturar patrones de la comunidad residual (Durán et al., 2021).

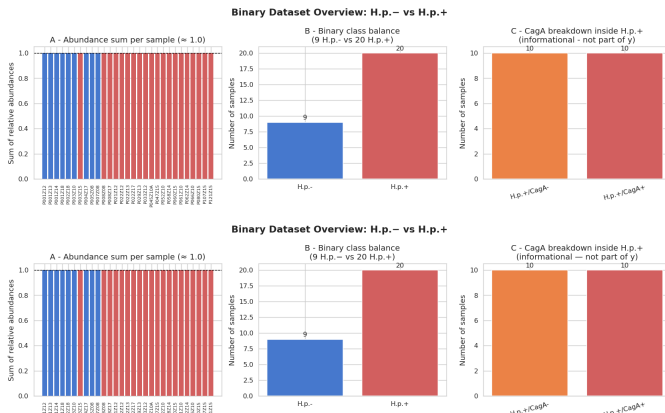


Figura 1. Descripción general del conjunto de datos. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

Los gráficos de violín sobre abundancias sin transformar (Figura 3), por otro lado, muestran, para los 10 géneros más abundantes, la distribución por grupo binario (H.p.- vs H.p.+). En el análisis con *H. pylori*, todos los géneros distintos de *Helicobacter pylori* presentan violines H.p.+ comprimidos hacia cero: sus distribuciones en muestras infectadas son más estrechas y con mediana más baja que en muestras no infectadas. Esta compresión no es biológica sino matemática, consecuencia directa de que *Helicobacter pylori* consume el presupuesto de lecturas en muestras H.p.+ 1. En el análisis sin *H. pylori* y tras renormalización, los mismos géneros muestran distribuciones más amplias en muestras H.p.+ , revelando su varianza real una vez liberados de la compresión composicional. Estas distribuciones asimétricas en datos crudos también ilustran por qué las abundancias no transformadas no deben emplearse directamente como variables de entrada en modelos estadísticos o de aprendizaje automático. En cuanto a la composición por *phylum* (Figura 4), en el análisis con *H. pylori*, las muestras H.p.+ están dominadas visualmente por Proteobacteria (el *phylum* que contiene *Helicobacter pylori*) con valores entre 80% y 98%, mientras que las muestras H.p.- exhiben una mezcla de Firmicutes,

Bacteroidetes y Actinobacteria. En el análisis sin *H. pylori* y tras renormalización, todos los grupos muestran una composición más heterogénea y la separación visual entre H.p.- y H.p.+ se reduce considerablemente, confirmando que la distinción a nivel de *phylum* en el análisis completo era prácticamente en su totalidad consecuencia de un único género dentro de Proteobacteria.




Figura 2. Géneros principales acorde a su abundancia relativa media. Se señala la abundancia relativa media de *Helicobacter pylori* considerando las 29 muestras conjuntamente. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.




Figura 3. Distribuciones de abundancia relativa cruda (top 10 géneros). En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.




Figura 4. Composición a nivel de *phylum*. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.




Figura 5. Prevalencia de géneros y filtrado. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

La prevalencia de cada género (fracción de muestras en la que es detectado) determina qué características se incluyen en el modelo. La mayoría de los 182 géneros son detectados en menos del 20% de las muestras (Figura 5), correspondiendo en gran medida a taxones cuya presencia en el dataset puede atribuirse a variabilidad de muestreo más que a diferencias biológicas reproducibles (Walsh et al., 2024). Se aplicó un umbral de prevalencia del 30%, que en este contexto equivale a aproximadamente 9 muestras. Este umbral es deliberadamente más bajo que el 50% habitual: con  $n = 29$ , un umbral más estricto descartaría géneros biológicamente relevantes que simplemente son menos frecuentes en esta cohorte. Tras el filtrado se retienen 60 géneros en el análisis con *H. pylori* y 59 en el análisis sin *H. pylori*, una dimensionalidad manejable que reduce el riesgo de sobreajuste en los modelos supervivientes.

Para el control de calidad de las transformaciones composicionales se evalúan las abundancias crudas y tras ser transformadas (Figura 6). El panel de abundancias crudas muestra una distribución fuertemente asimétrica a la derecha, característica de datos de microbioma, que viola los supuestos de los métodos paramétricos estándar. Tras la transformación CLR, la distribución se aproxima a una campana simétrica centrada en cero, reflejando la propiedad de suma cero por fila 1. La comparación entre análisis con y sin *H. pylori* es directamente diagnóstica: la reducción del máximo CLR de +9.73 a +8.22, y del máximo rCLR de +8.76 a +6.47, evidencia que la eliminación de *Helicobacter pylori* eleva la media

geométrica de referencia de las muestras H.p.+ , comprimiendo todos los valores hacia cero y produciendo una distribución más equilibrada. Para rCLR, el panel incluye únicamente los valores no nulos (72.4% de ceros se preservan), mostrando un rango más extremo en el mínimo que CLR por la razón descrita, donde la referencia geométrica es más alta al calcularse sólo sobre géneros detectados.




Figura 6. Distribuciones de valores transformados: Crudo, CLR y rCLR. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

El heatmap visualiza los valores CLR de los 40 géneros con mayor varianza entre muestras (la medida correcta de variabilidad para datos composicionales) (Gloor et al., 2017), con muestras ordenadas H.p.- | H.p.+ y la paleta rojo-blanco-azul indicando enriquecimiento (CLR > 0), neutralidad (CLR ≈ 0) y depleción (CLR < 0) respecto a la media geométrica de cada muestra (Figura 7). La escala utiliza los percentiles 2-98 para evitar el colapso de la paleta por valores extremos. En el análisis con *H. pylori*, para muestras H.p.+ , se observa una columna de rojo intenso para *Helicobacter pylori* rodeada de valores negativos (azul) para prácticamente todos los demás géneros. Este patrón es la visualización directa de la restricción de suma cero: el enriquecimiento extremo de *Helicobacter pylori* fuerza valores CLR negativos en toda la comunidad residual (Gloor et al., 2017). En el análisis sin *H. pylori*, el patrón es cualitativamente distinto, ya que ninguna columna domina y los diferentes géneros muestran patrones heterogéneos entre muestras H.p.+ , revelando la variación real de la comunidad no-*Helicobacter pylori*.






Figura 7. Heatmap CLR: Cuarenta géneros de mayor abundancia. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.



Figura 8. Test de Mann-Whitney U para abundancia CLR. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

Para los 6 géneros de mayor varianza CLR, se presentan distribuciones por grupo junto con el resultado del test de Mann-Whitney U (MWU) (Mann y Whitney, 1947) para la comparación binaria H.p.- vs H.p.+ (Figura 8). El MWU es no paramétrico y no supone normalidad, características apropiadas para  $n = 9$  vs  $n = 20$ . En el análisis con *H. pylori*, el género de mayor varianza es *Helicobacter pylori* con separación casi perfecta entre grupos. En el análisis sin *H. pylori*, el top-6 corresponde a géneros biológicamente más diversos, con distribuciones más superpuestas entre grupos y p-valores nominales menos extremos. Es indispensable subrayar que todos los p-valores reportados en esta figura son nominales y no corregidos por comparaciones múltiples. Con 182 géneros a  $\alpha = 0.05$ , aproximadamente 9 géneros serían significativos por azar en ausencia de cualquier efecto real (Benjamini y Hochberg, 1995). Estos resultados deben interpretarse exclusivamente como hipótesis candidatas para análisis confirmatorios, no como evidencia de diferencias biológicas reales.

Por otro lado, la PCA sobre la matriz CLR constituye el Logratio Analysis (LRA) de la comunidad microbiana (Greenacre et al., 2021) (Figura 9). El panel de scree plot documenta la varianza acumulada en función del número de componentes, mientras que el scatter PC1 vs PC2 visualiza la separación entre grupos, tanto con etiquetas binarias como con el desglose CagA. En el análisis con *H. pylori*, PC1 explica el 31.3% y PC2 el 17.6% de la varianza total, con los dos primeros componentes capturando el 48.9%. Esta concentración inusual de varianza en dos dimensiones refleja que PC1 es esencialmente un eje de abundancia de *Helicobacter pylori*, y la separación H.p.-/H.p.+ a lo largo de este eje es casi perfecta. En el análisis sin *H. pylori*, PC1 cae al 21.0% y PC2 al 8.8%, con los dos primeros componentes explicando el 29.8% de la varianza. La varianza ya no está concentrada en el único driver: está distribuida entre múltiples géneros y la separación entre grupos es considerablemente más débil, con mayor solapamiento entre H.p.- y

H.p.+.

Este resultado es coherente con Durán et al. (2021), quienes observaron que la comunidad no-*Helicobacter pylori* no se estructura de forma simple en el espacio PCA para este conjunto de datos.

Esta figura se clasifica como exploratoria en el contexto del pipeline de aprendizaje automático. Walsh et al. (2024) establecen que cualquier transformación que utilice información de todas las muestras, incluyendo PCA, debe ajustarse exclusivamente sobre los datos de entrenamiento de cada fold de validación cruzada y aplicarse sin reajuste sobre los datos de validación. La PCA presentada aquí usa las 29 muestras conjuntamente y sirve para orientar el análisis descriptivo, no como paso de preprocesamiento directamente trasladable al modelo.

Es importante tener en cuenta también el análisis UMAP, que complementa el análisis lineal de PCA al preservar la estructura local de la variedad de los datos (McInnes et al., 2018) (Figura 10). Se usa distancia euclidiana en espacio CLR (equivalente a la distancia de Aitchison) como métrica. En el análisis con *H. pylori*, la separación entre grupos en la proyección 2D es prácticamente completa. En el análisis sin *H. pylori*, la separación es más débil y con mayor solapamiento, aunque UMAP tiende a revelar algo de estructura que PCA no captura, consistente con los hallazgos de Durán et al. (2021). La interpretación de estas proyecciones es exclusivamente cualitativa y exploratoria dada la inestabilidad inherente de UMAP con  $n = 29$ : no deben cuantificarse distancias ni inferirse estructuras de cluster a partir de una única proyección con una semilla fija.




Figura 9. Análisis de componentes principales - Análisis log-ratio. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

Figura 10. Proyección UMAP. A la izquierda, el conjunto de datos incluyendo *H. pylori*. A la derecha, el conjunto de datos excluyéndola.




Figura 11. Matriz de distancias de Aitchison. A la izquierda, el conjunto de datos incluyendo *H. pylori*. A la derecha, el conjunto de datos excluyéndola.




Figura 12. Abundancia diferencial en espacio CLR. A la izquierda, el conjunto de datos incluyendo *H. pylori*. A la derecha, el conjunto de datos excluyéndola.

La matriz 29×29 de distancias de Aitchison (calculadas como distancia euclidiana en espacio CLR) (Figura 11) se visualiza como imagen con la paleta viridis, ordenando filas y columnas por grupo H.p.-/H.p+. En el análisis con *H. pylori*, el bloque diagonal H.p.+ es oscuro (muestras H.p.+ son composicionalmente similares entre sí) porque la dominancia de *Helicobacter pylori* homogeniza la composición de todas las muestras infectadas. En el análisis sin *H. pylori*, el bloque H.p.+ es más heterogéneo, ya que la comunidad no-*Helicobacter pylori* varía sustancialmente entre muestras infectadas, reflejando diferencias individuales en la respuesta del huésped o el estadio de la infección. Esta visualización establece que la similitud aparente entre muestras H.p.+ en el análisis completo es un producto de la homogeneización por *Helicobacter pylori*, no de una comunidad residual uniforme. Finalmente, el volcánplot grafica, para cada género, la diferencia media de CLR entre H.p.+ y H.p.- frente a  $-\log_{10}$  (p-valor nominal MWU) (Figura 12). El contraste entre análisis es el resultado más informativo de todo el EDA, ya que muestra 132/182 géneros (72.5%) significativos en el análisis con *H. pylori* frente a 19/181 géneros (10.5%) en el análisis sin *H. pylori*. El mecanismo ya descrito, la dominancia de *Helicobacter pylori* fuerza valores CLR negativos sistemáticamente en toda la comunidad H.p.+ , explica por qué el 72.5% es una firma del artefacto composicional y no de biología real (Gloor et al., 2017). Los 19 géneros del análisis sin *H. pylori* representan las hipótesis candidatas más plausibles de reorganización microbiana genuinamente asociada a la infección. Incluso en este caso, con 181 tests a  $\alpha = 0.05$  se esperan aproximadamente 9 falsos positivos por azar 9, por lo que estos resultados tienen carácter exclusivamente exploratorio y requieren validación en cohortes independientes de mayor tamaño.





Figura 13. Resumen de selección de características. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

La ingeniería de características se visualiza en la Figura 13, donde el panel A muestra la varianza CLR de todos los géneros en orden descendente con el corte de prevalencia marcado, evidenciando que los géneros eliminados tienen varianza CLR marginal y contribuirían más ruido que señal al modelo. El panel B presenta la matriz de correlación de Pearson entre los 30 géneros de mayor varianza CLR, donde la presencia de bloques de correlación positiva refleja co-ocurrencia ecológica y, en parte, la restricción composicional residual; géneros altamente correlacionados son potencialmente redundantes como características independientes. El panel C muestra una PCA sobre la tabla CLR filtrada por prevalencia, confirmando que la estructura de grupos se mantiene tras el filtrado.

## VII. GENERACIÓN DE DATASET AUMENTADO USANDO UNA RED GENERATIVA ANTAGÓNICA GAN

Dado que el dataset original contaba únicamente con 29 registros de perfiles de microbioma gástrico (divididos entre pacientes positivos y negativos para *Helicobacter pylori*), se identificó la necesidad de aplicar una técnica de aumento de datos (Data Augmentation) que preservara la estructura biológica de los datos sin limitarse a simples transformaciones geométricas. Para esto se diseñó e implementó una Red Generativa Antagónica (GAN), arquitectura que permite aprender la distribución subyacente de los datos reales y generar muestras sintéticas estadísticamente coherentes.

### A. Preparación de Los Datos

Los datos de entrada consistían en perfiles de abundancia de taxones bacterianos a nivel de género, previamente transformados con la técnica CLR (Center Log-Ratio), lo cual produce valores reales positivos y negativos sin un rango fijo. Dado que las funciones de activación de las redes neuronales son sensibles a la magnitud de los valores de entrada, se aplicó una normalización MinMaxScaler para acotar todos los valores al rango estricto de  $[-1, 1]$ , garantizando estabilidad durante el entrenamiento. Se trabajaron por separado dos subconjuntos: el grupo HP (con *H. pylori*, 60 taxones) y el grupo NHP (sin *H. pylori*, 59 taxones).

### B. Implementación de la Arquitectura AC-GAN Binaria

Se diseñó una variación de la Auxiliary Classifier GAN (AC-GAN) adaptada para datos tabulares, compuesta por dos redes que compiten en un proceso de optimización mutua:

**Generador:** Recibe como entrada un vector de ruido aleatorio de 16 dimensiones (espacio latente) y una etiqueta binaria de clase (0 o 1), y produce un vector sintético de 60 taxones. La dimensión latente de 16 fue elegida deliberadamente para forzar a la red a aprender los "factores biológicos" ocultos sin memorizar el ruido. La capa de salida utiliza activación tanh, lo que matemáticamente obliga al generador a producir valores dentro del mismo rango  $[-1, 1]$  que los datos de entrenamiento.

**Discriminador:** Arquitectura de salida múltiple (multi-output) con dos cabezas: una neurona sigmoid para predecir si la muestra es real o sintética, y otra para diagnosticar la presencia de *H. pylori*. La capa oculta cuenta con 128 neuronas y activación LeakyReLU.

**Modelo combinado:** Para el entrenamiento conjunto, el discriminador se congela (trainable = False) durante la fase de

actualización del generador, y se activa (`trainable = True`) durante su propia fase de aprendizaje. Este interruptor explícito fue una solución técnica crítica para garantizar que ambas redes actualizaran sus pesos correctamente bajo las restricciones de Keras 3.

### C. Proceso de Entrenamiento y Búsqueda del Equilibrio de Nash

El principal desafío del entrenamiento fue lograr que el generador y el discriminador aprendieran a un ritmo equilibrado. Se realizaron múltiples iteraciones:

En los intentos iniciales, el generador reducía su pérdida rápidamente ( $\sim 0.3$ ) mientras la pérdida del discriminador se disparaba por encima de 2.5, lo que indicaba que este quedaba "ciego" frente a las muestras sintéticas. Se descartó el colapso de modo (Mode Collapse) mediante validación manual, confirmando que el generador producía muestras diversas; el discriminador simplemente carecía de capacidad suficiente.

La solución definitiva consistió en dos ajustes estructurales: igualar la capacidad de ambas redes a 128 neuronas en su capa oculta, y la introducción del interruptor manual de entrenamiento (`trainable`) dentro del bucle de épocas. Con estos cambios, el modelo GAN del grupo HP se entrenó durante 2,000 épocas, alcanzando el equilibrio de Nash con una pérdida del discriminador estabilizada en  $\sim 0.49$  y la del generador en  $\sim 1.38$ . Para el grupo NHP se replicó la misma arquitectura con 1,000 épocas de entrenamiento.

### D. Generación y Validación del Dataset Aumentado

Una vez entrenadas ambas GANs, se generaron 1,000 muestras sintéticas por cada grupo (HP y NHP), produciendo un dataset aumentado de 2,000 registros. La calidad de las muestras generadas fue evaluada mediante tres pruebas:

#### 1) Análisis PCA

La proyección en dos dimensiones no mostró una separación visual clara entre los datos reales y sintéticos. Sin embargo, esto se interpreta como un fenómeno propio de datos ómicos de alta dimensionalidad, donde los patrones relevantes suelen perderse en proyecciones lineales a 2D.




Figura 14. Datos Reales vs Sintéticos generados por entrenamiento de Red GAN.

#### 2) Preservación de la estructura de correlación

El análisis de la diferencia entre las matrices de correlación cruzada de los datos reales y sintéticos arrojó un error medio mínimo (cercano a 0), confirmando que la GAN aprendió y replicó con fidelidad las complejas redes de co-ocurrencia biológica entre los taxones.




Figura 15. Mapa de calor de diferencia de correlación de datos generados por Red GAN.

#### 3) Validación predictiva TSTR (Train on Synthetic, Test on Real)

Se entrenó un clasificador `RandomForestClassifier` exclusivamente con los datos sintéticos y se evaluó sobre los pacientes reales originales. El modelo alcanzó una precisión del 96.55%, validando que los patrones biológicos codificados en los datos sintéticos son estadísticamente equivalentes a los de los datos reales.

#### 4) Verificación anti-colapso de modo

Para el grupo NHP se calculó la desviación estándar media de los taxones generados, confirmando diversidad suficiente en las muestras (valor superior al umbral de 0.1).

## VIII. APROXIMACIÓN DE REDES NEURONALES SUPERFICIALES

### A. Datos de Entrada

El conjunto de datos utilizado para el entrenamiento y evaluación de los modelos corresponde al dataset aumentado generado por la red GAN descrita en la sección anterior, compuesto por 2,000 muestras sintéticas con perfiles de abundancia microbiana a nivel de género, así como el conjunto de datos original para la evaluación *Leave One Out*, con 29 muestras asociadas a sus metadatos (`Sample_ID`), con perfiles de abundancia microbiana a nivel de género. Ambos conjuntos de datos fueron transformados con la técnica CLR (Center Log-Ratio). Cada registro cuenta con un vector de features correspondiente a los taxones identificados en los datos originales, así como una etiqueta binaria indicando la presencia (1) o ausencia (0) de *Helicobacter pylori*.

El entrenamiento se realizó con las 2000 muestras del conjunto de datos sintéticos, sin generar un conjunto de validación y prueba durante el entrenamiento, y utilizando como prueba las 29 muestras originales con y sin *Helicobacter pylori*:

### B. Arquitectura Implementada

Se diseñó e implementó la arquitectura del perceptrón multicapa (*Multilayer Perceptron*, MLP) para la tarea de clasificación binaria, compuesto por una capa de entrada cuya dimensionalidad corresponde al número de *features* del conjunto de datos, seguida de dos capas ocultas densas con 64 y 32 unidades respectivamente, ambas con función de activación ReLU. Tras cada capa oculta se aplica una capa de Dropout con tasa de 0.3 con el fin de reducir el sobreajuste durante el entrenamiento. La capa de salida cuenta con una única neurona con función de activación sigmoide, acorde con la naturaleza binaria de la tarea. El modelo fue compilado con el



optimizador Adam y la función de pérdida de entropía cruzada binaria.

### C. Proceso de Validación y Prueba con Dataset Original

Una vez completado el entrenamiento sobre el conjunto de datos sintético, se llevó a cabo la validación mediante validación cruzada *Leave-One-Out* (LOO-CV), una técnica en la que el número de *folds* es igual al número de muestras disponibles en el conjunto de evaluación, de manera que en cada iteración una única muestra es apartada como dato de prueba y el resto se destina al entrenamiento. Dado que en este caso el entrenamiento se realizó sobre el conjunto sintético GAN y no sobre los datos originales, el protocolo se adaptó haciendo que, en cada fold, una muestra del conjunto original fuese apartada como dato de prueba, mientras el modelo era entrenado desde cero con la totalidad del conjunto GAN, durante 100 épocas y con un tamaño de batch de 16. El preprocesamiento, donde se hizo selección de características mediante *VarianceThreshold* con umbral de 0.01 y estandarización mediante *StandardScaler*, fue ajustado exclusivamente sobre los datos de entrenamiento GAN y posteriormente aplicado a la muestra de prueba, evitando así la fuga de información entre conjuntos. Este protocolo se ejecutó de forma independiente para dos escenarios: uno incluyendo el género *Helicobacter* como feature (escenario HP) y otro excluyéndolo (escenario NHP), resultando en 29 iteraciones de evaluación por escenario.

## IX. APROXIMACIÓN DE REDES NEURONALES PROFUNDAS

### A. Datos de Entrada

El conjunto de datos utilizado para el entrenamiento y evaluación de los modelos corresponde al dataset aumentado generado por la red GAN descrita en la sección anterior, compuesto por 2,000 muestras sintéticas con perfiles de abundancia microbiana a nivel de género, transformados con la técnica CLR (Center Log-Ratio). Cada registro cuenta con un vector de features correspondiente a los taxones identificados en los datos originales, así como una etiqueta binaria indicando la presencia (1) o ausencia (0) de *Helicobacter pylori*.

Este dataset fue dividido en tres subconjuntos de forma estratificada para garantizar la representación proporcional de ambas clases en cada partición:

- 1) Entrenamiento (70%): 1,400 muestras utilizadas para actualizar los pesos de cada modelo.
- 2) Validación (15%): 300 muestras empleadas durante el entrenamiento para monitorear el rendimiento y detectar sobreajuste.
- 3) Prueba (15%): 300 muestras reservadas para la evaluación imparcial de la capacidad de generalización de cada arquitectura.

La decisión de asignar una proporción mayoritaria al conjunto de prueba responde al objetivo central del proyecto: evaluar con la mayor solidez estadística posible si los modelos entrenados con datos sintéticos logran generalizar hacia datos no vistos, antes de enfrentarlos al dataset real.

### B. Arquitecturas Implementadas

Se diseñaron e implementaron tres arquitecturas de redes neuronales profundas para la tarea de clasificación binaria, cada una con características estructurales diferenciadas que permiten explorar distintos enfoques de aprendizaje sobre datos tabulares de microbioma.

#### 1) MLP Con Regularización Fuerte

La primera arquitectura consiste en un Perceptrón Multicapa (Multilayer Perceptron, MLP) de tipo secuencial, compuesto por cuatro capas densas completamente conectadas (fully connected) apiladas en secuencia, con dimensiones de 256, 128, 64 y 32 neuronas

respectivamente. Cada una de las tres primeras capas incorpora Normalización por Lotes (Batch Normalization) seguida de activación ReLU y capas de Dropout con tasas de 0.4, 0.3 y 0.3 progresivamente, configuradas para combatir el sobreajuste. La capa de salida consta de una única neurona con activación sigmoid para producir una probabilidad de clasificación binaria.

Esta arquitectura profunda permite aprender representaciones jerárquicas de las co-abundancias microbianas, donde las capas iniciales capturan patrones locales entre géneros bacterianos y las capas superiores abstracciones de mayor orden biológico. La regularización combinada de Dropout y Batch Normalization actúa como un mecanismo de control frente al sobreajuste inherente a datasets de tamaño moderado. El modelo fue compilado con el optimizador Adam y función de pérdida de entropía cruzada binaria.

#### 2) MLP Residual (ResNet Tabular)

La segunda arquitectura introduce conexiones residuales (skip connections) entre bloques de procesamiento, inspiradas en la arquitectura ResNet originalmente propuesta para visión por computadora y aquí adaptada para datos tabulares. La red inicia con una capa densa de proyección a 256 dimensiones con Batch Normalization, activación ReLU y Dropout (0.4), seguida de tres bloques residuales con 256, 128 y 64 unidades respectivamente.

Cada bloque residual ejecuta la siguiente operación: aplica dos transformaciones densas sucesivas con Batch Normalization, y suma el resultado con la entrada original del bloque (la conexión residual o shortcut). Cuando la dimensionalidad de entrada y salida del bloque difieren, se aplica una proyección lineal a la conexión residual para hacer compatibles las dimensiones antes de la suma. Tras la adición, se aplica una activación ReLU.

El valor de este diseño radica en que las skip connections permiten que los gradientes fluyan directamente a través de la red sin degradarse, mitigando el problema del desvanecimiento del gradiente (vanishing gradient) que limita a los MLP convencionales al incrementar su profundidad. En el contexto del microbioma, esto permite capturar simultáneamente relaciones lineales directas entre géneros bacterianos e interacciones no lineales de orden superior. El modelo fue compilado con los mismos hiperparámetros que el MLP base.

#### 3) TabNet

La tercera arquitectura implementada es TabNet, un modelo diseñado específicamente para datos tabulares que combina la capacidad expresiva del aprendizaje profundo con un mecanismo de atención secuencial que otorga interpretabilidad al proceso de clasificación.

A diferencia de las arquitecturas anteriores, la profundidad de TabNet no se articula mediante el apilamiento de capas densas, sino a través de  $n\_steps = 3$  pasos de atención secuenciales. En cada paso, la red ejecuta dos operaciones principales: un Attentive Transformer que genera una máscara de atención sobre las features de entrada, decidiendo qué taxones bacterianos son más informativos para ese paso particular; y un Feature Transformer que procesa las features seleccionadas y produce una representación útil para la predicción. Las salidas de todos los pasos se acumulan y se pasan a la capa de salida final.

Un parámetro clave es el factor de relajación  $\gamma = 1.3$ , que controla la penalización que recibe cada feature por

haber sido seleccionada en pasos anteriores, incentivando a la red a considerar diferentes subconjuntos de taxones en cada paso y evitando que la atención colapse siempre sobre las mismas variables. Los hiperparámetros de dimensionalidad se fijaron en  $N_a = N_d = 8$  para el tamaño de los transformadores de atención y de features respectivamente, y se aplicó una tasa de Dropout de 0.2. El modelo fue compilado con Adam y entropía cruzada binaria.

Todos los modelos fueron entrenados durante 20 épocas con un tamaño de batch de 32, monitoreando la exactitud (accuracy) como métrica principal durante el entrenamiento.

### C. Proceso de Validación y Prueba con Dataset Original

Una vez completado el entrenamiento de cada arquitectura sobre el dataset sintético, se llevó a cabo un protocolo de evaluación en dos niveles con el propósito de medir tanto la capacidad de generalización interna como la transferibilidad hacia datos biológicos reales.

Cada modelo fue evaluado sobre el conjunto de prueba sintético (15% del dataset GAN, 300 muestras) y sobre el conjunto de validación, obteniendo métricas de pérdida y exactitud en condiciones controladas.

Como prueba definitiva de la utilidad clínica del enfoque, los tres modelos fueron evaluados directamente sobre el dataset original de 29 registros reales de microbioma gástrico. Estos datos no participaron en ninguna etapa del entrenamiento ni de la validación, por lo que representan un conjunto de prueba completamente independiente que permite determinar si los patrones aprendidos a partir de datos sintéticos son transferibles a muestras biológicas auténticas.

Para cada modelo y sobre el dataset original, se computaron la matriz de confusión y el reporte de clasificación completo, que incluye métricas de precisión (accuracy), exhaustividad (recall), puntuación F1 (f1-score) y soporte por clase, tanto a nivel individual como en sus promedios macro y ponderado. Adicionalmente, las predicciones de cada modelo sobre ambos conjuntos (sintético y original) fueron exportadas como archivos CSV para facilitar análisis comparativos posteriores.

## X. RESULTADOS FINALES Y EVALUACIÓN DE DESEMPEÑO

### A. Resultados Arquitectura de Red Superficial

#### 1) Resultados Escenario Con Helicobacter (HP)

En el escenario HP el modelo alcanzó una exactitud del 82.76%, un F1-score de 0.8889 y un ROC-AUC de 0.8889 sobre los 29 pacientes originales. Estos valores indican un desempeño razonablemente sólido para un modelo de solo dos capas ocultas entrenado íntegramente sobre datos sintéticos, especialmente considerando que el ROC-AUC de 0.89 refleja una buena capacidad discriminante entre las dos clases más allá del umbral de decisión del 50%.

El análisis por clase revela un comportamiento asimétrico: los 20 pacientes positivos para *H. pylori* fueron clasificados correctamente en su totalidad (recall del 100% para Clase 1), mientras que 5 de los 9 pacientes negativos fueron clasificados erróneamente como positivos (recall del 44% para Clase 0). Esta asimetría no es casual: refleja que la GAN generó perfiles del grupo HP con mayor coherencia interna y separabilidad, probablemente porque la presencia de *Helicobacter* como feature dominante ancla la distribución sintética de ese grupo de manera más definida. El modelo aprendió con mayor certeza los patrones del grupo positivo, pero a costa de ser conservador en exceso al clasificar negativos.

TABLA 2.

MATRIZ DE CONFUSIÓN MLP SUPERFICIAL, ESCENARIO CON HELICOBACTER

|                    | Pred: Negativo (0) | Pred: Positivo (1) |
|--------------------|--------------------|--------------------|
| Real: Negativo (0) | 4(VN)              | 5(FP)              |
| Real: Positivo (1) | 0(FN)              | 20(VP)             |

TABLA 3.

REPORTE DE CALCIFICACIÓN MLP SUPERFICIAL, ESCENARIO CON HELICOBACTER

| Clase        | Precisión | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Negativo (0) | 1.00      | 0.44   | 0.62     | 9       |
| Positivo(1)  | 0.8       | 1.00   | 0.89     | 20      |
| Accuracy     |           |        | 0.83     | 29      |
| Macro AVG    | 0.9       | 0.72   | 0.75     | 29      |
| Weighted AVG | 0.86      | 0.83   | 0.8      | 29      |

#### 2) Resultados Escenario Sin Helicobacter (NHP)

El escenario NHP expuso una limitación estructural severa del modelo superficial. Al excluir la columna *Helicobacter*, el MLP alcanzó una exactitud del 24.14%, un F1-score de 0.2143 y un ROC-AUC de 0.2556. Estos valores no solo se encuentran muy por debajo de una clasificación aleatoria (50%), sino que están por debajo de un clasificador mayoritario trivial que predijera siempre la clase positiva (que obtendría un 68.97% de exactitud dado el desbalance del conjunto). En la práctica, el modelo invirtió la distribución de predicciones: clasificó correctamente apenas 4 de los 9 pacientes negativos y solo 3 de los 20 pacientes positivos, errando en 22 de 29 casos.

TABLA 4.

MATRIZ DE CONFUSIÓN MLP SUPERFICIAL, ESCENARIO SIN HELICOBACTER

|                    | Pred: Negativo (0) | Pred: Positivo (1) |
|--------------------|--------------------|--------------------|
| Real: Negativo (0) | 4(VN)              | 5(FP)              |
| Real: Positivo (1) | 17(FN)             | 3(VP)              |

TABLA 5.

REPORTE DE CALCIFICACIÓN MLP SUPERFICIAL, ESCENARIO SIN HELICOBACTER

| Clase        | Precisión | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Negativo (0) | 0.19      | 0.44   | 0.27     | 9       |
| Positivo(1)  | 0.38      | 0.15   | 0.21     | 20      |
| Accuracy     |           |        | 0.24     | 29      |
| Macro AVG    | 0.9       | 0.72   | 0.24     | 29      |
| Weighted AVG | 0.32      | 0.24   | 0.23     | 29      |

#### 3) Diagnóstico

El colapso del modelo en el escenario NHP responde a un problema de subajuste (underfitting), no de sobreajuste. El modelo no tiene capacidad suficiente para aprender la estructura discriminante del problema cuando se elimina el feature más informativo. Esto se evidencia en que el error no es producto de memorización excesiva de los datos de entrenamiento, sino de incapacidad para capturar las relaciones no lineales y de alto orden entre los 59 taxones restantes que permiten distinguir los dos grupos en ausencia de *Helicobacter*.

La causa raíz es doble. Por un lado, la dependencia crítica de un único feature: la presencia del género *Helicobacter* actúa como señal discriminante dominante en el problema,

y una red de solo dos capas no logra construir representaciones distribuidas del microbioma que capturen la señal diagnóstica a partir de las interacciones sutiles entre múltiples géneros bacterianos. Por otro lado, existe una brecha de distribución (distribution shift) entre los datos sintéticos GAN y los datos biológicos reales que se vuelve insalvable para un modelo de capacidad limitada: sin la señal directa de *Helicobacter*, los patrones de co-abundancia microbiana generados por la GAN no son suficientemente transferibles al dominio real.

En el escenario HP, el modelo exhibe un comportamiento diferente pero igualmente diagnóstico. El desempeño perfecto que se esperaría sobre el conjunto de entrenamiento sintético (dado que la red converge sobre 2,000 muestras balanceadas con señal clara) contrasta con la exactitud del 82.76% sobre los datos reales. Esta brecha evidencia sobreajuste a la distribución sintética: el modelo aprendió patrones que son válidos dentro del espacio generado por la GAN, pero que no capturan la totalidad de la variabilidad biológica presente en muestras clínicas reales, particularmente en los pacientes negativos cuya diversidad microbiana real es más heterogénea que la sintetizada.

Cabe destacar que las técnicas de regularización aplicadas (Dropout del 30%) controlaron efectivamente el sobreajuste clásico a los datos de entrenamiento, pero no pueden compensar la brecha de distribución entre el dominio sintético y el dominio real.

## B. Resultados Arquitecturas de Red Profundas

### 1) Desempeño Durante el Entrenamiento

Los tres modelos fueron entrenados durante 20 épocas sobre el dataset sintético de 2,000 registros, utilizando el 70% para entrenamiento y monitoreando el rendimiento sobre el 15% de validación en cada época.

MLP con Regularización Fuerte mostró una convergencia rápida y estable. Desde la época 1 alcanzó una exactitud de entrenamiento del 64%, escalando a 100% a partir de la época 6 y manteniéndola hasta el final. La pérdida de entrenamiento descendió de 0.6226 en la primera época a 0.0069 en la época 20. El conjunto de validación siguió una trayectoria igualmente favorable, alcanzando el 100% de exactitud desde la época 4 y reduciendo su pérdida a 0.0012 al finalizar.




Figura 16. Curvas de Accuracy y Loss durante el entrenamiento del modelo MLP con regularización fuerte.

MLP Residual (ResNet Tabular) mostró un arranque más lento que el MLP base, con una exactitud de validación de apenas 56% en la primera época, lo que refleja la mayor complejidad de la arquitectura. Sin embargo, a partir de la época 6 alcanzó el 100% de exactitud tanto en entrenamiento como en validación, y la pérdida de validación continuó descendiendo hasta valores

extremadamente bajos ( $2.72 \times 10^{-4}$  en la época 20), lo que indica una convergencia muy precisa sobre los datos sintéticos.




Figura 17. Curvas de Accuracy y Loss durante el entrenamiento del modelo MLP Residual.

TabNet presentó el comportamiento de convergencia más lento de los tres modelos, con una exactitud de entrenamiento de apenas 50% en las primeras épocas, equivalente a clasificación aleatoria. Esto se explica por la naturaleza secuencial del mecanismo de atención, que requiere más iteraciones para aprender qué taxones seleccionar en cada paso. A partir de la época 10 alcanzó el 100% de exactitud en entrenamiento y validación, aunque sus valores de pérdida final (0.0350 en entrenamiento y 0.0323 en validación) fueron considerablemente más altos que los de las arquitecturas MLP, lo que sugiere que la red aún no saturó su capacidad de ajuste sobre los datos sintéticos dentro de las 20 épocas asignadas. (Insertar aquí imagen de curvas de entrenamiento TabNet — Título:




Figura 18. Curvas de Accuracy y Loss durante el entrenamiento del modelo TabNet.

### 2) Evaluación sobre el Dataset Original de 29 Registros Reales

La prueba más relevante del proyecto consistió en evaluar los modelos entrenados exclusivamente sobre datos sintéticos contra los 29 registros biológicos reales del dataset original. Esta evaluación mide la capacidad de transferibilidad del aprendizaje sintético hacia datos clínicos auténticos.

El dataset original contiene 9 pacientes negativos para *H. pylori* (Clase 0) y 20 pacientes positivos (Clase 1).

MLP con Regularización Fuerte clasificó correctamente 26 de los 29 pacientes, alcanzando una exactitud del 89.66%. Los 3 errores corresponden a falsos negativos de la Clase 0 (pacientes negativos clasificados como positivos). La precisión para la Clase 0 fue del 100% con un recall del 67%, mientras que para la Clase 1 obtuvo una precisión del 87% y un recall del 100%. El F1-score ponderado fue de 0.89.

TABLA 6.

MATRIZ DE CONFUSIÓN MLP CON REGULARIZACIÓN FUERTE

|                    | Pred: Negativo (0) | Pred: Positivo (1) |
|--------------------|--------------------|--------------------|
| Real: Negativo (0) | 6(VN)              | 3(FP)              |
| Real: Positivo (1) | 0(FN)              | 20(VP)             |

TABLA 7.  
REPORTE DE CALCIFICACIÓN MLP CON REGULARIZACIÓN FUERTE

| Clase        | Precisión | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Negativo (0) | 1.00      | 0.67   | 0.8      | 9       |
| Positivo(1)  | 0.87      | 1.00   | 0.93     | 20      |
| Accuracy     |           |        | 0.9      | 29      |
| Macro AVG    | 0.93      | 0.83   | 0.87     | 29      |
| Weighted AVG | 0.91      | 0.90   | 0.89     | 29      |

MLP Residual (ResNet Tabular) fue el modelo de mejor desempeño sobre el dataset real, clasificando correctamente 27 de 29 pacientes con una exactitud del 93.10%. Cometió únicamente 2 errores, ambos falsos negativos de Clase 0. Obtuvo una precisión del 100% para Clase 0 con recall del 78%, y precisión del 91% con recall del 100% para Clase 1. El F1-score ponderado fue de 0.93.

TABLA 8.  
MATRIZ DE CONFUSIÓN MLP RESIDUAL (RESNET TABULAR)

|                    | Pred: Negativo (0) | Pred: Positivo (1) |
|--------------------|--------------------|--------------------|
| Real: Negativo (0) | 7(VN)              | 2(FP)              |
| Real: Positivo (1) | 0(FN)              | 20(VP)             |

TABLA 9.  
REPORTE DE CALCIFICACIÓN MLP RESIDUAL (RESNET TABULAR)

| Clase        | Precisión | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Negativo (0) | 1.00      | 0.78   | 0.88     | 9       |
| Positivo(1)  | 0.91      | 1.00   | 0.95     | 20      |
| Accuracy     |           |        | 0.93     | 29      |
| Macro AVG    | 0.95      | 0.89   | 0.91     | 29      |
| Weighted AVG | 0.94      | 0.93   | 0.93     | 29      |

TabNet clasificó correctamente 24 de 29 pacientes con una exactitud del 82.76%, siendo el modelo de menor transferibilidad al dominio real. Los 5 errores fueron también falsos negativos de Clase 0, lo que indica que el mecanismo de atención aprendido sobre los datos sintéticos no capturó con suficiente fidelidad los patrones de los pacientes negativos reales. La precisión para Clase 0 fue del 100% con un recall de apenas 44%, y para Clase 1 obtuvo precisión del 80% y recall del 100%. El F1-score ponderado fue de 0.80.

TABLA 10.  
MATRIZ DE CONFUSIÓN TABNET

|                    | Pred: Negativo (0) | Pred: Positivo (1) |
|--------------------|--------------------|--------------------|
| Real: Negativo (0) | 4(VN)              | 5(FP)              |
| Real: Positivo (1) | 0(FN)              | 20(VP)             |

TABLA 11.  
REPORTE DE CALCIFICACIÓN TABNET

| Clase        | Precisión | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Negativo (0) | 1.00      | 0.44   | 0.62     | 9       |
| Positivo(1)  | 0.8       | 1.00   | 0.89     | 20      |
| Accuracy     |           |        | 0.83     | 29      |

| Clase        | Precisión | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Macro AVG    | 0.9       | 0.72   | 0.75     | 29      |
| Weighted AVG | 0.86      | 0.83   | 0.8      | 29      |

### 3) Diagnóstico

Un análisis comparativo entre el desempeño sobre datos sintéticos y datos reales revela un patrón consistente en los tres modelos que merece discusión. Los tres alcanzan exactitudes perfectas (100%) sobre el conjunto de prueba sintético, pero exhiben caídas de rendimiento al evaluar sobre los datos reales: 89.66% para el MLP, 93.10% para el ResNet y 82.76% para el TabNet. Esta brecha evidencia la presencia de sobreajuste a la distribución sintética, un fenómeno esperado dado que los modelos fueron entrenados íntegramente sobre datos generados por la GAN.

El sobreajuste no se origina en una memorización excesiva de los datos de entrenamiento en el sentido clásico, las técnicas de regularización aplicadas (Dropout, Batch Normalization) controlaron efectivamente esa forma de sobreajuste, sino en la brecha de distribución (distribution shift) entre los datos sintéticos y los datos biológicos reales. La GAN, aunque validada estadísticamente, no reproduce la totalidad de la variabilidad biológica presente en muestras clínicas reales. En particular, los tres modelos muestran dificultades para identificar correctamente a los pacientes negativos para *H. pylori* (Clase 0), lo que sugiere que los perfiles sintéticos de este grupo no capturaron con total precisión la diversidad microbiana de los pacientes sanos.

El hecho de que el ResNet Tabular sea el modelo más robusto ante esta brecha de distribución es consistente con su arquitectura: las conexiones residuales le permiten preservar representaciones de bajo nivel aprendidas en capas tempranas, haciéndolo menos susceptible a la especialización excesiva sobre patrones específicos de la distribución sintética.

### C. Comparación, Análisis y Discusión de los Resultados

La siguiente tabla consolida el desempeño de todos los clasificadores evaluados sobre las 29 muestras originales, que constituyen la prueba definitiva del proyecto. Las métricas incluyen exactitud (accuracy), precisión, recall (sensibilidad), especificidad y F1-score. Para los modelos deep, los resultados provienen de la evaluación directa sobre el dataset original; para el modelo shallow, provienen de la validación cruzada LOO-CV.

TABLA 12.  
COMPARACIÓN CONSOLIDADA DE TODOS LOS CLASIFICADORES SOBRE LAS 29 MUESTRAS REALES

| Familia | Modelo             | Accuracy | Precisión | Recall | Specificity | F1     |
|---------|--------------------|----------|-----------|--------|-------------|--------|
| Deep    | ResNet Tabular     | 0.9310   | 0.9091    | 1      | 0.777       | 0.9524 |
| Deep    | MLP                | 0.8966   | 0.8696    | 1      | 0.666       | 0.93   |
| Deep    | Profundo           | 0.8276   | 0.8       | 1      | 0.444       | 0.888  |
| Shallow | TabNet MLP         | 0.8966   | 0.8696    | 1      | 0.666       | 0.9302 |
| Shallow | Shallow (hp-GA N)  | 0.2414   | 0.3750    | 0.15   | 0.444       | 0.2143 |
| Shallow | Shallow (nhp-GA N) |          |           |        |             |        |

Dentro de los modelos deep, existe una jerarquía clara de desempeño que se explica por las diferencias arquitectónicas de cada modelo. El ResNet Tabular es el clasificador más sólido, con 27 aciertos de 29, F1 de 0.9524 y únicamente 2 falsos positivos. Le sigue el MLP Profundo, con 26 aciertos de 29 y F1 de 0.9302, y en tercer lugar el TabNet, con 24 aciertos de 29 y F1 de 0.8889.

Un hallazgo transversal a los tres modelos deep es el recall perfecto de 1.0 sobre el conjunto original: ninguno de los 20 pacientes positivos para *H. pylori* fue clasificado erróneamente como negativo. Este resultado tiene una interpretación clínica directa: desde una perspectiva de diagnóstico médico, la consecuencia más grave es un falso negativo (no detectar la infección en un paciente que sí la tiene), y los tres modelos la evitan por completo. La diferencia entre ellos radica exclusivamente en cuántos pacientes negativos confunden como positivos, es decir, en la especificidad: 77.78% para ResNet, 66.67% para MLP Profundo y 44.44% para TabNet.

La superioridad del ResNet Tabular es consistente con su diseño: las conexiones residuales le permiten preservar representaciones de bajo nivel aprendidas en capas tempranas mientras construye abstracciones de alto orden, haciéndolo más robusto ante la brecha de distribución entre los datos sintéticos y los reales. El TabNet, pese a su mecanismo de atención interpretable, mostró la mayor dificultad para transferir los patrones aprendidos sobre datos sintéticos al dominio biológico real, evidenciando que las 20 épocas de entrenamiento fueron insuficientes para que su mecanismo de atención secuencial convergiera de manera óptima.

### 1) Análisis Comparativo Deep vs Shallow

La comparación entre el MLP Shallow entrenado con datos GAN (escenario hp-GAN) y los modelos deep arroja un resultado sorprendente: el MLP Shallow alcanza exactamente el mismo desempeño que el MLP Profundo, con 26 aciertos de 29, F1 de 0.9302 y una matriz de confusión idéntica ([[6, 3], [0, 20]]). Ambos modelos quedan a solo un paciente de distancia del mejor clasificador del proyecto (ResNet Tabular, con 27 aciertos). Este resultado tiene una implicación metodológica relevante: cuando el feature discriminante principal (*Helicobacter*) está disponible como variable de entrada, la mayor complejidad arquitectónica de los modelos profundos no se traduce en una ventaja significativa de generalización sobre datos reales. El MLP Shallow, con solo dos capas ocultas, logra capturar suficiente señal diagnóstica del dataset sintético GAN para clasificar con alta precisión los casos reales. Esto sugiere que, en este problema específico, la señal contenida en el género *Helicobacter* es lo suficientemente dominante como para que arquitecturas más simples sean competitivas.

Sin embargo, la ventaja del ResNet Tabular se mantiene: su especificidad del 77.78% frente al 66.67% del MLP Shallow implica un falso positivo menos en un conjunto de solo 29 pacientes, diferencia que en un contexto clínico real tendría impacto práctico.

### 2) Diagnóstico Global

A lo largo de todos los modelos evaluados se observa un patrón consistente: el desempeño sobre el conjunto de datos sintéticos es perfectamente alto (100% de accuracy en los modelos deep sobre el conjunto aumentado), mientras que al evaluar sobre los 29 datos reales aparecen errores concentrados exclusivamente en la Clase 0 (pacientes negativos). Este patrón es la firma característica de un sobreajuste a la distribución sintética generada por la GAN. La causa no es la memorización clásica de los datos de entrenamiento, los mecanismos de regularización (Dropout, Batch Normalization) controlaron esa forma de sobreajuste

efectivamente, sino la brecha de distribución entre el espacio sintético y el espacio biológico real. La GAN, aunque estadísticamente validada, genera perfiles del grupo negativo con menor variabilidad que la presente en los pacientes reales, lo que lleva a todos los modelos a ser más conservadores de lo necesario al clasificar negativos.

TABLA 13.

BRECHA DE DESEMPEÑO ENTRE DATASET AUMENTADO Y DATASET ORIGINAL —  
MODELOS DEEP

| Modelo            | Accurac<br>y<br>(Aum) | Accur<br>acy<br>(Orig) | Caída | F1<br>(Aum) | F1(Orig) | Caída |
|-------------------|-----------------------|------------------------|-------|-------------|----------|-------|
| ResNet<br>Tabular | 1.00                  | 0.931                  | 0.069 | 1.00        | 0.952    | 0.047 |
| MLP<br>Profundo   | 1.00                  | 0.896                  | 0.103 | 1.00        | 0.93     | 0.07  |
| TabNet            | 1.00                  | 0.827                  | 0.172 | 1.00        | 0.889    | 0.111 |

El ResNet Tabular exhibe la menor brecha de distribución (caída de 6.9% en accuracy), mientras que TabNet muestra la mayor (17.24%), lo que refuerza la conclusión de que las conexiones residuales confieren mayor robustez ante el cambio de dominio.

El ResNet Tabular se consolida como el clasificador recomendado para el problema de detección de *H. pylori* a partir de perfiles de microbioma gástrico aumentados por GAN. Ofrece el mejor equilibrio entre exactitud (93.10%), recall perfecto sobre casos positivos (100%) y la menor tasa de falsos positivos entre los modelos evaluados. Como alternativa práctica cuando la complejidad computacional sea una restricción, el MLP Shallow en el escenario HP es una opción competitiva que alcanza el mismo F1 que el MLP Profundo con una arquitectura considerablemente más simple.

## XI. CONSIDERACIONES Y PREGUNTAS ÉTICAS

El proyecto utiliza datos de microbiota humana obtenidos de estudios previamente aprobados por comités de ética y con consentimiento informado de los participantes.

Se tendrán en cuenta los siguientes aspectos:

- 1) Uso exclusivo de datos anonimizados.
- 2) No se realizará reidentificación de individuos.
- 3) Los resultados se interpretarán únicamente con fines investigativos.
- 4) El modelo desarrollado no será considerado una herramienta diagnóstica clínica sin validación externa adicional.

Asimismo, se reconoce que el tamaño muestral limitado puede afectar la generalización del modelo, por lo que cualquier conclusión deberá interpretarse dentro del contexto del dataset utilizado.

## XII. ENLACES WEB DEL CÓDIGO FUENTE Y VIDEO EXPLICATIVO

### A. Código Fuente

- 1) La carpeta donde se almacenarán los notebooks se encuentra en el siguiente enlace: [https://drive.google.com/drive/folders/1T7gSd9RB6pCJoz1JuhegMilYUAspRP2p?usp=drive\\_link](https://drive.google.com/drive/folders/1T7gSd9RB6pCJoz1JuhegMilYUAspRP2p?usp=drive_link).

- 2) El repositorio del proyecto se encuentra disponible en el siguiente enlace: <https://github.com/nmart1nez/NeuronalNetworks-Group6>. En este repositorio se puede consultar el archivo README.md, el cual describe detalladamente la estructura del proyecto, los objetivos de su desarrollo, los integrantes del equipo de trabajo y las directrices para colaborar en él.

En términos generales, el repositorio se organiza en dos carpetas principales. La primera, denominada “project”, contiene todos los



avances relacionados con el proyecto final del curso. La segunda, llamada “ClassPresentations”, almacena las distintas producciones, notebooks y material audiovisual que serán utilizados por los miembros del equipo para la preparación y desarrollo de las presentaciones realizadas a lo largo del curso.

#### B. Video Explicativo

El video explicativo correspondiente a la entrega final del proyecto puede encontrarse en el siguiente enlace: <https://youtu.be/I8qgw7s87E>.

### XIII. CONTRIBUCIÓN DE LOS MIEMBROS DEL EQUIPO

TABLA 14.

CONTRIBUCIÓN DE CADA UNO DE LOS MIEMBROS DEL EQUIPO

| Miembro del Equipo             | Rol(es)                                        | Actividades / Contribuciones                                                                                                                                                                                                                                     |
|--------------------------------|------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| David Felipe Marin Rosas       | Coordinador, Investigador, Observador, Técnico | Revisión de arquitecturas de red relevantes para el problema. Implementación y entrenamiento de la red GAN para generación de dataset aumentado. Coordinación del equipo en las actividades del proyecto. Análisis e interpretación de los resultados obtenidos. |
| Diego Esteban Morales Granados | Técnico, Experto                               | Análisis e interpretación de los resultados obtenidos.                                                                                                                                                                                                           |
| Laura Camila Girón Pinto       | Líder, Animadora, Investigadora, Técnica       | Preparación y preprocesamiento de los datos de entrada. Documentación del desarrollo y resultados del proyecto. Análisis e interpretación de los resultados obtenidos.                                                                                           |
| Nicolás Martínez López         | Coordinador, Técnico                           | Entrenamiento y Validación Arquitecturas de Red Profundas. Documentación del desarrollo y resultados del proyecto. Creación y Edición de Video.                                                                                                                  |
| Sergio Ivan Motta Doncel       | Investigador, Técnico                          | Entrenamiento y Validación Red Neuronal Superficial. Creación de Video.                                                                                                                                                                                          |

### XIV. CONCLUSIONES

El proyecto demostró que las redes neuronales profundas pueden clasificar de manera efectiva el estado de infección por *Helicobacter pylori* utilizando perfiles de microbioma gástrico. Entre los modelos evaluados, las arquitecturas profundas mostraron mejor capacidad de generalización y desempeño que los modelos superficiales, especialmente al capturar relaciones no lineales entre los taxones bacterianos. Los resultados obtenidos evidencian el potencial del aprendizaje profundo como herramienta para el análisis de datos biomédicos complejos.

El trabajo también confirmó la importancia de aplicar métodos adecuados de análisis composicional en datos de microbioma, ya que la presencia dominante de *Helicobacter pylori* puede generar interpretaciones estadísticas erróneas. Además, el uso de una red GAN permitió aumentar el tamaño del dataset y entrenar modelos más robustos, aunque persistieron diferencias entre los datos sintéticos y los reales. Esto demuestra que las técnicas de generación sintética son prometedoras, pero requieren validación cuidadosa antes de su aplicación clínica.

### XV. USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL

*El desarrollo del texto contó con el apoyo de la herramienta de inteligencia artificial ChatGPT, utilizada para asistir en la mejora de la redacción al corregir redundancias en ideas, palabras y algunos verbos. El análisis, la selección de ideas y la coherencia argumentativa del texto son responsabilidad exclusiva de los autores. Adicionalmente, se aprovechó la herramienta NotebookLM para contextualizar los temas y para el aprendizaje de los autores.*

### XVI. REFERENCIAS

- [1] Akpoigbe, K., Culpepper-Morgan, J., Nwankwo, O., & Genao, A. (2022). Predicting Gastric Intestinal Metaplasia in a High-Risk Population. *Cureus*. <https://doi.org/10.7759/cureus.31502>.
- [2] Atherton, J. C. (2006). The pathogenesis of *Helicobacter pylori*-induced gastro-duodenal diseases. *Annual Review of Pathology*, 1, 63–96. <https://doi.org/10.1146/annurev.pathol.1.110304.100125>.
- [3] Chang, W. K., VanInsberghe, D., & Kelly, L. (2020). Topological analysis reveals state transitions in human gut and marine bacterial communities. *Npj Biofilms and Microbiomes*, 6(1), 41. <https://doi.org/10.1038/s41522-020-00145-9>.
- [4] Chiu, C. Y., & Miller, S. A. (2019). Clinical metagenomics. *Nature Reviews Genetics*, 20(6), 341–355. <https://doi.org/10.1038/s41576-019-0113-7>.
- [5] Durán, C., Ciucci, S., Palladini, A., Ijaz, U. Z., Zippo, A. G., Sterbini, F. P., Masucci, L., Cammarota, G., Ianiro, G., Spul, P., Schroeder, M., Grill, S. W., Parsons, B. N., Pritchard, D. M., Posteraro, B., Sanguinetti, M., Gasbarrini, G., Gasbarrini, A., & Cannistraci, C. V. (2021). Nonlinear machine learning pattern recognition and bacteria-metabolite multilayer network analysis of perturbed gastric microbiome. *Nature Communications*, 12(1), 1926. <https://doi.org/10.1038/s41467-021-22135-x>.
- [6] Eun, C. S., Kim, B. K., Han, D. S., Kim, S. Y., Kim, K. M., Choi, B. Y., Song, K. S., Kim, Y. S., & Kim, J. F. (2014). Differences in gastric mucosal microbiota profiling in patients with chronic gastritis, intestinal metaplasia, and gastric cancer using pyrosequencing methods. *Helicobacter*, 19(6), 407–416. <https://doi.org/10.1111/hel.12145>.
- [7] Gloor, G. B., Macklaim, J. M., Pawlowsky-Glahn, V., & Egozcue, J. J. (2017b). Microbiome datasets are compositional: and this is not optional. *Frontiers in Microbiology*, 8, 2224. <https://doi.org/10.3389/fmicb.2017.02224>.
- [8] Kusters, J. G., Van Vliet, A. H. M., & Kuipers, E. J. (2006). Pathogenesis of *Helicobacter pylori* Infection. *Clinical Microbiology Reviews*, 19(3), 449–490. <https://doi.org/10.1128/CMR.00054-05>.
- [9] Klymiuk, I., Bilgiler, C., Stadlmann, A., Thannesberger, J., Kastner, M., Högenauer, C., Puspök, A., Biowski-Frotz, S., Schrutka-Kölbl, C., Thallinger, G. G., & Steininger, C. (2017). The Human Gastric Microbiome Is Predicated upon Infection with *Helicobacter pylori*. *Frontiers in Microbiology*, 8, 2508. <https://doi.org/10.3389/fmicb.2017.02508>.
- [10] La Placa, G., Covino, M., Candelli, M., Gasbarrini, A., Franceschi, F., & Merra, G. (2025). Relationship Between Human Microbiome and *Helicobacter pylori*. *Microbiology Research*, 16(1), 24. <https://doi.org/10.3390/microbiolres16010024>.
- [11] Lee, S., & Lee, I. (2024). Comprehensive assessment of machine learning methods for diagnosing gastrointestinal diseases through whole metagenome sequencing data. *Gut Microbes*, 16(1), 2375679. <https://doi.org/10.1080/19490976.2024.2375679>.
- [12] Lehr, K., Nikitina, D., Vilchez-Vargas, R., Steponaitiene, R., Thon, C., Skieceviciene, J., Schanze, D., Zenker, M., Malfertheiner, P., Kupcinskas, J., & Link, A. (2023). Microbial composition of tumorous and adjacent gastric

- tissue is associated with prognosis of gastric cancer. *Scientific Reports*, 13(1), 4640. <https://doi.org/10.1038/s41598-023-31740-3>.
- [13] Meyer, F., Fritz, A., Deng, Z.-L., Koslicki, D., Lesker, T. R., Gurevich, A., Robertson, G., Alser, M., Antipov, D., Beghini, F., Bertrand, D., Brito, J. J., Brown, C. T., Buchmann, J., Buluç, A., Chen, B., Chikhi, R., Clausen, P. T. L. C., Cristian, A., ... McHardy, A. C. (2022). Critical Assessment of Metagenome Interpretation: the second round of challenges. *Nature Methods*, 19(4), 429–440. <https://doi.org/10.1038/s41592-022-01431-4>.
  - [14] Mohamed, A. S., Bhujar, R., Martinez, E., Basta, M., Deyab, A., Mansour, C., Tejada, D., Deshpande, V., Elias, S., & Nagesh, V. K. (2025). The Gut Microbiome's Impact on the Pathogenesis and Treatment of Gastric Cancer—An Updated Literature Review. *Cancers*, 17(17), 2795. <https://doi.org/10.3390/cancers17172795>.
  - [15] Park, C. H., Lee, A., Lee, Y., Eun, C. S., Lee, S. K., & Han, D. S. (2019). Evaluation of gastric microbiome and metagenomic function in patients with intestinal metaplasia using 16S rRNA gene sequencing. *Helicobacter*, 24(1), e12547. <https://doi.org/10.1111/hel.12547>.
  - [16] Sgamato, C., Rocco, A., Compare, D., Priadko, K., Romano, M., & Nardone, G. (2024). Exploring the Link between *Helicobacter pylori*, Gastric Microbiota and Gastric Cancer. *Antibiotics*, 13(6), 484. <https://doi.org/10.3390/antibiotics13060484>.
  - [17] SICC | DANE. (n.d.). Sistema de información de cáncer de Colombia. <https://www.infocancer.co/>.
  - [18] Sung, J., Kim, N., Kim, J., Jo, H. J., Park, J. H., Nam, R. H., Seok, Y.-J., Kim, Y.-R., Lee, D. H., & Jung, H. C. (2016). Comparison of Gastric Microbiota Between Gastric Juice and Mucosa by Next Generation Sequencing Method. *Journal of Cancer Prevention*, 21(1), 60–65. <https://doi.org/10.15430/JCP.2016.21.1.60>.
  - [19] Topçuoğlu, B. D., Lesniak, N. A., Ruffin, M. T., Wiens, J., & Schloss, P. D. (2020). A framework for Effective Application of Machine Learning to Microbiome-Based Classification Problems. *mBio*, 11(3). <https://doi.org/10.1128/mbio.00434-20>.
  - [20] Wang, D., Zhang, T., Lu, Y., Wang, C., Wu, Y., Li, J., Tao, Y., Deng, L., Zhang, X., & Ma, J. (2022). *Helicobacter pylori* infection affects the human gastric microbiome, as revealed by metagenomic sequencing. *FEBS Open Bio*, 12(6), 1188–1196. <https://doi.org/10.1002/2211-5463.13390>.
  - [21] Wang, Y., Wang, Y., Han, W., Han, M., Liu, X., Dai, J., Dong, Y., Sun, T., & Xu, J. (2024). Intratumoral and fecal microbiota reveals microbial markers associated with gastric carcinogenesis. *Frontiers in Cellular and Infection Microbiology*, 14, 1397466. <https://doi.org/10.3389/fcimb.2024.1397466>.
  - [22] Weiss, S., Xu, Z. Z., Peddada, S., Amir, A., Bittinger, K., Gonzalez, A., Lozupone, C., Zaneveld, J. R., Vázquez-Baeza, Y., Birmingham, A., Hyde, E. R., & Knight, R. (2017). Normalization and microbial differential abundance strategies depend upon data characteristics. *Microbiome*, 5(1), 27. <https://doi.org/10.1186/s40168-017-0237-y>.
  - [23] Yang, I., Woltemate, S., Piazzuelo, M. B., Bravo, L. E., Yopez, M. C., Romero-Gallo, J., Delgado, A. G., Wilson, K. T., Peek, R. M., Correa, P., Josenhans, C., Fox, J. G., & Suerbaum, S. (2016). Different gastric microbiota compositions in two human populations with high and low gastric cancer risk in Colombia. *Scientific Reports*, 6(1), 18594. <https://doi.org/10.1038/srep18594>.
  - [24] Zaramella, A., Arcidiacono, D., Duci, M., Benna, C., Pucciarelli, S., Fantin, A., Rosato, A., De Re, V., Cannizzaro, R., Fassan, M., & Realdon, S. (2024). Predictive Value of a Gastric Microbiota Dysbiosis Test for Stratifying Cancer Risk in Atrophic Gastritis Patients. *Nutrients*, 17(1), 142. <https://doi.org/10.3390/nu17010142>.
  - [25] Zeng, R., Gou, H., Lau, H. C. H., & Yu, J. (2024). Stomach microbiota in gastric cancer development and clinical implications. *Gut*, 73(12), 2062–2073. <https://doi.org/10.1136/gutjnl-2024-332815>.
  - [26] Zhao, H., Zhang, S., Qin, H., Liu, X., Ma, D., Han, X., Mao, J., & Liu, S. (2024). DSNtax: a deep learning species annotation method based on a deep-shallow parallel framework. *Briefings in Bioinformatics*, 25(3), bbae157. <https://doi.org/10.1093/bib/bbae157>.
  - [27] Greenacre, M., Martínez-Álvarez, M., & Blasco, A. (2021). Compositional data analysis of microbiome and any-omics datasets: A validation of the additive, logratio transformation. *Frontiers in Microbiology*, 12, 727398. <https://doi.org/10.3389/fmicb.2021.727398>.
  - [28] Walsh, C., Stallard-Olivera, E., & Fierer, N. (2024). Nine (not so simple) steps: A practical guide to using machine learning in microbial ecology. *mBio*, 15(2), e02050-23. <https://doi.org/10.1128/mbio.02050-23>.
  - [29] Aitchison, J. (1986). *The Statistical Analysis of Compositional Data*. Chapman and Hall.
  - [30] McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv:1802.03426*.
  - [31] Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
  - [32] Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *Annals of Mathematical Statistics*, 18(1), 50–60.