

Clasificación De Helicobacter Pylori Mediante Redes Neuronales Superficiales (Marzo 2026)

David F. Marin Rosas, Diego E. Morales Granados, Laura C. Girón Pinto, Nicolás Martínez López, Sergio I. Motta Doncel., Facultad de Ingeniería, Universidad Nacional de Colombia

Abstract—This work evaluates shallow neural network approaches for the classification of *Helicobacter pylori* infection using gastric microbiome data. Given the limited dataset, multiple strategies were explored, including a baseline Multilayer Perceptron (MLP), an autoencoder-based model, and generative approaches such as AC-GAN and VAE-GAN. The MLP achieved strong classification performance but showed dependence on dominant features. The autoencoder improved feature representation with limited generalization. In contrast, generative models captured the underlying structure of the data and enabled effective data augmentation, with AC-GAN showing high predictive validity in synthetic-to-real evaluation. These results suggest that, in small datasets, generative approaches can better support robust modeling compared to direct classification methods.

Index Terms—Shallow Neural Networks, MLP, Autoencoder, GAN, AC-GAN, VAE-GAN, Microbiome, *Helicobacter pylori*, Data Augmentation, Classification.

I. INTRODUCCIÓN

La infección por *Helicobacter pylori* constituye un factor de riesgo importante en el desarrollo de diversas enfermedades gastrointestinales, como la gastritis, la úlcera péptica y el cáncer gástrico. Su presencia no solo implica la colonización de la mucosa gástrica, sino también alteraciones en la estructura y composición de la microbiota asociada, lo que ha llevado a considerar estos cambios como posibles indicadores del estado de infección. El análisis de este tipo de sistemas representa un desafío, ya que las interacciones entre sus componentes suelen ser no lineales y difíciles de capturar mediante enfoques tradicionales.

El presente acercamiento propone abordar el problema de clasificación del estado de infección por *Helicobacter pylori* mediante el uso de redes neuronales superficiales. Este tipo de modelos permite explorar relaciones no lineales y capturar estructuras relevantes, ofreciendo una alternativa computacional para el análisis de sistemas biológicos complejos. De esta manera, se busca evaluar su potencial en la identificación de patrones asociados al estado de infección y aportar una perspectiva complementaria a los métodos convencionales.

II. OBJETIVO Y ALCANCE DEL PROYECTO

El objetivo del presente proyecto es evaluar si los modelos de aprendizaje automático no lineales, incluyendo redes neuronales multicapa, aportan un valor predictivo e interpretativo adicional frente a métodos estadísticos clásicos en la clasificación de la infección por *Helicobacter pylori* utilizando datos de microbiota gástrica obtenidos mediante secuenciación 16S rRNA de biopsias humanas.

El proyecto se centrará exclusivamente en microbiota gástrica en humanos adultos, comparando individuos infectados contra no infectados. Se realizará integración de datos provenientes de múltiples cohortes públicas, procesamiento uniforme de datos de secuenciación para evitar batch effect, modelado supervisado y análisis de interpretabilidad. No se pretende establecer causalidad ni

mecanismos funcionales profundos, sino evaluar capacidad predictiva y estructura microbiana asociada al estado de infección.

III. REVISIÓN DE LITERATURA

A. Definiciones Básicas

- 1) *Helicobacter pylori*: bacteria gramnegativa microaerófila que coloniza la mucosa gástrica y se asocia con gastritis, úlcera péptica y cáncer gástrico.
- 2) Microbiota gástrica: Comunidad microbiana residente en la mucosa del estómago.
- 3) Perfil taxonómico: Identificación y cuantificación de especies, géneros o distintos taxones presentes en una muestra para determinar la composición y abundancia relativa de una muestra de microbiota.
- 4) Abundancia relativa: Proporción de un taxón o especie respecto al número total de taxones o especies en un área definida.
- 5) Secuenciación 16S rRNA: Técnica de secuenciación de regiones variables del gen 16S para caracterización taxonómica bacteriana.
- 6) Datos composicionales: Datos donde las abundancias son proporciones relativas y requieren transformaciones adecuadas (ej. CLR).

B. Revisión

El cáncer gástrico constituye una de las principales causas de mortalidad por cáncer a nivel mundial, con alta carga global y local (Zeng et al., 2024; SICC, DANE). Una de las mayores causas de la muerte por esta enfermedad es la detección tardía, cuando el cáncer se encuentra en sus etapas más avanzadas (Mohamed et al., 2025; Zeng et al., 2024). Su etiología es altamente heterogénea, lo que ha dificultado el desarrollo de metodologías de diagnóstico y tratamiento tempranos (Atherton, 2006; Wang et al., 2024). Adicionalmente, uno de los factores de mayor efecto en el inicio de este tipo de cáncer es la infección por *Helicobacter pylori*, bacteria gramnegativa microaerófila que coloniza la mucosa gástrica y cuya prevalencia global se estima cercana al 50% de la población. La infección crónica se asocia con inflamación persistente, alteraciones en la secreción ácida y modificaciones del microambiente gástrico y alrededor del 3% de la población puede llegar a desarrollar cáncer gástrico, aunque la prevalencia y el riesgo asociado varían según la región geográfica, la edad y la cepa adquirida (La Placa et al., 2025; Zeng et al., 2024).

El papel de este microorganismo en el desarrollo del cáncer no está establecido con claridad, pero se considera que la alteración de su comportamiento en el nicho actúa como disparador de la disbiosis, la inflamación y los cambios en el pH gástrico que permiten la colonización del estómago por microbiota oral e intestinal (Kusters et al., 2006; Zeng et al., 2024). Se han descrito cambios en diversidad, desplazamientos en la composición taxonómica y variaciones en comunidades no-*H. pylori*, lo que sugiere que la infección no solo implica la presencia del patógeno, sino una reorganización del ecosistema microbiano local (Eun et al., 2014; Park et al., 2019; Wang et al., 2024; Yang et al., 2016). Adicionalmente, se ha determinado que pacientes con ciertas abundancias de taxones orales específicos presentan una menor supervivencia al cáncer gástrico en comparación con otros (Lehr et al., 2023), lo que refuerza la idea de que la composición microbiana asociada al estado de infección podría

tener implicaciones clínicas más amplias. Por otra parte, la actividad metabólica de estas comunidades tras la disbiosis se ha convertido en un foco central de estudio por su vínculo con la transición hacia lesiones precancerosas y tumor. Estos hallazgos en conjunto sugieren que la infección por *H. pylori* deja una huella microbiana característica que potencialmente podría ser detectada como un patrón de clasificación, lo que abriría la posibilidad de desarrollar herramientas diagnósticas no invasivas basadas en la composición del microbioma gástrico (Durán et al., 2021; Topçuoğlu et al., 2020).

Sin embargo, los resultados entre estudios muestran heterogeneidad considerable, atribuida en parte a diferencias en el sitio de muestreo (antro, cuerpo gástrico), tipo de muestra (biopsia, jugo gástrico), baja biomasa bacteriana y posibles problemas de contaminación (Sgamato et al., 2024; Sung et al., 2016; Zaramella et al., 2024; Zeng et al., 2024). Adicional a estas fuentes de variabilidad, existen limitaciones metodológicas relacionadas con el modo en que se generan y representan computacionalmente los datos de microbiota.

En estudios basados en secuenciación 16S rRNA, la comunidad microbiana se cuantifica mediante matrices de conteo de variantes de secuencia o taxones generadas a partir de pipelines bioinformáticos, que suelen luego transformarse en abundancias relativas para su análisis comparativo (Chiu y Miller, 2019). Sin embargo, estas abundancias no representan cantidades absolutas de microorganismos, sino proporciones dentro de cada muestra, por lo que están restringidas por una suma constante. Esto implica que un incremento relativo en un taxón necesariamente conlleva una disminución proporcional en otros, incluso si sus cantidades reales no han variado. Debido a esto, los datos derivados de 16S constituyen datos composicionales, cuya estructura puede generar asociaciones artificiales cuando se aplican métodos estadísticos convencionales directamente sobre proporciones. Por ello, se recomienda el uso de transformaciones log-ratio que permitan analizar los datos en un espacio adecuado para inferencia estadística y modelado predictivo (Gloor et al., 2017; Weiss et al., 2017).

Esta representación numérica permite modelar cada muestra como un vector en un espacio multivariado, sobre el cual pueden aplicarse técnicas estadísticas y de aprendizaje automático. Este enfoque, sin embargo, ha mostrado dificultades de reproducibilidad entre cohortes y contextos clínicos, posiblemente debido a la naturaleza composicional de los datos (Gloor et al., 2017), la alta variabilidad interindividual, el efecto dominante de *H. pylori* en individuos infectados, que puede alterar de manera desproporcionada la estructura relativa de la comunidad (Meyer et al., 2022; Lee & Lee, 2024; Wang et al., 2024). Adicionalmente, no existe consenso sobre si las variables más informativas para caracterizar el estado de infección corresponden exclusivamente a abundancias taxonómicas o si patrones de interacción entre microorganismos y características funcionales del ecosistema aportan mayor estabilidad y capacidad predictiva (Zeng et al., 2024).

En este contexto, los enfoques de aprendizaje automático han comenzado a utilizarse para explorar patrones complejos en datos de microbioma, dado que en sistemas ecológicos como el microbioma gástrico las relaciones entre microorganismos pueden ser no lineales y depender de combinaciones multivariadas de abundancias que los métodos estadísticos tradicionales no logran capturar (Chang et al., 2020; Akpoigbe et al., 2022; Zhao et al., 2024). Durán y colaboradores (2021) ha demostrado que la comparación de técnicas lineales y no lineales en datos de microbioma gástrico de pacientes *H. pylori* positivos y negativos permite revelar estructuras de agrupamiento que los métodos lineales no detectan, lo que respalda la pertinencia de este tipo de análisis. Sin embargo, su aplicación en la clasificación del estado de infección por *H. pylori* utilizando microbiota gástrica humana aún es limitada y requiere evaluación rigurosa en términos de reproducibilidad, control de sesgos técnicos y comparación sistemática frente a modelos lineales clásicos. De

manera complementaria, en función de la disponibilidad de información en los conjuntos de datos seleccionados, el análisis podría extenderse en dos direcciones adicionales. Por un lado, la variabilidad en la virulencia de *H. pylori*, determinada por factores como los genotipos *cagA* y *vacA*, podría modular el impacto de la bacteria sobre la comunidad microbiana gástrica, por lo que su integración permitiría explorar si existen diferencias microbianas asociadas no solo al estado de infección, sino también al perfil de virulencia del patógeno (La Placa et al., 2025; Zeng et al., 2024). Por otro lado, dado que la composición microbiana asociada a la infección y distintas cepas de *H. pylori* han mostrado vínculos con la supervivencia al cáncer gástrico (Lehr et al., 2023), podría explorarse si los patrones clasificatorios identificados guardan relación con desenlaces clínicos relevantes.

IV. CASO DE ESTUDIO

Durán et al., 2021 (PMID: 33771992). El presente artículo analiza datos de microbioma gástrico en pacientes infectados y no infectados por *Helicobacter pylori*, comparando enfoques analíticos lineales y no lineales para explorar las diferencias estructurales entre los dos escenarios en la comunidad microbiana. Estos autores observan que los enfoques no lineales revelan estructuras no reveladas por otros métodos, pero no evalúan formalmente la capacidad predictiva de dichos patrones. El presente proyecto busca extender este avance mediante la implementación y evaluación comparativa de modelos de aprendizaje automático de redes profundas para caracterizar la microbiota antes y después de la infección con *H. pylori*.

Klymkiuk et al., 2017. En este paper se generaron datos de microbiota gástrica obtenida mediante secuenciación 16S rRNA en biopsias humanas, incluyendo individuos infectados y no infectados por *Helicobacter pylori*, con información adicional sobre el estado de virulencia (*CagA*). El estudio caracteriza diferencias en la composición microbiana asociadas al estado de infección, pero no implementa modelos supervisados para evaluar capacidad predictiva. El presente proyecto utilizará este conjunto de datos como base experimental para formular una tarea de clasificación binaria (infectado contra no infectado) y evaluar si los patrones multivariados de la comunidad microbiana permiten discriminar el estado de infección mediante modelos de aprendizaje automático.

V. CONJUNTO DE DATOS DE ENTRENAMIENTO

El dataset de entrenamiento a utilizar proviene del paper de Klymkiuk y colaboradores (2017), recopilado en la base de datos Sequence Read Archive (SRA) con el código de acceso PRJEB22107. Este cuenta con información de 29 pacientes dentro de tres categorías: no infectados con *H. pylori* (*H.p.*-), infectado con *H. pylori* sin el factor de virulencia *CagA* (*H.p.*+/*CagA*-) e infectado con *H. pylori* con el factor de virulencia *CagA* (*H.p.*+/*CagA*+). Para cada uno de los casos se cuenta con 10 muestras, entre pacientes masculinos y femeninos con una media de edad de aproximadamente 50 años. Estas muestras fueron sometidas a procesamiento por pirosecuenciación 16S rRNA y análisis metagenómico, por lo que se obtienen valores de abundancia de distintos phylum, clases, órdenes, familias y especies bacterianas encontradas en el lumen de los distintos individuos.

El conjunto de datos está estructurado como una matriz de abundancia taxonómica en la que cada una de las muestras corresponde a un vector numérico de características, representando la abundancia relativa de los distintos taxones identificados. El número de características dependerá del nivel taxonómico seleccionado (phylum, clase, orden, familia o género), con el fin de reducir la dimensionalidad y mejorar la estabilidad del modelo dada la relación entre número de muestras y número de variables. Por otro lado, las abundancias mencionadas se utilizarán como variables de entrada para el modelo y la variable objetivo corresponderá al estado de

infección por *Helicobacter pylori*, inicialmente formulado como un problema de clasificación binaria (H.p.+ contra H.p.-). Se explorará además la posibilidad de discriminar entre subgrupos según el estado de virulencia (CagA+ vs CagA-), sujeto a estabilidad estadística del modelo.

El dataset presenta un balance casi equitativo entre categorías, lo cual favorece la evaluación comparativa de modelos supervisados mediante validación cruzada estratificada, pero puede verse limitado para la implementación de arquitecturas complejas debido a su tamaño muestral. Para lidiar con ello, se emplearán estrategias de regularización y validación repetida para minimizar el riesgo de sobreajuste. Adicional a esto, dado que los datos de microbiota son composicionales, se aplicarán transformaciones log-ratio apropiadas antes del entrenamiento de los modelos para asegurar una representación adecuada en el espacio multivariado.

VI. PREPROCESAMIENTO Y ANÁLISIS EXPLORATORIO DE LOS DATOS

Como se mencionó previamente, las abundancias derivadas de secuenciación 16S rRNA son proporciones relativas restringidas a sumar una constante, lo que exige transformaciones específicas antes de cualquier análisis estadístico o entrenamiento de modelos (Gloor et al., 2017). En el presente trabajo se implementaron dos variantes del enfoque log-ratio para abordar esta restricción: la Centered Log-Ratio (CLR) y su versión robusta (rCLR), complementadas por el análisis de distancias de Aitchison.

A. Transformación CLR.

La transformación CLR (Gloor et al., 2017; Aitchison, 1986) mapea cada composición desde el simplex S^{D-1} al espacio euclidiano RD expresando la abundancia de cada taxón relativa a la media geométrica de la muestra:

$$\text{clr}(x)_i = \log(x_i + \delta) - (1/D) \cdot \sum \log(x_j + \delta)$$

donde D es el número de géneros y $\delta = 0.5/11\,200 \approx 4.46 \times 10^{-5}$ es un pseudoconteo que desplaza los ceros para evitar $\log(0)$, escalado a la unidad de abundancia relativa definida por la rarefacción a 11 200 lecturas. Tras la transformación, cada fila de la matriz suma exactamente cero (desviación máxima observada: 4.21×10^{-12}), verificando la propiedad de suma cero que garantiza la correcta implementación del algoritmo. Las propiedades fundamentales de CLR son: (i) invariancia de escala: produce los mismos valores sobre conteos crudos o abundancias relativas; (ii) equivalencia con la distancia de Aitchison: la distancia euclidiana en espacio CLR es igual a la distancia de Aitchison en el simplex; y (iii) equivalencia con el Logratio Analysis (LRA): la PCA sobre la matriz CLR es algebraicamente equivalente al análisis de todos los log-ratios por pares entre géneros.

La propiedad de suma cero implica que la matriz CLR tiene rango $D - 1$: la restricción composicional consume un grado de libertad, por lo que el número de componentes principales no redundantes es como máximo $\min(n - 1, D - 1) = 28$ para este conjunto de datos. Esto se refleja en la configuración del algoritmo PCA, cuyo parámetro $n_components$ se establece como $\min(n - 1, D - 1)$ y no como D.

B. Transformación rCLR.

C. Distancia de Aitchison y PCA como LRA.

D. UMAP.

El análisis exploratorio se implementó en dos versiones paralelas: una que incorpora *Helicobacter* en la tabla OTU y otra que lo elimina antes de cualquier transformación. Esta decisión responde a una consecuencia directa de la naturaleza composicional de los datos: Cuando un taxón domina la composición de un grupo de muestras, como ocurre con *Helicobacter* en muestras H.p.+ (80-90% de lecturas), la restricción de suma constante fuerza que todas las demás abundancias relativas sean pequeñas, independientemente de si los taxones correspondientes cambiaron biológicamente o no. Tras la

transformación CLR, este efecto se traduce en que la media geométrica de la muestra queda deprimida por la presencia de ~130 géneros a nivel de pseudoconteo, lo que infla el valor CLR de *Helicobacter* (+9.73 en el análisis con *H. pylori*) y simultáneamente empuja hacia valores negativos los CLR de prácticamente todos los demás géneros en muestras H.p.+ Gloor y colaboradores (2017), formalizaron este mecanismo: un incremento en un componente genera señales de depleción artefactuales en todos los demás debido a la restricción de suma constante. El resultado observado es que un test estadístico de abundancia diferencial entre grupos detecta diferencias aparentes en el 72.5% de los géneros (132/182), un valor biológicamente inverosímil que refleja el artefacto y no reorganización real del microbioma.

Eliminar *Helicobacter* de la tabla OTU sin renormalizar produce sumas de fila de 0.02–0.20 en muestras H.p.+ , lo que viola la definición de datos composicionales y hace que las abundancias restantes representen fracciones del total original en lugar de proporciones de la comunidad no-*Helicobacter*. La renormalización es por tanto obligatoria:

$$x'_{i,\square} = x_{i,\square} / \sum x_{i,\square} \quad (k \neq \text{Helicobacter})$$

donde la suma en el denominador recorre todos los géneros excepto *Helicobacter*. Tras este paso, todas las sumas de fila son exactamente 1.0, y la CLR calculada sobre la tabla renormalizada tiene la interpretación correcta: *log-ratio* de cada género respecto a la media geométrica de la comunidad no-*Helicobacter*. Las sumas de fila del análisis sin renormalización en el análisis con *H. pylori* oscilan entre 0.9986 y 1.0000, diferencia que refleja taxones de la tabla original no capturados en el pivoteo y que es irrelevante para el análisis dado que el assert de control pasa en todos los casos.

Los cambios en las métricas clave entre ambos análisis cuantifican directamente el tamaño del artefacto de supresión (Tabla 1). La reducción del máximo CLR de +9.73 a +8.22 es la huella directa de que la eliminación de *Helicobacter* eleva la media geométrica de referencia de cada muestra H.p.+ , comprimiendo todos los valores CLR hacia cero. De forma análoga, la caída de PC1 del 31.3% al 21.0% cuantifica que aproximadamente 10 puntos porcentuales de la varianza total del dataset están asociados exclusivamente a la presencia o ausencia de *Helicobacter*, no a ninguna estructura del resto de la comunidad. Finalmente, la disminución de géneros significativos de 132 a 19 indica que el 89.5% del microbioma restante exhibía diferencias estadísticas artefactuales inducidas por la dominancia del patógeno.

TABLA 1.
COMPARACIÓN DE MÉTRICAS CLAVE ENTRE EL ANÁLISIS CON Y SIN
HELICOBACTER PYLORI.

Métrica	Con <i>H. pylori</i>	Sin <i>H. pylori</i>
Géneros en tabla OTU	182	181
Género tras filtro $\geq 30\%$	60	59
Sparcidad	72.4%	72.8%
Rango CLR	-1.51 a +9.73	-1.66 a +8.22
Rango rCLR	-4.16 a +8.76	-4.18 a +6.47
PC1 varianza explicada	31.3%	21.0%
PC2 varianza explicada	17.6%	8.8%
Géneros significativos ($p < 0.05$)	132/182 (72.5%)	19/181 (10.5%)

La reducción en el rango CLR, la varianza explicada por PCA y el número de géneros significativos cuantifica el artefacto de supresión composicional generado por la dominancia de *Helicobacter* en muestras positivas.

Walsh y colaboradores (2024), establecen que conocer los datos antes de modelar es un paso crítico e ineludible, y el set de datos se explica en Figura 1. El panel A verifica que las sumas de abundancias

por muestra son ≈ 1.0 , confirmando que el pivoteo de la tabla OTU no eliminó taxones silenciosamente. El panel B muestra el balance de clases: 9 muestras H.p.- frente a 20 H.p.+ , una ratio de 1:2.2. Este desequilibrio implica que la exactitud global no es una métrica de evaluación adecuada para los modelos de clasificación, y que deben reportarse por separado la precisión y el recall de cada clase, o métricas integradas como el F1-score o el área bajo la curva ROC. El panel C desglosa los subgrupos CagA dentro de H.p.+ (10 CagA- y 10 CagA+) de forma informativa: aunque ambos subgrupos se colapsan en una sola categoría H.p.+ para el clasificador binario, su distribución en las proyecciones de ordenación permite evaluar si los métodos de reducción dimensional los separan, lo que indicaría que el estado CagA también estructura la comunidad microbiana. Por otra parte, el análisis de los 20 géneros de mayor abundancia media revela la asimetría central del dataset (Figura 2): en el análisis con *H. pylori*, *Helicobacter* representa en promedio $\approx 56\%$ de las lecturas totales, más que todos los demás géneros combinados. En el análisis sin *H. pylori*, los géneros dominantes son *Streptococcus*, *Prevotella* y *Actinomyces*, todos con abundancias medias inferiores al 10%. Esta visualización establece cuantitativamente por qué cualquier modelo entrenado sobre la comunidad completa tenderá a clasificar el estado de infección detectando la presencia de *Helicobacter* directamente, sin necesidad de capturar patrones de la comunidad residual (Durán et al., 2021).




Figura 1. Descripción general del conjunto de datos. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

Los gráficos de violín sobre abundancias sin transformar (Figura 3), por otro lado, muestran, para los 10 géneros más abundantes, la distribución por grupo binario (H.p.- vs H.p.+). En el análisis con *H. pylori*, todos los géneros distintos de *Helicobacter* presentan violines H.p.+ comprimidos hacia cero: sus distribuciones en muestras infectadas son más estrechas y con mediana más baja que en muestras no infectadas. Esta compresión no es biológica sino matemática, consecuencia directa de que *Helicobacter* consume el presupuesto de lecturas en muestras H.p.+ 1. En el análisis sin *H. pylori* y tras renormalización, los mismos géneros muestran distribuciones más amplias en muestras H.p.+ , revelando su varianza real una vez liberados de la compresión composicional. Estas distribuciones asimétricas en datos crudos también ilustran por qué las abundancias no transformadas no deben emplearse directamente como variables de entrada en modelos estadísticos o de aprendizaje automático. En cuanto a la composición por *phylum* (Figura 4), en el análisis con *H. pylori*, las muestras H.p.+ están dominadas visualmente por Proteobacteria (el *phylum* que contiene *Helicobacter*) con valores entre 80% y 98%, mientras que las muestras H.p.- exhiben una mezcla de Firmicutes, Bacteroidetes y Actinobacteria. En el análisis sin *H. pylori* y tras renormalización, todos los grupos muestran una composición más heterogénea y la separación visual entre H.p.- y H.p.+ se reduce considerablemente,

confirmando que la distinción a nivel de *phylum* en el análisis completo era prácticamente en su totalidad consecuencia de un único género dentro de Proteobacteria.




Figura 2. Géneros principales acorde a su abundancia relativa media. Se señala la abundancia relativa media de *Helicobacter pylori* considerando las 29 muestras conjuntamente. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.





Figura 3. Distribuciones de abundancia relativa cruda (top 10 géneros). En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.






Figura 4. Composición a nivel de *phylum*. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.




Figura 5. Prevalencia de géneros y filtrado. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

La prevalencia de cada género (fracción de muestras en la que es detectado) determina qué características se incluyen en el modelo. La mayoría de los 182 géneros son detectados en menos del 20% de las muestras (Figura 5), correspondiendo en gran medida a taxones cuya presencia en el dataset puede atribuirse a variabilidad de muestreo más que a diferencias biológicas reproducibles (Walsh et al., 2024). Se aplicó un umbral de prevalencia del 30%, que en este contexto equivale a aproximadamente 9 muestras. Este umbral es deliberadamente más bajo que el 50% habitual: con $n = 29$, un umbral más estricto descartaría géneros biológicamente relevantes que simplemente son menos frecuentes en esta cohorte. Tras el filtrado se retienen 60 géneros en el análisis con *H. pylori* y 59 en el análisis sin *H. pylori*, una dimensionalidad manejable que reduce el riesgo de sobreajuste en los modelos supervivientes.

Para el control de calidad de las transformaciones composicionales se evalúan las abundancias crudas y tras ser transformadas (Figura 6). El panel de abundancias crudas muestra una distribución fuertemente asimétrica a la derecha, característica de datos de microbioma, que viola los supuestos de los métodos paramétricos estándar. Tras la transformación CLR, la distribución se aproxima a una campana simétrica centrada en cero, reflejando la propiedad de suma cero por fila 1. La comparación entre análisis con y sin *H. pylori* es directamente diagnóstica: la reducción del máximo CLR de +9.73 a +8.22, y del máximo rCLR de +8.76 a +6.47, evidencia que la eliminación de *Helicobacter* eleva la media geométrica de referencia de las muestras H.p.+, comprimiendo todos los valores hacia cero y produciendo una distribución más equilibrada. Para rCLR, el panel incluye únicamente los valores no nulos (72.4% de ceros se preservan), mostrando un rango más extremo en el mínimo que CLR por la razón descrita, donde la referencia geométrica es más alta al calcularse sólo sobre géneros detectados.




Figura 6. Distribuciones de valores transformados: Crudo, CLR y rCLR. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

El heatmap visualiza los valores CLR de los 40 géneros con mayor varianza entre muestras (la medida correcta de variabilidad para datos composicionales) (Gloor et al., 2017), con muestras ordenadas H.p.- | H.p.+ y la paleta rojo-blanco-azul indicando enriquecimiento (CLR > 0), neutralidad (CLR ≈ 0) y depleción (CLR < 0) respecto a la media geométrica de cada muestra (Figura 7). La escala utiliza los percentiles 2-98 para evitar el colapso de la paleta por valores extremos. En el análisis con *H. pylori*, para muestras H.p.+, se observa una columna de rojo intenso para *Helicobacter* rodeada de valores negativos (azul) para prácticamente todos los demás géneros. Este patrón es la visualización directa de la restricción de suma cero: el enriquecimiento extremo de *Helicobacter* fuerza valores CLR negativos en toda la comunidad residual (Gloor et al., 2017). En el análisis sin *H. pylori*, el patrón es cualitativamente distinto, ya que ninguna columna domina y los diferentes géneros muestran patrones heterogéneos entre muestras H.p.+, revelando la variación real de la comunidad no-*Helicobacter*.




Figura 7. Heatmap CLR: Cuarenta géneros de mayor abundancia. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.




Figura 8. Test de Mann-Whitney U para abundancia CLR. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

Para los 6 géneros de mayor varianza CLR, se presentan distribuciones por grupo junto con el resultado del test de Mann-Whitney U (MWU) (Mann y Whitney, 1947) para la comparación binaria H.p.- vs H.p.+ (Figura 8). El MWU es no paramétrico y no supone normalidad, características apropiadas para $n = 9$ vs $n = 20$. En el análisis con *H. pylori*, el género de mayor varianza es *Helicobacter* con separación casi perfecta entre grupos. En el análisis sin *H. pylori*, el top-6 corresponde a géneros biológicamente más diversos, con distribuciones más superpuestas entre grupos y p-valores nominales menos extremos. Es indispensable subrayar que todos los p-valores reportados en esta figura son nominales y no corregidos por comparaciones múltiples. Con 182 géneros a $\alpha = 0.05$, aproximadamente 9 géneros serían significativos por azar en ausencia de cualquier efecto real (Benjamini y Hochberg, 1995). Estos resultados deben interpretarse exclusivamente como hipótesis candidatas para análisis confirmatorios, no como evidencia de diferencias biológicas reales.

Por otro lado, la PCA sobre la matriz CLR constituye el Logratio Analysis (LRA) de la comunidad microbiana (Greenacre et al., 2021) (Figura 9). El panel de scree plot documenta la varianza acumulada en función del número de componentes, mientras que el scatter PC1 vs PC2 visualiza la separación entre grupos, tanto con etiquetas binarias como con el desglose CagA. En el análisis con *H. pylori*, PC1 explica el 31.3% y PC2 el 17.6% de la varianza total, con los dos primeros componentes capturando el 48.9%. Esta concentración inusual de varianza en dos dimensiones refleja que PC1 es esencialmente un eje de abundancia de *Helicobacter*, y la separación H.p.-/H.p.+ a lo largo de este eje es casi perfecta. En el análisis sin *H. pylori*, PC1 cae al 21.0% y PC2 al 8.8%, con los dos primeros componentes explicando el 29.8% de la varianza. La varianza ya no está concentrada en un único driver: está distribuida entre múltiples géneros y la separación entre grupos es considerablemente más débil, con mayor solapamiento entre H.p.- y H.p.+. Este resultado es coherente con Durán et al. (2021), quienes observaron que la comunidad no-*Helicobacter* no se estructura de forma simple en el espacio PCA para este conjunto de datos.

Esta figura se clasifica como exploratoria en el contexto del pipeline de aprendizaje automático. Walsh et al. (2024) establecen que cualquier transformación que utilice información de todas las muestras, incluyendo PCA, debe ajustarse exclusivamente sobre los datos de entrenamiento de cada fold de validación cruzada y aplicarse sin reajuste sobre los datos de validación. La PCA presentada aquí usa las 29 muestras conjuntamente y sirve para orientar el análisis descriptivo, no como paso de preprocesamiento directamente trasladable al modelo.

Es importante tener en cuenta también el análisis UMAP, que complementa el análisis lineal de PCA al preservar la estructura local de la variedad de los datos (McInnes et al., 2018) (Figura 10). Se usa distancia euclidiana en espacio CLR (equivalente a la distancia de Aitchison) como métrica. En el análisis con *H. pylori*, la separación entre grupos en la proyección 2D es prácticamente completa. En el análisis sin *H. pylori*, la separación es más débil y con mayor solapamiento, aunque UMAP tiende a revelar algo de estructura que PCA no captura, consistente con los hallazgos de Durán et al. (2021). La interpretación de estas proyecciones es exclusivamente cualitativa y exploratoria dada la inestabilidad inherente de UMAP con $n = 29$: no deben cuantificarse distancias ni inferirse estructuras de cluster a partir de una única proyección con una semilla fija.




Figura 9. Análisis de componentes principales - Análisis log-ratio. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.




Figura 10. Proyección UMAP. A la izquierda, el conjunto de datos incluyendo *H. pylori*. A la derecha, el conjunto de datos excluyéndola.




Figura 11. Matriz de distancias de Aitchison. A la izquierda, el conjunto de datos incluyendo *H. pylori*. A la derecha, el conjunto de datos excluyéndola.




Figura 12. Abundancia diferencial en espacio CLR. A la izquierda, el conjunto de datos incluyendo *H. pylori*. A la derecha, el conjunto de datos excluyéndola.

La matriz 29×29 de distancias de Aitchison (calculadas como distancia euclidiana en espacio CLR) (Figura 11) se visualiza como imagen con la paleta viridis, ordenando filas y columnas por grupo H.p.-/H.p.+. En el análisis con *H. pylori*, el bloque diagonal H.p.+ es oscuro (muestras H.p.+ son composicionalmente similares entre sí) porque la dominancia de *Helicobacter* homogeniza la composición de todas las muestras infectadas. En el análisis sin *H. pylori*, el bloque H.p.+ es más heterogéneo, ya que la comunidad no-*Helicobacter* varía sustancialmente entre muestras infectadas, reflejando diferencias individuales en la respuesta del huésped o el estadio de la infección. Esta visualización establece que la similitud aparente entre muestras H.p.+ en el análisis completo es un producto de la homogeneización por *Helicobacter*, no de una comunidad residual uniforme. Finalmente, el volcánplot grafica, para cada género, la diferencia media de CLR entre H.p.+ y H.p.- frente a $-\log_{10}$ (p-valor nominal MWU) (Figura 12). El contraste entre análisis es el resultado más informativo de todo el EDA, ya que muestra 132/182 géneros (72.5%) significativos en el análisis con *H. pylori* frente a 19/181 géneros (10.5%) en el análisis sin *H. pylori*. El mecanismo ya descrito, la dominancia de *Helicobacter* fuerza valores CLR negativos sistemáticamente en toda la comunidad H.p.+, explica por qué el 72.5% es una firma del artefacto composicional y no de biología real (Gloor et al., 2017). Los 19 géneros del análisis sin *H. pylori* representan las hipótesis candidatas más plausibles de reorganización microbiana genuinamente asociada a la infección. Incluso en este caso, con 181 tests a $\alpha = 0.05$ se esperan aproximadamente 9 falsos positivos por azar 9, por lo que estos resultados tienen carácter exclusivamente exploratorio y requieren validación en cohortes independientes de mayor tamaño.




Figura 13. Resumen de selección de características. En la parte superior, el conjunto de datos incluyendo *H. pylori*. En la inferior, el conjunto de datos excluyéndola.

La ingeniería de características se visualiza en la Figura 13, donde el panel A muestra la varianza CLR de todos los géneros en orden descendente con el corte de prevalencia marcado, evidenciando que los géneros eliminados tienen varianza CLR marginal y contribuirían más ruido que señal al modelo. El panel B presenta la matriz de correlación de Pearson entre los 30 géneros de mayor varianza CLR, donde la presencia de bloques de correlación positiva refleja co-ocurrencia ecológica y, en parte, la restricción composicional

residual; géneros altamente correlacionados son potencialmente redundantes como características independientes. El panel C muestra una PCA sobre la tabla CLR filtrada por prevalencia, confirmando que la estructura de grupos se mantiene tras el filtrado.

VII. APROXIMACIÓN DE REDES NEURONALES SUPERFICIALES PROPUESTA

El enfoque basado en redes neuronales superficiales se abordó mediante la implementación de distintas arquitecturas orientadas al mismo problema de clasificación. La idea principal fue explorar cómo diferentes configuraciones de modelos, tanto superficiales como híbridos, permiten representar los datos y contribuir a la detección de *Helicobacter pylori*.

Para ello, se partió de un proceso común de preparación de datos que incluyó la exploración, limpieza y construcción de los vectores de entrada. En esta etapa se realizaron transformaciones sobre las variables para adecuarlas al modelo, tales como la normalización o estandarización de variables numéricas y la codificación de variables categóricas. Además, se consideraron criterios de selección de características con el fin de reducir la redundancia y mejorar la calidad de la información suministrada a los modelos.

Sobre esta base, se desarrollaron varios enfoques: una red neuronal superficial para clasificación binaria, una red generativa adversaria (GAN, Generative Adversarial Network) con arquitectura simplificada, un modelo basado en autoencoder (codificador-decodificador) combinado con un clasificador, y una arquitectura híbrida VAE-GAN (Variational Autoencoder – Generative Adversarial Network), que integra un autoencoder variacional con un esquema adversario.

Estas implementaciones permiten comparar el desempeño de diferentes estrategias de aprendizaje dentro de un mismo contexto experimental.

A. Red Neuronal Superficial Para Clasificación Binaria

Enfoque propuesto para la clasificación de *Helicobacter pylori* utilizando una red neuronal superficial tipo Multilayer Perceptron (MLP), aplicada sobre datos de microbiota gástrica.

El modelo implementado corresponde a una red neuronal multicapa superficial. La arquitectura base está compuesta por una capa de entrada implícita, una única capa oculta y una capa de salida.

La capa oculta consiste en 16 neuronas con función de activación ReLU, lo que permite modelar relaciones no lineales entre las características. A continuación, se incorpora una capa de regularización Dropout con una tasa del 30%, cuyo objetivo es reducir el riesgo de sobreajuste, especialmente relevante dado el tamaño reducido del conjunto de datos. Finalmente, la capa de salida está formada por una única neurona con activación sigmoide, adecuada para clasificación binaria, que produce la probabilidad de pertenencia a la clase positiva.

La elección de una arquitectura superficial y compacta responde a la necesidad de controlar el sobreajuste en un contexto con pocos datos (29 muestras). En este sentido, el uso de ReLU favorece la eficiencia del entrenamiento, mientras que el Dropout introduce robustez al modelo.

El modelo se entrena sobre datos de abundancia taxonómica previamente transformados mediante CLR (Centered Log-Ratio), lo cual permite manejar la naturaleza composicional de los datos microbiológicos.

Para evitar problemas de data leakage, todo el proceso de preprocesamiento se realiza dentro de cada iteración de validación. En primer lugar, se aplica una selección de características utilizando VarianceThreshold con un umbral de 0.1, eliminando aquellas variables con baja variabilidad. Posteriormente, se realiza un escalado de las características mediante StandardScaler, asegurando que

tengan media cero y desviación estándar uno, lo cual facilita la convergencia del modelo.

Las características de entrada corresponden a las abundancias de los taxones (inicialmente 60), reducidas dinámicamente tras la selección por varianza. La salida del modelo es un valor entre 0 y 1 que representa la probabilidad de infección por *H. pylori*. Para la clasificación final se emplea un umbral de 0.5.

Debido al tamaño limitado del dataset, se utilizó validación cruzada Leave-One-Out (LOOCV). En cada iteración, una muestra se reserva para prueba y el resto se emplea para entrenamiento, lo que permite aprovechar al máximo los datos disponibles y obtener una estimación más robusta del rendimiento.

El modelo se compila utilizando el optimizador Adam y la función de pérdida binary cross-entropy, estándar en problemas de clasificación binaria. El entrenamiento se realiza durante 60 épocas con un tamaño de lote de 4, valores definidos a partir de un análisis de sensibilidad de hiperparámetros.

Para evaluar el desempeño del modelo se emplearon múltiples métricas. El F1-score se utilizó como medida principal, ya que combina precisión y exhaustividad y resulta adecuado en escenarios con posible desbalance de clases. Asimismo, se calculó el AUC-ROC, que mide la capacidad del modelo para discriminar entre clases. Adicionalmente, se consideró la exactitud (accuracy), aunque su interpretación se realizó con cautela debido a su sensibilidad al desbalance. Finalmente, se analizó la matriz de confusión, que permite descomponer los resultados en verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. En este contexto, los falsos negativos son especialmente relevantes, ya que implican no detectar correctamente casos de infección.

B. Auxiliary Classifier Generative Adversarial Network (AC-GAN)

Se implementó una red neuronal superficial del tipo AC-GAN, orientada al aumento de datos en el análisis del microbioma gástrico. El objetivo principal fue ampliar un conjunto de datos limitado relacionado con perfiles de *H. pylori*, generando muestras sintéticas que conserven coherencia biológica.

Se optó por una arquitectura AC-GAN adaptada a datos tabulares biológicos. La elección de un modelo superficial responde al tamaño reducido del dataset original, ya que una arquitectura más profunda podría sobreajustarse fácilmente. En este caso, el uso de una sola capa oculta tanto en el generador como en el discriminador actúa como un mecanismo de regularización, favoreciendo la generalización.

El Generador recibe como entrada un vector de ruido de dimensión 16 y una etiqueta binaria que indica la presencia o ausencia de *H. pylori*. Este módulo cuenta con una capa oculta de 128 neuronas con activación LeakyReLU, seguida de una capa de salida de 60 neuronas (una por cada taxón), con activación tanh. Esta función de activación asegura que los valores generados se mantengan en el rango $[-1, 1]$, consistente con los datos normalizados. El Discriminador toma como entrada un vector de 60 características correspondiente a un perfil microbiológico. Su arquitectura incluye una capa oculta de 128 neuronas con activación LeakyReLU. La salida se divide en dos partes: una que clasifica si la muestra es real o generada, y otra que predice la presencia de *H. pylori*, ambas mediante activación sigmoide.

El uso de AC-GAN permite generar datos condicionados por clase, lo cual resulta clave para el aumento controlado del dataset. Además, la salida dual del discriminador mejora la calidad de las muestras generadas al incorporar información supervisada durante el entrenamiento.

El proceso inicia con la carga de los datos microbiológicos y sus metadatos asociados. Se eliminan identificadores como Sample_ID, obteniendo una matriz de características (60 taxones) y un vector de etiquetas binarias. Dado que los datos fueron transformados previamente mediante CLR, se aplicó una normalización con

MinMaxScaler al rango $[-1, 1]$. Este paso es fundamental para estabilizar el entrenamiento de la GAN y garantizar coherencia con la activación tangente hiperbólica del generador.

En cuanto a las entradas y salidas del modelo, el generador recibe ruido aleatorio y una etiqueta de clase, produciendo perfiles sintéticos de abundancia bacteriana. El discriminador, por su parte, evalúa tanto datos reales como generados, produciendo una probabilidad de autenticidad y una predicción de clase.

El entrenamiento se llevó a cabo durante 2000 épocas con un tamaño de lote de 32, siguiendo un esquema adversario. Se utilizaron dos optimizadores Adam con diferentes tasas de aprendizaje: una mayor para el discriminador (0.0002) y una menor para el generador (0.00005), con el fin de mantener un equilibrio entre ambos.

El proceso alterna entre dos fases: primero se entrena el discriminador con muestras reales y generadas, y luego se entrena el generador para producir datos que el discriminador clasifique como reales. Se utilizó entropía cruzada binaria como función de pérdida tanto para la autenticidad como para la clasificación.

Durante el entrenamiento se alcanzó un equilibrio estable, evidenciado por la convergencia de las pérdidas del discriminador y el generador, lo que indica que ambos modelos aprendieron de manera efectiva sin colapsar.

La evaluación del modelo se realizó mediante diferentes enfoques. En primer lugar, se aplicó PCA para comparar visualmente los datos reales y sintéticos; sin embargo, esta representación resultó limitada para evidenciar diferencias claras debido a la alta dimensionalidad.

Posteriormente, se analizó la similitud estructural mediante la comparación de matrices de correlación entre los taxones. El bajo error promedio obtenido indicó que el modelo logró capturar adecuadamente las relaciones entre variables.

Finalmente, se realizó una validación predictiva utilizando el esquema Train on Synthetic, Test on Real (TSTR). Se entrenó un modelo Random Forest con datos sintéticos y se evaluó sobre datos reales, alcanzando una precisión del 96.55%. Este resultado confirma que los datos generados preservan información relevante y son útiles para tareas de aprendizaje supervisado.

C. Autoencoder combinado con un clasificador

Esta aproximación se basa en una red neuronal superficial construida a partir de un autoencoder previamente entrenado. Esta arquitectura se compone de dos fases principales: una fase de pre-entrenamiento no supervisado y una fase de clasificación supervisada.

En la fase de pre-entrenamiento, se implementa un autoencoder cuya función es aprender una representación comprimida de los datos de entrada. El encoder está conformado por una capa densa con función de activación ReLU, que transforma los datos desde un espacio de dimensión input_dim hacia un espacio latente de dimensión reducida (encoding_dim = 8). Por su parte, el decoder, compuesto por una capa densa con activación lineal, tiene como objetivo reconstruir los datos originales a partir de dicha representación. No obstante, esta última parte es descartada en la fase de clasificación.

Posteriormente, en la fase supervisada, se construye un clasificador superficial que toma como entrada la representación latente generada por el encoder. Este clasificador está compuesto por una única capa de salida con activación sigmoide, adecuada para problemas de clasificación binaria, la cual produce una probabilidad de pertenencia a la clase positiva.

La elección de esta arquitectura híbrida (autoencoder + clasificador superficial) responde principalmente a la naturaleza del conjunto de datos, caracterizado por un número reducido de observaciones (29 instancias). En este contexto, los autoencoders resultan especialmente útiles, ya que permiten realizar extracción de

características de forma no supervisada, capturando relaciones intrínsecas en los datos. Asimismo, la reducción de dimensionalidad contribuye a mitigar el riesgo de sobreajuste en el clasificador. Adicionalmente, el pre-entrenamiento del autoencoder proporciona una base representacional sólida, que facilita el aprendizaje en la etapa supervisada. Al descartar el decoder y utilizar únicamente el encoder junto con un clasificador simple, se reduce la complejidad del modelo y el número de parámetros a entrenar, lo cual resulta conveniente en escenarios con datos limitados.

El proceso de preparación de datos inicia con la estandarización de las variables mediante el uso de StandardScaler, garantizando que todas las características tengan media cero y desviación estándar uno. Esto es fundamental para evitar que variables con escalas mayores dominen el proceso de aprendizaje.

Posteriormente, se aplicaron técnicas de aumento de datos con el fin de mitigar la escasez y el desbalance del conjunto original. En particular, se utilizó SMOTE (Synthetic Minority Over-sampling Technique) para generar muestras sintéticas y balancear las clases, alcanzando un total de 40 instancias por clase, lo que resultó en un conjunto de datos ampliado de 80 observaciones. Adicionalmente, se incorporó ruido gaussiano de baja magnitud a los datos generados, con el objetivo de introducir variabilidad y mejorar la capacidad de generalización del modelo.

Una vez preparado el conjunto de datos, el autoencoder es entrenado de forma no supervisada. Posteriormente, el encoder es utilizado como mecanismo de extracción de características, transformando los datos originales en una representación latente de 8 dimensiones. Estas nuevas características constituyen la entrada del clasificador superficial.

En este sentido, la entrada a la red neuronal corresponde a las características codificadas (encoded features), mientras que la salida es un valor binario que indica la clase predicha. La arquitectura final del modelo puede interpretarse como la extensión del encoder, seguida de una capa densa de salida con activación sigmoide.

El proceso de entrenamiento se llevó a cabo mediante la división de los datos en conjuntos de entrenamiento y prueba. Se evaluaron tanto el conjunto original como el conjunto aumentado. Para la optimización de los parámetros se utilizó el algoritmo Adam, junto con la función de pérdida binary cross-entropy, adecuada para clasificación binaria. El entrenamiento se realizó durante 50 épocas con un tamaño de lote de 16, monitoreando el desempeño mediante un conjunto de validación.

Para evaluar el desempeño del modelo se emplearon diversas métricas. En primer lugar, se utilizó la precisión (accuracy), la cual mide la proporción de predicciones correctas sobre el total de instancias. Esta métrica se analizó tanto en el conjunto de entrenamiento como en el de validación a lo largo de las épocas, apoyándose en representaciones gráficas que permiten observar la evolución del aprendizaje.

Adicionalmente, se utilizó la matriz de confusión, la cual proporciona una visión más detallada del comportamiento del modelo al descomponer las predicciones en verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Este análisis permite identificar posibles sesgos del modelo y evaluar su capacidad para clasificar correctamente cada una de las clases.

En conjunto, estas métricas permiten obtener una evaluación integral del rendimiento del modelo y de su capacidad de generalización en el problema propuesto.

D. Implementación Mixta de un Variational Autoencoder (VAE) con una Generative Adversarial Network (GAN)

Esta implementación emplea una arquitectura de tipo VAE-GAN (Variational Autoencoder Generative Adversarial Network), la cual corresponde a un modelo generativo de aprendizaje profundo. Esta

elección se fundamenta en la necesidad de capturar patrones complejos presentes en los datos microbiológicos, manejar su posible alta dimensionalidad y aprender un espacio latente significativo que permita analizar la influencia de *H. pylori*.

La arquitectura VAE-GAN está compuesta por tres módulos principales: un Encoder, un Decoder y un Discriminator, cada uno implementado como una red neuronal feedforward.

El Encoder recibe como entrada los datos microbiológicos preprocesados, correspondientes a los géneros bacterianos transformados mediante CLR (Centered Log-Ratio). La dimensión de entrada varía entre 59 y 60 características, dependiendo de la inclusión o no de *H. pylori*. Este módulo contiene una capa oculta de 64 neuronas con activación ReLU. Como salida, produce dos vectores: la media (μ) y la log-varianza (logvar), que definen una distribución probabilística en un espacio latente de dimensión 10. El Decoder toma como entrada un vector latente z , obtenido mediante el truco de reparametrización a partir de μ y logvar. Este módulo presenta una capa oculta de 64 neuronas con activación ReLU y una capa de salida lineal cuya dimensión coincide con la entrada original (59 o 60 características). La ausencia de función de activación en la salida permite reconstruir valores negativos, consistentes con los datos transformados mediante CLR. El Discriminator recibe como entrada tanto datos reales como reconstruidos. Su arquitectura consiste en una capa oculta de 64 neuronas con activación ReLU y una capa de salida con una neurona y activación sigmoide, que produce la probabilidad de que una muestra sea real.

El proceso de preparación de datos se centra en el preprocesamiento. En primer lugar, se realiza la alineación entre las tablas OTU (Operational Taxonomic Units) y los metadatos mediante el identificador de muestra (Sample_ID). Posteriormente, se gestionan valores faltantes e infinitos en los datos transformados mediante CLR, reemplazándolos por cero. A continuación, los datos son normalizados mediante MinMaxScaler en el rango $[-1, 1]$, lo cual resulta fundamental para estabilizar el entrenamiento, especialmente en modelos con componentes adversarios.

Las entradas al Encoder y al Discriminator corresponden a estos datos preprocesados. El Decoder genera reconstrucciones de dichas entradas, mientras que el Discriminator produce una salida binaria que indica si los datos son reales o generados.

El modelo se entrena utilizando validación cruzada estratificada de 5 particiones, lo que permite evaluar su desempeño de forma más robusta y considerar el desbalance de clases. Para la optimización se emplea el algoritmo Adam con una tasa de aprendizaje de $1e-3$, aplicado tanto al VAE como al Discriminator. La función de pérdida combina varios componentes: el error de reconstrucción (MSE) y la divergencia Kullback-Leibler (KLD) en el VAE, junto con la entropía cruzada binaria utilizada por el Discriminator para distinguir entre datos reales y generados. Además, el Decoder se entrena de forma adversaria para generar reconstrucciones que sean clasificadas como reales. El entrenamiento se realiza de manera iterativa, alternando la actualización del Discriminator y del VAE.

El desempeño del modelo se evalúa principalmente a través de la pérdida total del VAE, que integra los términos de reconstrucción, KLD y pérdida adversaria. Valores bajos y estables indican una adecuada convergencia.

También se analizan las curvas de aprendizaje para observar la evolución de la pérdida durante el entrenamiento. Adicionalmente, se proyecta el espacio latente a dos dimensiones mediante PCA sobre el vector μ , lo que permite visualizar si el modelo logra separar las clases. Finalmente, la calidad de las reconstrucciones se considera como un indicador cualitativo de la capacidad del modelo para representar los datos.

VIII. RESULTADOS PRELIMINARES Y EVALUACIÓN DE DESEMPEÑO

En esta sección se presentan los resultados obtenidos a partir de la implementación de las distintas arquitecturas propuestas, incluyendo

la red neuronal superficial, el modelo basado en autoencoder y las variantes generativas como GAN y VAE-GAN. El objetivo es analizar comparativamente su desempeño en la tarea planteada, considerando tanto su capacidad predictiva como su habilidad para capturar la estructura de los datos.

Para ello, se emplean diferentes métricas de evaluación, acordes a la naturaleza de cada modelo, así como herramientas de análisis que permiten interpretar su comportamiento durante el entrenamiento. En particular, se examinan aspectos como la convergencia de las funciones de pérdida, la estabilidad del aprendizaje y la capacidad de generalización.

Adicionalmente, se realiza un análisis del ajuste de los modelos, con el fin de identificar posibles problemas de sobreajuste o subajuste. Este diagnóstico permite plantear ajustes en las arquitecturas o en el proceso de entrenamiento, buscando mejorar el rendimiento y la robustez de las soluciones propuestas.

A. Resultados de la Red Neuronal Superficial Para Clasificación Binaria

El modelo baseline, con arquitectura Dense(16, ReLU) → Dropout(0.3) → Dense(1, Sigmoid), fue entrenado durante 60 épocas. Las métricas obtenidas a partir de las 29 predicciones generadas mediante LOOCV fueron las siguientes:

- 1) F1-Score: 0.9231
- 2) AUC-ROC: 0.9278
- 3) Accuracy: 0.8966

La matriz de confusión mostró los siguientes resultados:

- 1) Verdaderos Positivos (VP): 18
- 2) Verdaderos Negativos (VN): 8
- 3) Falsos Positivos (FP): 1
- 4) Falsos Negativos (FN): 2

Estos resultados evidencian un alto desempeño del modelo, particularmente en términos de F1-Score y AUC-ROC, lo cual es destacable considerando el tamaño del dataset y el desbalance de clases (20 casos positivos frente a 9 negativos). Es relevante notar la baja cantidad de falsos negativos, dado que este tipo de error tiene un impacto crítico en el contexto clínico.




Figura 14. Resultados Baseline MLP [16] | Microbioma sin Helicobacter.

Se evaluaron distintas configuraciones variando el número de neuronas en la capa oculta, con el fin de identificar la arquitectura más adecuada en el dataset sin Helicobacter. Los resultados obtenidos fueron:

TABLA 2
DESEMPEÑO DEL PERCEPTRÓN MULTICAPA A TRAVÉS DE DIFERENTES CONFIGURACIONES DE ARQUITECTURA DE RED

Arquitectura	F1 - Score	AUC - ROC	Accuracy
[32]	0.7	0.4222	0.5862
[24]	0.6977	0.3833	0.5517
[16]	0.6667	0.3333	0.5517

La arquitectura [32] presentó el mejor desempeño relativo entre las evaluadas. Sin embargo, todas las configuraciones muestran una disminución significativa en comparación con el modelo baseline, lo que sugiere que el problema sin la variable Helicobacter es más complejo o menos separable. Esto también puede indicar que el

modelo baseline captura patrones fuertemente asociados a la presencia de esta variable.

Se realizó un análisis de sensibilidad considerando diferentes funciones de activación (ReLU, tanh, ELU) y número de épocas (30, 60, 90), utilizando la arquitectura [16] como base. Los resultados más relevantes se presentan a continuación:

TABLA 3
ANÁLISIS DE SENSIBILIDAD DEL PERCEPTRÓN MULTICAPA CONSIDERANDO DIFERENTES FUNCIONES DE ACTIVACIÓN

Configuración	Activación	Épocas	F1 - Score	AUC - ROC	Accuracy
act=elu, epochs=30	elu	30	0.7	0.45	0.5862
act=relu, epochs=60	relu	60	0.7	0.45	0.5862
act=relu, epochs=90	relu	90	0.6977	0.3833	0.5517
act=tanh, epochs=60	tanh	60	0.6977	0.3833	0.5517
act=elu, epochs=90	elu	90	0.6977	0.3833	0.5517
act=elu, epochs=60	elu	60	0.6667	0.3833	0.5517
act=relu, epochs=30	relu	30	0.6316	0.4833	0.5172
act=tanh, epochs=90	tanh	90	0.6316	0.4833	0.5172
act=tanh, epochs=30	tanh	30	0.5833	0.5222	0.4828

Los resultados indican que las funciones de activación ReLU y ELU presentan un desempeño ligeramente superior en términos de F1-Score. Asimismo, se observa que un número moderado de épocas (30–60) tiende a ofrecer mejores resultados, mientras que un mayor número de épocas no garantiza mejoras y puede introducir inestabilidad en el aprendizaje.

El reducido tamaño del dataset implica un riesgo constante de sobreajuste. El alto desempeño del modelo baseline sugiere que este logra capturar patrones relevantes, aunque también podría estar parcialmente ajustado a características específicas del conjunto de entrenamiento. La disminución del rendimiento al evaluar configuraciones alternativas y, especialmente, al considerar el dataset sin Helicobacter, indica limitaciones en la capacidad de generalización del modelo. Esto sugiere que la presencia de H. pylori constituye una señal dominante en los datos.

Las técnicas utilizadas, como el uso de Dropout, una arquitectura superficial y validación LOOCV, contribuyen a mitigar el sobreajuste. No obstante, los resultados muestran que el modelo aún enfrenta dificultades para generalizar en escenarios donde la señal principal es menos evidente.

En conjunto, no se observa un caso claro de subajuste en el modelo baseline, pero sí evidencia de una generalización limitada en condiciones más complejas, lo que sugiere la necesidad de ajustes adicionales en la arquitectura o en la selección de características.

B. Resultados de la arquitectura Auxiliary Classifier Generative Adversarial Network (AC - GAN)

Durante el entrenamiento, el modelo mostró un comportamiento estable a lo largo de las 2000 épocas. Se observó una convergencia adecuada entre el generador y el discriminador, alcanzando valores de pérdida aproximados de 0.49 para el discriminador y 1.38 para el generador. Este equilibrio indica que ambos componentes aprendieron de manera conjunta sin que uno dominara al otro, evitando problemas como el mode collapse y favoreciendo la generación de muestras diversas.

Con el fin de evaluar la calidad de los datos sintéticos generados, se emplearon distintos enfoques. En primer lugar, se realizó una visualización mediante Análisis de Componentes Principales (PCA), proyectando los datos reales y sintéticos en dos dimensiones. En esta representación no se evidenció una separación clara entre ambos conjuntos. Sin embargo, este resultado es esperable en datos de alta dimensionalidad, donde las proyecciones lineales en 2D pueden no reflejar adecuadamente la estructura interna.




Figura 15. PCA: Datos Reales vs Sintéticos.

Adicionalmente, se evaluó la similitud estructural entre los datos reales y sintéticos mediante el análisis de las matrices de correlación entre los taxones. El bajo error promedio observado sugiere que el modelo logró capturar de manera consistente las relaciones entre variables, preservando la estructura biológica subyacente.




Figura 16. Diferencia de Correlación Real vs Sintético

Como validación adicional, se implementó el esquema Train on Synthetic, Test on Real (TSTR). Se entrenó un modelo Random Forest utilizando únicamente datos sintéticos y posteriormente se evaluó sobre el conjunto de datos reales. El modelo alcanzó una precisión del 96.55%, lo que indica que los datos generados contienen información discriminativa relevante y son útiles para tareas de clasificación.

En términos de ajuste del modelo, no se observaron indicios claros de sobreajuste, ya que el discriminador no alcanzó una dominancia excesiva ni el generador colapsó en la producción de muestras similares. Por el contrario, la estabilidad en las pérdidas sugiere un aprendizaje equilibrado. No obstante, la ausencia de

separación clara en el PCA indica que podrían explorarse estrategias adicionales para mejorar la representatividad de las muestras generadas.

En conjunto, estos resultados evidencian un desempeño sólido del modelo en la generación de datos sintéticos coherentes y útiles para análisis posteriores.

C. Resultados de la Arquitectura Autoencoder combinado con clasificador

El autoencoder entrenado sobre el conjunto original mostró limitaciones derivadas del reducido número de observaciones. La evolución de la pérdida evidencia un comportamiento inestable, así como una posible separación entre las curvas de entrenamiento y validación, lo que sugiere sobreajuste o dificultades para aprender representaciones robustas.




Figura 17. Pérdida del Autoencoder haciendo uso del conjunto original de datos.

El análisis del error de reconstrucción muestra una distribución relativamente dispersa, con presencia de valores elevados. Esto indica que el modelo no logra reconstruir adecuadamente ciertos ejemplos, posiblemente debido a la falta de variabilidad en los datos de entrenamiento.




Figura 18. Distribución del Error de Reconstrucción del Autoencoder en el entrenamiento con únicamente el conjunto de datos original.

El entrenamiento del autoencoder sobre el conjunto aumentado mostró una mejora en la estabilidad del aprendizaje. La evolución de la pérdida presenta un comportamiento más suave, con menor divergencia entre entrenamiento y validación, lo que indica una representación más consistente.




Figura 19. Pérdida del Autoencoder haciendo uso del conjunto sintético de datos.

El error de reconstrucción tiende a concentrarse en valores más bajos, reflejando una mejor capacidad del modelo para reconstruir tanto datos originales como sintéticos.




Figura 20. Distribución del Error de Reconstrucción del Autoencoder en el entrenamiento con el conjunto de datos sintéticos.

El clasificador entrenado sobre las representaciones latentes del dataset original presenta un comportamiento inestable. La precisión muestra alta variabilidad, con valores elevados en entrenamiento pero bajos o fluctuantes en validación, lo que evidencia un claro sobreajuste.




Figura 21. Precisión del Clasificador a lo largo de las distintas épocas haciendo uso del conjunto de datos original.

La matriz de confusión resulta poco confiable debido al tamaño reducido del conjunto de prueba. La distribución de predicciones suele estar sesgada, dificultando una evaluación representativa del modelo.




Figura 22. Matriz de Confusión del Clasificador entrenado con el conjunto de datos original.

El clasificador entrenado con el dataset aumentado presenta un comportamiento más estable. La precisión muestra curvas más suaves y una menor diferencia entre entrenamiento y validación, lo que indica una mejora en la capacidad de generalización.




Figura 23. Precisión del Clasificador a lo largo de las distintas épocas haciendo uso del conjunto de datos sintético.

La matriz de confusión refleja una distribución más equilibrada entre verdaderos positivos y negativos, lo que sugiere una mejor discriminación entre clases en comparación con el caso original.




Figura 24. Matriz de Confusión del Clasificador entrenado con el conjunto de datos sintético.

Al evaluar el clasificador entrenado con datos aumentados directamente sobre el dataset original, se obtuvo una precisión de 31.03%. Este resultado evidencia una baja capacidad de generalización hacia los datos reales. La matriz de confusión asociada muestra un alto número de clasificaciones incorrectas, lo que indica que el modelo ha aprendido patrones presentes en los datos sintéticos que no se corresponden completamente con la distribución original.

Los resultados permiten identificar comportamientos claros en los modelos evaluados. En el caso del dataset original, tanto el autoencoder como el clasificador presentan un fuerte sobreajuste, debido al tamaño extremadamente reducido del conjunto de datos, lo que impide aprender patrones generalizables.

Por otro lado, el uso de datos aumentados mejora la estabilidad del entrenamiento y permite obtener métricas más consistentes. Sin embargo, la baja precisión al evaluar sobre datos originales indica que el modelo no logra generalizar adecuadamente, lo que sugiere un sobreajuste hacia los datos sintéticos.

A partir de los resultados obtenidos, se identifican varias acciones para mejorar el desempeño del modelo. En primer lugar, la recolección de más datos reales es fundamental, ya que las técnicas de aumento no sustituyen completamente la información original. Asimismo, se pueden explorar estrategias adicionales de regularización para reducir el sobreajuste.

También resulta pertinente evaluar modelos más simples como línea base, así como implementar esquemas de validación cruzada que permitan obtener estimaciones más robustas del desempeño. Finalmente, la incorporación de técnicas de ingeniería de características o enfoques como transferencia de aprendizaje podría contribuir a mejorar la calidad de las representaciones aprendidas.

D. Resultados de la Implementación Mixta VAE-GAN

Los resultados obtenidos indican que el modelo no se limita a la presencia de *Helicobacter pylori*, sino que es capaz de capturar patrones más complejos dentro del microbioma. Aunque *H. pylori* representa una señal dominante, los análisis realizados muestran que el modelo identifica cambios en las relaciones entre géneros bacterianos y conserva estructuras relevantes para la clasificación incluso cuando esta variable es excluida.

En primer lugar, el análisis del balance de clases muestra una distribución consistente en ambos escenarios. Tanto el dataset con *H. pylori* como el dataset sin esta variable presentan una proporción aproximada de 69% para la clase 1 y 31% para la clase 0 en la variable `label_binary`. Esto garantiza que las comparaciones realizadas no estén sesgadas por desbalances en las clases.




Figura 25. Balance de clases: Dataset con HP y 'Balance de clases: Dataset sin HP.

El análisis de correlación evidenció cambios importantes en la estructura del microbioma. En el dataset que incluye *H. pylori*, se observan clústeres de correlación más definidos entre ciertos géneros bacterianos. En contraste, al eliminar esta variable, la estructura de correlaciones se reorganiza, lo que sugiere que la presencia de *Helicobacter* influye en las relaciones internas del ecosistema microbiano.




Figura 26. Correlación de géneros (Top 20) - Con HP y Correlación de géneros (Top 20) - Sin HP.

En cuanto al desempeño del modelo VAE-GAN, las curvas de entrenamiento muestran una convergencia estable al integrar los distintos componentes de la función de pérdida. Este comportamiento se mantiene en ambos conjuntos de datos, incluso en el escenario sin *H. pylori*, donde la dinámica de aprendizaje es diferente pero igualmente convergente. Esto sugiere que el modelo es capaz de adaptarse a patrones más sutiles presentes en el microbioma (ver [Figura 27. Comparación de Curvas de Aprendizaje: VAE-GAN - HP vs No HP](#)).




Figura 27. Comparación de Curvas de Aprendizaje: VAE-GAN - HP vs No HP.

El análisis del espacio latente refuerza estos resultados. La proyección mediante PCA de las representaciones generadas por el encoder muestra la formación de agrupaciones coherentes en ambos escenarios. Es particularmente relevante que, incluso sin la presencia de *H. pylori*, el modelo mantiene cierta capacidad de organización y separación entre muestras, lo que indica que está aprendiendo características relevantes más allá de una sola variable dominante.




Figura 28. Latent Space PCA: Dataset con H' y Latent Space PCA: Dataset sin HP.

En conjunto, los resultados sugieren que el modelo logra capturar patrones estructurales del microbioma más allá de la presencia de *Helicobacter pylori*. Si bien esta variable influye significativamente en la organización de los datos, no es el único factor determinante en el aprendizaje del modelo.

E. Comparación, Análisis y Discusión de los Resultados

Teniendo en cuenta los cuatro enfoques basados en redes neuronales superficiales: (i) una red neuronal tipo MLP para clasificación directa, (ii) un modelo híbrido basado en autoencoder con clasificador, (iii) una arquitectura generativa AC-GAN y (iv) un modelo VAE-GAN. Aunque difieren en su formulación, todos comparten una característica clave: arquitecturas poco profundas, diseñadas para trabajar en un contexto de datos extremadamente limitado.

En términos de desempeño en clasificación, la MLP superficial mostró los mejores resultados iniciales. Las métricas obtenidas (F1-Score, AUC-ROC y accuracy) fueron altas, lo que indica que el modelo logra separar adecuadamente las clases en el dataset original. Sin embargo, este buen rendimiento está fuertemente condicionado por la presencia de señales dominantes, en particular *Helicobacter pylori*. Cuando esta variable se elimina o se modifica el contexto de los datos, el desempeño disminuye de manera considerable, lo que sugiere una dependencia importante de características altamente discriminativas y un riesgo latente de sobreajuste.

El enfoque basado en autoencoder + clasificador superficial permitió introducir un proceso de extracción de características. Este modelo logró representar los datos en un espacio latente más compacto, lo que contribuyó a estabilizar parcialmente el entrenamiento. No obstante, los resultados evidencian que la calidad de las representaciones depende fuertemente de los datos disponibles. En particular, al utilizar datos aumentados, el modelo mostró mejoras en estabilidad, pero una capacidad limitada de generalización al evaluarse sobre datos reales, lo que indica que las características aprendidas no capturan completamente la distribución original.

Por su parte, la AC-GAN presentó resultados sólidos desde la perspectiva de modelado de datos. Aunque no es un clasificador directo, su capacidad para generar muestras sintéticas coherentes fue validada mediante análisis estructurales (correlaciones) y pruebas predictivas. El hecho de que un modelo entrenado sobre datos sintéticos logre un alto desempeño sobre datos reales sugiere que la red fue capaz de capturar patrones relevantes del microbioma. Este enfoque resulta especialmente útil para mitigar la escasez de datos, que es el principal cuello de botella del problema.

El modelo VAE-GAN, aun siendo superficial en su arquitectura, mostró una mayor capacidad para aprender representaciones latentes estructuradas. Los resultados indican que el modelo logra capturar patrones del microbioma incluso en ausencia de *H. pylori*, lo cual es particularmente relevante. A diferencia de la MLP, que depende de señales directas, este modelo evidencia la capacidad de aprender relaciones más globales entre los taxones. Además, la estabilidad observada en las curvas de entrenamiento sugiere un aprendizaje consistente, aunque limitado por la cantidad de datos disponibles.

En conjunto, los resultados muestran que, incluso dentro del marco de redes superficiales, existen diferencias importantes en el tipo de aprendizaje que cada arquitectura permite. La MLP destaca en tareas de clasificación directa cuando existen patrones claros, pero presenta limitaciones en generalización. El modelo de autoencoder introduce una mejora en la representación, aunque depende de la calidad de los datos. Las arquitecturas generativas (AC-GAN y VAE-GAN) aportan un valor adicional al capturar la estructura del espacio de datos y permitir la generación de nuevas muestras, lo que resulta clave en escenarios con pocos datos. A partir de estos hallazgos, se puede inferir que el principal limitante no es tanto la profundidad del modelo, sino la disponibilidad de datos. En este contexto, las arquitecturas más complejas (aunque superficiales) tienden a ofrecer mejores resultados en términos de representación y modelado estructural, mientras que los modelos más simples son efectivos únicamente cuando las señales son claras y dominantes.

En conclusión, las arquitecturas generativas, especialmente AC-GAN y VAE-GAN, demostraron un mayor potencial para capturar patrones complejos del microbioma y enfrentar el problema

de escasez de datos. Esto sugiere que futuras mejoras del sistema deberían orientarse hacia el uso combinado de generación de datos y clasificación, más que al incremento de la complejidad estructural de las redes.

IX. CONSIDERACIONES Y PREGUNTAS ÉTICAS

El proyecto utiliza datos de microbiota humana obtenidos de estudios previamente aprobados por comités de ética y con consentimiento informado de los participantes.

Se tendrán en cuenta los siguientes aspectos:

- 1) Uso exclusivo de datos anonimizados.
- 2) No se realizará reidentificación de individuos.
- 3) Los resultados se interpretarán únicamente con fines investigativos.
- 4) El modelo desarrollado no será considerado una herramienta diagnóstica clínica sin validación externa adicional.

Asimismo, se reconoce que el tamaño muestral limitado puede afectar la generalización del modelo, por lo que cualquier conclusión deberá interpretarse dentro del contexto del dataset utilizado.

X. ENLACES WEB DEL CÓDIGO FUENTE Y VIDEO EXPLICATIVO

A. Código Fuente

- 1) La carpeta donde se almacenarán los notebooks se encuentra en el siguiente enlace: https://drive.google.com/drive/folders/1T7gSd9RB6pCJoz1JuhegMilvUAspRP2p?usp=drive_link.

- 2) El repositorio del proyecto se encuentra disponible en el siguiente enlace: <https://github.com/nmart1nez1/NeuronalNetworks-Group6>. En este repositorio se puede consultar el archivo README.md, el cual describe detalladamente la estructura del proyecto, los objetivos de su desarrollo, los integrantes del equipo de trabajo y las directrices para colaborar en él.

En términos generales, el repositorio se organiza en dos carpetas principales. La primera, denominada “project”, contiene todos los avances relacionados con el proyecto final del curso. La segunda, llamada “ClassPresentations”, almacena las distintas producciones, notebooks y material audiovisual que serán utilizados por los miembros del equipo para la preparación y desarrollo de las presentaciones realizadas a lo largo del curso.

B. Video Explicativo

El video explicativo puede encontrarse en el siguiente enlace: <https://youtu.be/XZgvpHs4SO4>

XI. CONTRIBUCIÓN DE LOS MIEMBROS DEL EQUIPO

TABLA 4
CONTRIBUCIÓN DE CADA UNO DE LOS MIEMBROS DEL EQUIPO

Miembro del Equipo	Rol(es)	Actividades / Contribuciones
David Felipe Marin Rosas	Coordinador, Investigador, Observador, Técnico	Revisión de arquitecturas de red relevantes para el problema. Implementación y entrenamiento de la red GAN. Coordinación del equipo en las actividades del proyecto. Análisis e interpretación de los resultados obtenidos.
Diego Esteban Morales Granados	Técnico, Experto	Implementación y entrenamiento de la red VAE - GAN. Análisis e interpretación de los resultados obtenidos.

Laura Camila Girón Pinto	Líder, Animadora, Investigadora, Técnica	Preparación y preprocesamiento de los datos de entrada. Documentación del desarrollo y resultados del proyecto. Análisis e interpretación de los resultados obtenidos.
Nicolás Martínez López	Coordinador, Técnico	Implementación entrenamiento de la red Autoencoder + Clasificador Binario. Documentación del desarrollo y resultados del proyecto. Análisis e interpretación de los resultados obtenidos.
Sergio Ivan Motta Doncel	Investigador, Técnico	Implementación y entrenamiento del perceptrón multicapa (MLP). Análisis e interpretación de resultados obtenidos. Creación y edición del video de presentación del proyecto.

XII. CONCLUSIÓN

El presente trabajo abordó la clasificación de la infección por *Helicobacter pylori* a partir de datos de microbioma gástrico mediante el uso de distintas arquitecturas de redes neuronales superficiales. A lo largo del desarrollo, se exploraron enfoques de clasificación directa, extracción de características y modelos generativos, con el objetivo de enfrentar la principal limitación del problema: el reducido tamaño del conjunto de datos. En cuanto a los resultados, se evidencia que los modelos de clasificación directa, como la MLP, pueden alcanzar un alto desempeño cuando existen señales dominantes en los datos. Sin embargo, también se observó una limitada capacidad de generalización, especialmente cuando se modifica el contexto del problema o se eliminan variables altamente discriminativas. Por su parte, el uso de autoencoders permitió mejorar la representación de los datos, aunque su efectividad estuvo condicionada por la calidad y cantidad de las muestras disponibles. Desde otra perspectiva, los enfoques generativos, particularmente AC-GAN y VAE-GAN, demostraron una mayor capacidad para capturar la estructura subyacente del microbioma. Estos modelos no solo permitieron generar datos sintéticos coherentes, sino que también evidenciaron la existencia de patrones relevantes más allá de la presencia de *H. pylori*. En este sentido, el uso de modelos generativos se posiciona como una estrategia clave para mitigar la escasez de datos y mejorar el desempeño de sistemas de clasificación en este tipo de problemas. Finalmente, los hallazgos sugieren que, en escenarios con datos limitados, el éxito no depende únicamente de la arquitectura del modelo, sino de la capacidad para representar adecuadamente la distribución de los datos. En consecuencia, una línea de trabajo futura consiste en integrar técnicas de generación de datos con modelos de clasificación, así como en ampliar el conjunto de datos real, con el fin de construir sistemas más robustos y generalizables.

XIII. USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL

El desarrollo del texto contó con el apoyo de la herramienta de inteligencia artificial ChatGPT, utilizada para asistir en la mejora de la redacción al corregir redundancias en ideas, palabras y algunos verbos. El análisis, la selección de ideas y la coherencia argumentativa del texto son responsabilidad exclusiva de los autores. Adicionalmente, se aprovechó la herramienta NotebookLM para contextualizar los temas y para el aprendizaje de los autores.

REFERENCIAS

- [1] Akpoigbe, K., Culpepper-Morgan, J., Nwankwo, O., & Genao, A. (2022). Predicting Gastric Intestinal Metaplasia in a High-Risk Population. *Cureus*. <https://doi.org/10.7759/cureus.31502>.
- [2] Atherton, J. C. (2006). The pathogenesis of *Helicobacter pylori*-induced gastro-duodenal diseases. *Annual Review of Pathology*, 1, 63–96. <https://doi.org/10.1146/annurev.pathol.1.110304.100125>.
- [3] Chang, W. K., VanInsberghe, D., & Kelly, L. (2020). Topological analysis reveals state transitions in human gut and marine bacterial communities. *Npj Biofilms and Microbiomes*, 6(1), 41. <https://doi.org/10.1038/s41522-020-00145-9>.
- [4] Chiu, C. Y., & Miller, S. A. (2019). Clinical metagenomics. *Nature Reviews Genetics*, 20(6), 341–355. <https://doi.org/10.1038/s41576-019-0113-7>.
- [5] Durán, C., Ciucci, S., Palladini, A., Ijaz, U. Z., Zippo, A. G., Sterbini, F. P., Masucci, L., Cammarota, G., Ianiro, G., Spuul, P., Schroeder, M., Grill, S. W., Parsons, B. N., Pritchard, D. M., Posteraro, B., Sanguinetti, M., Gasbarrini, G., Gasbarrini, A., & Cannistraci, C. V. (2021). Nonlinear machine learning pattern recognition and bacteria-metabolite multilayer network analysis of perturbed gastric microbiome. *Nature Communications*, 12(1), 1926. <https://doi.org/10.1038/s41467-021-22135-x>.
- [6] Eun, C. S., Kim, B. K., Han, D. S., Kim, S. Y., Kim, K. M., Choi, B. Y., Song, K. S., Kim, Y. S., & Kim, J. F. (2014). Differences in gastric mucosal microbiota profiling in patients with chronic gastritis, intestinal metaplasia, and gastric cancer using pyrosequencing methods. *Helicobacter*, 19(6), 407–416. <https://doi.org/10.1111/hel.12145>.
- [7] Gloor, G. B., Macklaim, J. M., Pawlowsky-Glahn, V., & Egozcue, J. J. (2017b). Microbiome datasets are compositional: and this is not optional. *Frontiers in Microbiology*, 8, 2224. <https://doi.org/10.3389/fmicb.2017.02224>.
- [8] Kusters, J. G., Van Vliet, A. H. M., & Kuipers, E. J. (2006). Pathogenesis of *Helicobacter pylori* Infection. *Clinical Microbiology Reviews*, 19(3), 449–490. <https://doi.org/10.1128/CMR.00054-05>.
- [9] Klymiuk, I., Bilgiler, C., Stadlmann, A., Thannesberger, J., Kastner, M., Högenauer, C., Püspök, A., Biowski-Frotz, S., Schrutka-Kölbl, C., Thallinger, G. G., & Steininger, C. (2017). The Human Gastric Microbiome Is Predicated upon Infection with *Helicobacter pylori*. *Frontiers in Microbiology*, 8, 2508. <https://doi.org/10.3389/fmicb.2017.02508>.
- [10] La Placa, G., Covino, M., Candelli, M., Gasbarrini, A., Franceschi, F., & Merra, G. (2025). Relationship Between Human Microbiome and *Helicobacter pylori*. *Microbiology Research*, 16(1), 24. <https://doi.org/10.3390/microbiolres16010024>.
- [11] Lee, S., & Lee, I. (2024). Comprehensive assessment of machine learning methods for diagnosing gastrointestinal diseases through whole metagenome sequencing data. *Gut Microbes*, 16(1), 2375679. <https://doi.org/10.1080/19490976.2024.2375679>.
- [12] Lehr, K., Nikitina, D., Vilchez-Vargas, R., Steponaitiene, R., Thon, C., Skieceviciene, J., Schanze, D., Zenker, M., Malfetherneier, P., Kupcinskas, J., & Link, A. (2023). Microbial composition of tumorous and adjacent gastric tissue is associated with prognosis of gastric cancer. *Scientific Reports*, 13(1), 4640. <https://doi.org/10.1038/s41598-023-31740-3>.
- [13] Meyer, F., Fritz, A., Deng, Z.-L., Koslicki, D., Lesker, T. R., Gurevich, A., Robertson, G., Alser, M., Antipov, D., Beghini, F., Bertrand, D., Brito, J. J., Brown, C. T., Buchmann, J., Buluc, A., Chen, B., Chikhi, R., Clausen, P. T. L. C., Cristian, A., ... McHardy, A. C. (2022). Critical Assessment of Metagenome Interpretation: the second round of challenges. *Nature Methods*, 19(4), 429–440. <https://doi.org/10.1038/s41592-022-01431-4>.

- [14] Mohamed, A. S., Bhujar, R., Martinez, E., Basta, M., Deyab, A., Mansour, C., Tejada, D., Deshpande, V., Elias, S., & Nagesh, V. K. (2025). The Gut Microbiome's Impact on the Pathogenesis and Treatment of Gastric Cancer—An Updated Literature Review. *Cancers*, 17(17), 2795. <https://doi.org/10.3390/cancers17172795>.
- [15] Park, C. H., Lee, A., Lee, Y., Eun, C. S., Lee, S. K., & Han, D. S. (2019). Evaluation of gastric microbiome and metagenomic function in patients with intestinal metaplasia using 16S rRNA gene sequencing. *Helicobacter*, 24(1), e12547. <https://doi.org/10.1111/hel.12547>.
- [16] Sgamato, C., Rocco, A., Compare, D., Priadko, K., Romano, M., & Nardone, G. (2024). Exploring the Link between *Helicobacter pylori*, Gastric Microbiota and Gastric Cancer. *Antibiotics*, 13(6), 484. <https://doi.org/10.3390/antibiotics13060484>.
- [17] SICC | DANE. (n.d.). Sistema de información de cáncer de Colombia. <https://www.infocancer.co/>.
- [18] Sung, J., Kim, N., Kim, J., Jo, H. J., Park, J. H., Nam, R. H., Seok, Y.-J., Kim, Y.-R., Lee, D. H., & Jung, H. C. (2016). Comparison of Gastric Microbiota Between Gastric Juice and Mucosa by Next Generation Sequencing Method. *Journal of Cancer Prevention*, 21(1), 60–65. <https://doi.org/10.15430/JCP.2016.21.1.60>.
- [19] Topçuoğlu, B. D., Lesniak, N. A., Ruffin, M. T., Wiens, J., & Schloss, P. D. (2020). A framework for Effective Application of Machine Learning to Microbiome-Based Classification Problems. *mBio*, 11(3). <https://doi.org/10.1128/mbio.00434-20>.
- [20] Wang, D., Zhang, T., Lu, Y., Wang, C., Wu, Y., Li, J., Tao, Y., Deng, L., Zhang, X., & Ma, J. (2022). *Helicobacter pylori* infection affects the human gastric microbiome, as revealed by metagenomic sequencing. *FEBS Open Bio*, 12(6), 1188–1196. <https://doi.org/10.1002/2211-5463.13390>.
- [21] Wang, Y., Wang, Y., Han, W., Han, M., Liu, X., Dai, J., Dong, Y., Sun, T., & Xu, J. (2024). Intratumoral and fecal microbiota reveals microbial markers associated with gastric carcinogenesis. *Frontiers in Cellular and Infection Microbiology*, 14, 1397466. <https://doi.org/10.3389/fcimb.2024.1397466>.
- [22] Weiss, S., Xu, Z. Z., Peddada, S., Amir, A., Bittinger, K., Gonzalez, A., Lozupone, C., Zaneveld, J. R., Vázquez-Baeza, Y., Birmingham, A., Hyde, E. R., & Knight, R. (2017). Normalization and microbial differential abundance strategies depend upon data characteristics. *Microbiome*, 5(1), 27. <https://doi.org/10.1186/s40168-017-0237-y>.
- [23] Yang, I., Woltemate, S., Piazzuelo, M. B., Bravo, L. E., Yepez, M. C., Romero-Gallo, J., Delgado, A. G., Wilson, K. T., Peek, R. M., Correa, P., Josenhans, C., Fox, J. G., & Suerbaum, S. (2016). Different gastric microbiota compositions in two human populations with high and low gastric cancer risk in Colombia. *Scientific Reports*, 6(1), 18594. <https://doi.org/10.1038/srep18594>.
- [24] Zaramella, A., Arcidiacono, D., Duci, M., Benna, C., Pucciarelli, S., Fantin, A., Rosato, A., De Re, V., Cannizzaro, R., Fassan, M., & Realdon, S. (2024). Predictive Value of a Gastric Microbiota Dysbiosis Test for Stratifying Cancer Risk in Atrophic Gastritis Patients. *Nutrients*, 17(1), 142. <https://doi.org/10.3390/nu17010142>.
- [25] Zeng, R., Gou, H., Lau, H. C. H., & Yu, J. (2024). Stomach microbiota in gastric cancer development and clinical implications. *Gut*, 73(12), 2062–2073. <https://doi.org/10.1136/gutjnl-2024-332815>.
- [26] Zhao, H., Zhang, S., Qin, H., Liu, X., Ma, D., Han, X., Mao, J., & Liu, S. (2024). DSNetax: a deep learning species annotation method based on a deep-shallow parallel framework. *Briefings in Bioinformatics*, 25(3), bbae157. <https://doi.org/10.1093/bib/bbae157>.
- [27] Greenacre, M., Martínez-Álvarez, M., & Blasco, A. (2021). Compositional data analysis of microbiome and any-omics datasets: A validation of the additive, logratio transformation. *Frontiers in Microbiology*, 12, 727398. <https://doi.org/10.3389/fmicb.2021.727398>.
- [28] Walsh, C., Stallard-Olivera, E., & Fierer, N. (2024). Nine (not so simple) steps: A practical guide to using machine learning in microbial ecology. *mBio*, 15(2), e02050-23. <https://doi.org/10.1128/mbio.02050-23>.
- [29] Aitchison, J. (1986). *The Statistical Analysis of Compositional Data*. Chapman and Hall.
- [30] McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv:1802.03426*.
- [31] Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- [32] Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *Annals of Mathematical Statistics*, 18(1), 50–60.