Propuesta de Proyecto Asignatura Redes Neuronales (Febrero 2026)

David F. Marin Rosas, Diego E. Morales Granados, Laura C. Girón Pinto, Nicolás Martínez López, Sergio I. Motta Doncel., Facultad de Ingeniería, Universidad Nacional de Colombia

***Abstract*—This research evaluates the efficacy of non-linear machine learning models, specifically multilayer neural networks, in classifying Helicobacter pylori infection using human gastric microbiota data. Gastric cancer remains a leading cause of global mortality, with Helicobacter pylori infection acting as a primary trigger for microbial dysbiosis and inflammation. Conventional statistical methods often struggle to capture the complex, non-linear interactions within the high-dimensional and sparse datasets generated by ribosomal RNA sequencing. This study implements a supervised modeling approach on a dataset of twenty-nine patients, integrating diverse cohorts and employing uniform data processing to mitigate technical variations. To address the inherent challenges of compositional data, centered log-ratio transformations are applied prior to model training. The performance of deep learning architectures is rigorously compared against classical linear methods to determine their additional predictive value. Furthermore, the study emphasizes model interpretability through explainable artificial intelligence techniques, such as SHAP and layer-wise relevance propagation, to identify specific microbial taxa driving the classification. The results aim to characterize the distinct microbial signature left by the pathogen, potentially informing the development of non-invasive diagnostic tools. By focusing on both predictive accuracy and biological insights, this project contributes to a deeper understanding of the gastric ecosystem's reorganization during chronic infection.**

***Index Terms*—Classification, Deep learning, Gastric microbiome, Helicobacter pylori, Neuronal Networks.**

I. Introducción

El cáncer gástrico representa una de las mayores causas de mortalidad a nivel mundial, principalmente debido a que su detección suele ocurrir en etapas avanzadas de la enfermedad. La infección por Helicobacter pylori es el factor de riesgo más determinante, ya que coloniza la mucosa gástrica, provoca inflamación persistente y desencadena una profunda reorganización del ecosistema microbiano local conocida como disbiosis. Aunque la tecnología de secuenciación de 16S rRNA ha permitido caracterizar estas comunidades, la naturaleza composicional, la alta dimensionalidad y la escasez de los datos de microbiota presentan retos significativos para los métodos estadísticos tradicionales.

En este contexto, este proyecto propone evaluar si los modelos de aprendizaje automático no lineales, específicamente las redes neuronales multicapa, aportan un valor predictivo e interpretativo superior a los métodos clásicos. Se postula que en sistemas ecológicos complejos como el microbioma gástrico, las relaciones entre microorganismos son inherentemente no lineales y dependen de combinaciones multivariadas de abundancias que las redes neuronales pueden capturar con mayor precisión. El estudio utilizará un conjunto de datos de 29 pacientes para desarrollar una tarea de clasificación binaria, integrando transformaciones de razón logarítmica para manejar la estructura de los datos y aplicando técnicas de inteligencia artificial explicable para identificar los taxones bacterianos clave que definen la huella microbiana de la infección.

II. Objetivo y Alcance del Proyecto

El objetivo del presente proyecto es evaluar si los modelos de aprendizaje automático no lineales, incluyendo redes neuronales multicapa, aportan un valor predictivo e interpretativo adicional frente a métodos estadísticos clásicos en la clasificación de la infección por Helicobacter pylori utilizando datos de microbiota gástrica obtenidos mediante secuenciación 16S rRNA de biopsias humanas.

El proyecto se centrará exclusivamente en microbiota gástrica en humanos adultos, comparando individuos infectados contra no infectados. Se realizará integración de datos provenientes de múltiples cohortes públicas, procesamiento uniforme de datos de secuenciación para evitar batch effect, modelado supervisado y análisis de interpretabilidad. No se pretende establecer causalidad ni mecanismos funcionales profundos, sino evaluar capacidad predictiva y estructura microbiana asociada al estado de infección.

III. Revisión de Literatura

A. Definiciones Básicas

1) Helicobacter pylori: bacteria gramnegativa microaerófila que coloniza la mucosa gástrica y se asocia con gastritis, úlcera péptica y cáncer gástrico.

2) Microbiota gástrica: Comunidad microbiana residente en la mucosa del estómago.

3) Perfil taxonómico: Identificación y cuantificación de especies, géneros o distintos taxones presentes en una muestra para determinar la composición y abundancia relativa de una muestra de microbiota.

4) Abundancia relativa: Proporción de un taxón o especie respecto al número total de taxones o especies en un área definida .

5) Secuenciación 16S rRNA: Técnica de secuenciación de regiones variables del gen 16S para caracterización taxonómica bacteriana.

6) Datos composicionales: Datos donde las abundancias son proporciones relativas y requieren transformaciones adecuadas (ej. CLR).

B. Revisión

El cáncer gástrico constituye una de las principales causas de mortalidad por cáncer a nivel mundial, con alta carga global y local (Zeng et al., 2024; SICC, DANE). Una de las mayores causas de la muerte por esta enfermedad es la detección tardía, cuando el cáncer se encuentra en sus etapas más avanzadas (Mohamed et al., 2025; Zeng et al., 2024). Su etiología es altamente heterogénea, lo que ha dificultado el desarrollo de metodologías de diagnóstico y tratamiento tempranos (Atherton, 2006; Wang et al., 2024). Adicionalmente, uno de los factores de mayor efecto en el inicio de este tipo de cáncer es la infección por Helicobacter pylori, bacteria gramnegativa microaerófila que coloniza la mucosa gástrica y cuya prevalencia global se estima cercana al 50% de la población. La infección crónica se asocia con inflamación persistente, alteraciones en la secreción ácida y modificaciones del microambiente gástrico y alrededor del 3% de la población puede llegar a desarrollar cáncer gástrico, aunque

la prevalencia y el riesgo asociado varían según la región geográfica, la edad y la cepa adquirida (La Placa et al., 2025; Zeng et al., 2024).

El papel de este microorganismo en el desarrollo del cáncer no está establecido con claridad, pero se considera que la alteración de su comportamiento en el nicho actúa como disparador de la disbiosis, la inflamación y los cambios en el pH gástrico que permiten la colonización del estómago por microbiota oral e intestinal (Kusters et al., 2006; Zeng et al., 2024). Se han descrito cambios en diversidad, desplazamientos en la composición taxonómica y variaciones en comunidades no-H. pylori, lo que sugiere que la infección no solo implica la presencia del patógeno, sino una reorganización del ecosistema microbiano local (Eun et al., 2014; Park et al., 2019; Wang et al., 2024; Yang et al., 2016). Adicionalmente, se ha determinado que pacientes con ciertas abundancias de taxones orales específicos presentan una menor supervivencia al cáncer gástrico en comparación con otros (Lehr et al., 2023), lo que refuerza la idea de que la composición microbiana asociada al estado de infección podría tener implicaciones clínicas más amplias. Por otra parte, la actividad metabólica de estas comunidades tras la disbiosis se ha convertido en un foco central de estudio por su vínculo con la transición hacia lesiones precancerosas y tumor. Estos hallazgos en conjunto sugieren que la infección por H. pylori deja una huella microbiana característica que potencialmente podría ser detectada como un patrón de clasificación, lo que abriría la posibilidad de desarrollar herramientas diagnósticas no invasivas basadas en la composición del microbioma gástrico (Durán et al., 2021; Topçuoğlu et al., 2020).

Sin embargo, los resultados entre estudios muestran heterogeneidad considerable, atribuida en parte a diferencias en el sitio de muestreo (antro, cuerpo gástrico), tipo de muestra (biopsia, jugo gástrico), baja biomasa bacteriana y posibles problemas de contaminación (Sgamato et al., 2024; Sung et al., 2016; Zaramella et al., 2024; Zeng et al., 2024). Adicional a estas fuentes de variabilidad, existen limitaciones metodológicas relacionadas con el modo en que se generan y representan computacionalmente los datos de microbiota.

En estudios basados en secuenciación 16S rRNA, la comunidad microbiana se cuantifica mediante matrices de conteo de variantes de secuencia o taxones generadas a partir de pipelines bioinformáticos, que suelen luego transformarse en abundancias relativas para su análisis comparativo (Chiu y Miller, 2019). Sin embargo, estas abundancias no representan cantidades absolutas de microorganismos, sino proporciones dentro de cada muestra, por lo que están restringidas por una suma constante. Esto implica que un incremento relativo en un taxón necesariamente conlleva una disminución proporcional en otros, incluso si sus cantidades reales no han variado. Debido a esto, los datos derivados de 16S constituyen datos composicionales, cuya estructura puede generar asociaciones artificiales cuando se aplican métodos estadísticos convencionales directamente sobre proporciones. Por ello, se recomienda el uso de transformaciones log-ratio que permitan analizar los datos en un espacio adecuado para inferencia estadística y modelado predictivo (Gloor et al., 2017; Weiss et al., 2017).

Esta representación numérica permite modelar cada muestra como un vector en un espacio multivariado, sobre el cual pueden aplicarse técnicas estadísticas y de aprendizaje automático. Este enfoque, sin embargo, ha mostrado dificultades de reproducibilidad entre cohortes y contextos clínicos, posiblemente debido a la naturaleza composicional de los datos (Gloor et al., 2017), la alta variabilidad interindividual, el efecto dominante de H. pylori en individuos infectados, , que puede alterar de manera desproporcionada la estructura relativa de la comunidad (Meyer et al., 2022; Lee & Lee, 2024; Wang et al., 2024). Adicionalmente, no existe consenso sobre si las variables más informativas para caracterizar el estado de infección corresponden exclusivamente a abundancias taxonómicas o si patrones de interacción entre microorganismos y características funcionales del ecosistema aportan mayor estabilidad y capacidad predictiva (Zeng et al., 2024).

En este contexto, los enfoques de aprendizaje automático han comenzado a utilizarse para explorar patrones complejos en datos de microbioma, dado que en sistemas ecológicos como el microbioma gástrico las relaciones entre microorganismos pueden ser no lineales y depender de combinaciones multivariadas de abundancias que los métodos estadísticos tradicionales no logran capturar (Chang et al., 2020; Akpoigbe et al., 2022; Zhao et al., 2024). Durán y colaboradores (2021) ha demostrado que la comparación de técnicas lineales y no lineales en datos de microbioma gástrico de pacientes H. pylori positivos y negativos permite revelar estructuras de agrupamiento que los métodos lineales no detectan, lo que respalda la pertinencia de este tipo de análisis. Sin embargo, su aplicación en la clasificación del estado de infección por H. pylori utilizando microbiota gástrica humana aún es limitada y requiere evaluación rigurosa en términos de reproducibilidad, control de sesgos técnicos y comparación sistemática frente a modelos lineales clásicos. De manera complementaria, en función de la disponibilidad de información en los conjuntos de datos seleccionados, el análisis podría extenderse en dos direcciones adicionales. Por un lado, la variabilidad en la virulencia de H. pylori, determinada por factores como los genotipos cagA y vacA, podría modular el impacto de la bacteria sobre la comunidad microbiana gástrica, por lo que su integración permitiría explorar si existen diferencias microbianas asociadas no solo al estado de infección, sino también al perfil de virulencia del patógeno (La Placa et al., 2025; Zeng et al., 2024). Por otro lado, dado que la composición microbiana asociada a la infección y distintas cepas de H. pylori han mostrado vínculos con la supervivencia al cáncer gástrico (Lehr et al., 2023), podría explorarse si los patrones clasificatorios identificados guardan relación con desenlaces clínicos relevantes.

IV. Caso de Estudio

Durán et al., 2021 (PMID: 33771992). El presente artículo analiza datos de microbioma gástrico en pacientes infectados y no infectados por Helicobacter pylori, comparando enfoques analíticos lineales y no lineales para explorar las diferencias estructurales entre los dos escenarios en la comunidad microbiana. Estos autores observan que los enfoques no lineales revelan estructuras no reveladas por otros métodos, pero no evalúan formalmente la capacidad predictiva de dichos patrones. El presente proyecto busca extender este avance mediante la implementación y evaluación comparativa de modelos de aprendizaje automático de redes profundas para caracterizar la microbiota antes y después de la infección con H. pylori.

Klymium et al., 2017. En este paper se generaron datos de microbiota gástrica obtenida mediante secuenciación 16S rRNA en biopsias humanas, incluyendo individuos infectados y no infectados por Helicobacter pylori, con información adicional sobre el estado de virulencia (CagA). El estudio caracteriza diferencias en la composición microbiana asociadas al estado de infección, pero no implementa modelos supervisados para evaluar capacidad predictiva. El presente proyecto utilizará este conjunto de datos como base experimental para formular una tarea de clasificación binaria (infectado contra no infectado) y evaluar si los patrones multivariados de la comunidad microbiana permiten discriminar el estado de infección mediante modelos de aprendizaje automático.

V. Conjunto de Datos de Entrenamiento

El dataset de entrenamiento a utilizar proviene del paper de Klymiuk y colaboradores (2017), recopilado en la base de datos Sequence Read Archive (SRA) con el código de acceso PRJEB22107. Este cuenta con información de 29 pacientes dentro de tres categorías: no infectados con H. pylori (H.p.-), infectado con H. pylori sin el factor de virulencia CagA (H.p.+/CagA-) e infectado con

H. pylori con el factor de virulencia CagA (H.p.+/CagA+). Para cada uno de los casos se cuenta con 10 muestras, entre pacientes masculinos y femeninos con una media de edad de aproximadamente 50 años. Estas muestras fueron sometidas a procesamiento por pirosecuenciación 16S rRNA y análisis metagenómico, por lo que se obtienen valores de abundancia de distintos phylum, clases, órdenes, familias y especies bacterianas encontradas en el lumen de los distintos individuos.

El conjunto de datos está estructurado como una matriz de abundancia taxonómica en la que cada una de las muestras corresponde a un vector numérico de características, representando la abundancia relativa de los distintos taxones identificados. El número de características dependerá del nivel taxonómico seleccionado (phylum, clase, orden, familia o género), con el fin de reducir la dimensionalidad y mejorar la estabilidad del modelo dada la relación entre número de muestras y número de variables. Por otro lado, las abundancias mencionadas se utilizarán como variables de entrada para el modelo y la variable objetivo corresponderá al estado de infección por Helicobacter pylori, inicialmente formulado como un problema de clasificación binaria (H.p.+ contra H.p.-). Se explorará además la posibilidad de discriminar entre subgrupos según el estado de virulencia (CagA+ vs CagA-), sujeto a estabilidad estadística del modelo.

El dataset presenta un balance casi equitativo entre categorías, lo cual favorece la evaluación comparativa de modelos supervisados mediante validación cruzada estratificada, pero puede verse limitado para la implementación de arquitecturas complejas debido a su tamaño muestral. Para lidiar con ello, se emplearán estrategias de regularización y validación repetida para minimizar el riesgo de sobreajuste. Adicional a esto, dado que los datos de microbiota son composicionales, se aplicarán transformaciones log-ratio apropiadas antes del entrenamiento de los modelos para asegurar una representación adecuada en el espacio multivariado.

VI. Enfoque Propuesto Basado en Redes Neuronales

A. *Variables de Entrada del Modelo*

Las variables de entrada consistirán en vectores de composición microbiana derivados de la secuenciación del gen 16S rRNA de biopsias humanas. Estos vectores representan el perfil taxonómico de cada muestra, cuantificado mediante la abundancia relativa de diferentes taxones (desde nivel de Phylum hasta Género). Debido a que estos son datos composicionales (donde las abundancias son proporciones que suman una constante), las variables deben ser sometidas a una transformación de razón logarítmica centrada (CLR) antes de ser alimentadas a la red neuronal. Esto asegura que los datos se encuentren en un espacio multivariado adecuado para el modelado predictivo, evitando asociaciones artificiales y mejorando la capacidad del modelo para capturar la reorganización del ecosistema microbiano tras la infección.

B. *Arquitectura del Modelo*

Para el desarrollo del presente proyecto, se contempla la posibilidad de utilizar diversas arquitecturas de aprendizaje profundo que permiten abordar los retos intrínsecos de los datos de microbiota, como su alta dimensionalidad, dispersión y la limitación del tamaño muestral. A continuación, se presentan de forma independiente las tres arquitecturas propuestas para el reporte, detallando su función y utilidad específica para los objetivos de clasificación e interpretación de la infección por H. pylori:

1) Redes Generativas Antagónicas (GAN)

Esta arquitectura se compone de dos modelos neuronales interconectados: un generador, que crea muestras sintéticas a partir de ruido aleatorio, y un discriminador, que evalúa si dichas muestras son reales (provenientes del dataset original) o falsas.

Dado que el estudio cuenta con una muestra de solo 29 pacientes, el riesgo de sobreajuste (overfitting) es una limitación crítica. Las GAN ofrecen la posibilidad de realizar un aumento de datos (data augmentation), generando perfiles taxonómicos sintéticos que preservan la diversidad y las correlaciones taxonómicas reales. Esto permite entrenar modelos de clasificación más robustos y con mejor capacidad de generalización.

2) Autoencodificadores (AE)

Un autoencodificador es una red diseñada para el aprendizaje no supervisado que consta de un codificador (comprime la entrada) y un decodificador (reconstruye la entrada), creando un cuello de botella o "capa latente" en el centro.

Los perfiles taxonómicos gástricos suelen ser altamente dimensionales y dispersos, lo que introduce ruido en los modelos predictivos. Esta arquitectura permite realizar una extracción de características y reducción de dimensionalidad eficiente, filtrando la información redundante y reteniendo únicamente los patrones biológicos más informativos para distinguir entre sujetos infectados y no infectados.

3) Redes Neuronales de Alimentación Hacia Adelante (FFNN / MLP)

Conocidas como Perceptrones Multicapa, estas redes procesan la información en una sola dirección, desde la capa de entrada hasta la de salida, utilizando capas ocultas y funciones de activación para aprender patrones complejos.

Es la arquitectura idónea para la tarea de clasificación binaria supervisada planteada en los objetivos. Su capacidad para modelar relaciones no lineales permite capturar la compleja reorganización estructural del ecosistema gástrico que los métodos estadísticos tradicionales podrían no detectar. Además, su estructura facilita el uso de métodos de Inteligencia Artificial Explicable (XAI), como SHAP o LRP, para identificar qué taxones específicos impulsan la predicción del modelo.

C. *Salida del Modelo*

Al finalizar el procesamiento de los datos a través de las capas ocultas de la red neuronal, el modelo ejecutará una tarea de clasificación supervisada como resultado final. La salida de la red estará diseñada para proporcionar una etiqueta categórica o un valor probabilístico que determine si el perfil de la microbiota gástrica analizada indica un daño considerable del tejido o si, en su defecto, el estado no es de gravedad.

Esta distinción es fundamental, ya que la infección por *H. pylori* se asocia con una inflamación persistente, alteraciones en el microambiente gástrico y el desarrollo de lesiones precancerosas o tumores. Técnicamente, la capa de salida de la red neuronal suele emplear una función de activación sigmoide, la cual transforma los valores procesados en un rango de 0 a 1, facilitando la interpretación de los resultados como la probabilidad de que una muestra pertenezca a la categoría de daño severo.

De este modo, el modelo no sólo clasificará la presencia del patógeno, sino que evaluará la "huella microbiana" y la reorganización del ecosistema para inferir la gravedad clínica de la muestra.

VII. Resultados Esperados

Basados en la literatura disponible, se espera que los perfiles taxonómicos de microbiota gástrica contengan señal discriminativa suficiente para diferenciar entre individuos infectados y no infectados por Helicobacter pylori mediante modelos supervisados.

Específicamente, se espera:

1) Diferencias estadísticamente significativas en la abundancia relativa de ciertos taxones entre los grupos Hp+ y Hp-.

2) Un desempeño predictivo superior al azar y e igual al clasificador base.

3) Métricas de desempeño relevantes (accuracy, precisión, recall, F1-score y AUC-ROC) que reflejen capacidad discriminativa real.

4) Que el modelo identifique subconjuntos de taxones con alta contribución a la clasificación, lo cual podría aportar evidencia adicional sobre la reorganización ecológica asociada a la infección.

Adicionalmente, se espera que los modelos no lineales (redes neuronales) presenten igual desempeño que modelos lineales clásicos, particularmente si las diferencias microbianas asociadas a la infección presentan patrones no lineales.

VIII. Evaluación de la Solución

La evaluación del modelo se realizará bajo un esquema de validación rigurosa que permita estimar su capacidad de generalización.

B. Estrategia de Validación

1) División estratificada del conjunto de datos en entrenamiento y prueba.

2) Validación cruzada estratificada (por ejemplo, k-fold con k=5 o 10).

3) Ajuste de hiper parámetros únicamente dentro del conjunto de entrenamiento.

C. Métricas de Desempeño

Para una evaluación exhaustiva, se utilizarán un conjunto de métricas que permitan analizar el comportamiento del modelo

1) Accuracy, Precisión, Recall (sensibilidad), F1-score

2) Curva ROC y área bajo la curva (AUC-ROC)

3) Matriz de confusión

4) Matthews Correlation Coefficient (MCC)

Dado el tamaño limitado del dataset, se priorizarán métricas robustas como F1-score y AUC-ROC por encima de accuracy aislada.

D. Comparación Con Modelos Base

Se implementarán modelos lineales y clásicos (por ejemplo, regresión logística) para comparar el desempeño frente a la red neuronal. Esto permitirá evaluar si la complejidad adicional del modelo no lineal aporta valor predictivo real.

E. Interpretabilidad

Para fortalecer la interpretación biológica de los resultados, se realizará un análisis de importancia de variables (por ejemplo, mediante permutación o métodos basados en contribución de características). Esto permitirá identificar qué taxones influyen más en la clasificación y evaluar si los resultados son coherentes con la literatura previa.

IX. Consideraciones y Preguntas Éticas

El proyecto utiliza datos de microbiota humana obtenidos de estudios previamente aprobados por comités de ética y con consentimiento informado de los participantes.

Se tendrán en cuenta los siguientes aspectos:

1) Uso exclusivo de datos anonimizados.

2) No se realizará reidentificación de individuos.

3) Los resultados se interpretarán únicamente con fines investigativos.

4) El modelo desarrollado no será considerado una herramienta diagnóstica clínica sin validación externa adicional.

Asimismo, se reconoce que el tamaño muestral limitado puede afectar la generalización del modelo, por lo que cualquier conclusión deberá interpretarse dentro del contexto del dataset utilizado.

X. Enlaces Web Del Código Fuente y Video Explicativo

B. Código Fuente

1) La carpeta donde se almacenarán los notebooks se encuentra en el siguiente enlace: https://drive.google.com/drive/folders/1T7gSd9RB6pCJoz1JuhegMiIyUAspRP2p?usp=drive_link.

2) El repositorio del proyecto se encuentra disponible en el siguiente enlace: https://github.com/nmart1nezl/NeuronalNetworks-Group6. En este repositorio se puede consultar el archivo README.md, el cual describe detalladamente la estructura del proyecto, los objetivos de su desarrollo, los integrantes del equipo de trabajo y las directrices para colaborar en él.

En términos generales, el repositorio se organiza en dos carpetas principales. La primera, denominada “project”, contiene todos los avances relacionados con el proyecto final del curso. La segunda, llamada “ClassPresentations”, almacena las distintas producciones, notebooks y material audiovisual que serán utilizados por los miembros del equipo para la preparación y desarrollo de las presentaciones realizadas a lo largo del curso.

C. Video Explicativo

El video en el cual se presenta nuestra propuesta de proyecto, y en donde se aborda el problema, el contexto, la revisión de la literatura, los casos de estudio relacionados, la descripción del conjunto de datos a ser usado y el enfoque del problema a través de las redes neuronales del proyecto se puede encontrar en el siguiente enlace: https://youtu.be/PUNYQVkFD3c.

XI. Contribución de Los Miembros del Equipo

TABLA 1
Contribución de Cada Uno De Los Miembros Del Equipo

Miembro del Equipo	Rol	Actividades / Contribuciones
David Felipe Marin Rosas	Experto, Animador	Aportó ideas para definir el enfoque del proyecto, participó en la discusión del problema y ayudó a mantener una dinámica de trabajo activa y colaborativa durante la construcción de la propuesta.
Diego Esteban Morales Granados	Técnico, Secretario	Apoyó la organización del contenido, y la estructuración del documento, contribuyendo a que la propuesta fuera clara, ordenada y coherente.
Laura Camila Girón Pinto	Lideresa, coordinadora	Organizó y coordinó el trabajo del equipo, hizo seguimiento a las tareas y participó activamente en la investigación del tema, apoyando la revisión bibliográfica y la definición del planteamiento metodológico. Encargada de realizar el video explicativo de la propuesta.
Nicolás Martínez López	Investigador, Observador	Se encargó de la búsqueda y análisis de artículos científicos relevantes para la construcción del marco teórico y el planteamiento del problema. Por último se encargó de la perfección del documento y la creación del repositorio de almacenamiento del código fuente.

Sergio Ivan Motta Doncel	Técnico, Investigador	Colaboró en la definición de la metodología y la organización de los recursos técnicos. Por otro lado también contribuyó en la búsqueda de divulgación científica relacionada con el tema.

XII. Uso de Herramientas de Inteligencia Artificial

El desarrollo del texto contó con el apoyo de la herramienta de inteligencia artificial ChatGPT, utilizada para asistir en la mejora de la redacción al corregir redundancias en ideas, palabras y algunos verbos. El análisis, la selección de ideas y la coherencia argumentativa del texto son responsabilidad exclusiva de los autores. Adicionalmente, se aprovechó la herramienta NotebookLM para contextualizar los temas y para el aprendizaje de los autores.

Referencias

[1] Akpoigbe, K., Culpepper-Morgan, J., Nwankwo, O., & Genao, A. (2022). Predicting Gastric Intestinal Metaplasia in a High-Risk Population. Cureus. https://doi.org/10.7759/cureus.31502.

[2] Atherton, J. C. (2006). The pathogenesis of Helicobacter pylori-induced gastro-duodenal diseases. Annual Review of Pathology, 1, 63–96. https://doi.org/10.1146/annurev.pathol.1.110304.100125.

[3] Chang, W. K., VanInsberghe, D., & Kelly, L. (2020). Topological analysis reveals state transitions in human gut and marine bacterial communities. Npj Biofilms and Microbiomes, 6(1), 41. https://doi.org/10.1038/s41522-020-00145-9.

[4] Chiu, C. Y., & Miller, S. A. (2019). Clinical metagenomics. Nature Reviews Genetics, 20(6), 341–355. https://doi.org/10.1038/s41576-019-0113-7.

[5] Durán, C., Ciucci, S., Palladini, A., Ijaz, U. Z., Zippo, A. G., Sterbini, F. P., Masucci, L., Cammarota, G., Ianiro, G., Spuul, P., Schroeder, M., Grill, S. W., Parsons, B. N., Pritchard, D. M., Posteraro, B., Sanguinetti, M., Gasbarrini, G., Gasbarrini, A., & Cannistraci, C. V. (2021). Nonlinear machine learning pattern recognition and bacteria-metabolite multilayer network analysis of perturbed gastric microbiome. Nature Communications, 12(1), 1926. https://doi.org/10.1038/s41467-021-22135-x.

[6] Eun, C. S., Kim, B. K., Han, D. S., Kim, S. Y., Kim, K. M., Choi, B. Y., Song, K. S., Kim, Y. S., & Kim, J. F. (2014). Differences in gastric mucosal microbiota profiling in patients with chronic gastritis, intestinal metaplasia, and gastric cancer using pyrosequencing methods. Helicobacter, 19(6), 407–416. https://doi.org/10.1111/hel.12145.

[7] Gloor, G. B., Macklaim, J. M., Pawlowsky-Glahn, V., & Egozcue, J. J. (2017b). Microbiome datasets are compositional: and this is not optional. Frontiers in Microbiology, 8, 2224. https://doi.org/10.3389/fmicb.2017.02224.

[8] Kusters, J. G., Van Vliet, A. H. M., & Kuipers, E. J. (2006). Pathogenesis of Helicobacter pylori Infection. Clinical Microbiology Reviews, 19(3), 449–490. https://doi.org/10.1128/CMR.00054-05.

[9] Klymiuk, I., Bilgilier, C., Stadlmann, A., Thannesberger, J., Kastner, M., Högenauer, C., Püspök, A., Biowski-Frotz, S., Schrutka-Kölbl, C., Thallinger, G. G., & Steininger, C. (2017). The Human Gastric Microbiome Is Predicated upon Infection with Helicobacter pylori. Frontiers in Microbiology, 8, 2508. https://doi.org/10.3389/fmicb.2017.02508.

[10] La Placa, G., Covino, M., Candelli, M., Gasbarrini, A., Franceschi, F., & Merra, G. (2025). Relationship Between Human Microbiome and Helicobacter pylori. Microbiology Research, 16(1), 24. https://doi.org/10.3390/microbiolres16010024.

[11] Lee, S., & Lee, I. (2024). Comprehensive assessment of machine learning methods for diagnosing gastrointestinal diseases through whole metagenome sequencing data. Gut Microbes, 16(1), 2375679. https://doi.org/10.1080/19490976.2024.2375679.

[12] Lehr, K., Nikitina, D., Vilchez-Vargas, R., Steponaitiene, R., Thon, C., Skieceviciene, J., Schanze, D., Zenker, M., Malfertheiner, P., Kupcinskas, J., & Link, A. (2023). Microbial composition of tumorous and adjacent gastric tissue is associated with prognosis of gastric cancer. Scientific Reports, 13(1), 4640. https://doi.org/10.1038/s41598-023-31740-3.

[13] Meyer, F., Fritz, A., Deng, Z.-L., Koslicki, D., Lesker, T. R., Gurevich, A., Robertson, G., Alser, M., Antipov, D., Beghini, F., Bertrand, D., Brito, J. J., Brown, C. T., Buchmann, J., Buluç, A., Chen, B., Chikhi, R., Clausen, P. T. L. C., Cristian, A., … McHardy, A. C. (2022). Critical Assessment of Metagenome Interpretation: the second round of challenges. Nature Methods, 19(4), 429–440. https://doi.org/10.1038/s41592-022-01431-4.

[14] Mohamed, A. S., Bhuju, R., Martinez, E., Basta, M., Deyab, A., Mansour, C., Tejada, D., Deshpande, V., Elias, S., & Nagesh, V. K. (2025). The Gut Microbiome's Impact on the Pathogenesis and Treatment of Gastric Cancer—An Updated Literature Review. Cancers, 17(17), 2795. https://doi.org/10.3390/cancers17172795.

[15] Park, C. H., Lee, A., Lee, Y., Eun, C. S., Lee, S. K., & Han, D. S. (2019). Evaluation of gastric microbiome and metagenomic function in patients with intestinal metaplasia using 16S rRNA gene sequencing. Helicobacter, 24(1), e12547. https://doi.org/10.1111/hel.12547.

[16] Sgamato, C., Rocco, A., Compare, D., Priadko, K., Romano, M., & Nardone, G. (2024). Exploring the Link between Helicobacter pylori, Gastric Microbiota and Gastric Cancer. Antibiotics, 13(6), 484. https://doi.org/10.3390/antibiotics13060484.

[17] SICC | DANE. (n.d.). Sistema de información de cáncer de Colombia. https://www.infocancer.co/.

[18] Sung, J., Kim, N., Kim, J., Jo, H. J., Park, J. H., Nam, R. H., Seok, Y.-J., Kim, Y.-R., Lee, D. H., & Jung, H. C. (2016). Comparison of Gastric Microbiota Between Gastric Juice and Mucosa by Next Generation Sequencing Method. Journal of Cancer Prevention, 21(1), 60–65. https://doi.org/10.15430/JCP.2016.21.1.60.

[19] Topçuoğlu, B. D., Lesniak, N. A., Ruffin, M. T., Wiens, J., & Schloss, P. D. (2020). A framework for Effective Application of Machine Learning to Microbiome-Based Classification Problems. mBio, 11(3). https://doi.org/10.1128/mbio.00434-20.

[20] Wang, D., Zhang, T., Lu, Y., Wang, C., Wu, Y., Li, J., Tao, Y., Deng, L., Zhang, X., & Ma, J. (2022). Helicobacter pylori infection affects the human gastric microbiome, as revealed by metagenomic sequencing. FEBS Open Bio, 12(6), 1188–1196. https://doi.org/10.1002/2211-5463.13390

[21] Wang, Y., Wang, Y., Han, W., Han, M., Liu, X., Dai, J., Dong, Y., Sun, T., & Xu, J. (2024). Intratumoral and fecal microbiota reveals microbial markers associated with gastric carcinogenesis. Frontiers in Cellular and Infection Microbiology, 14, 1397466. https://doi.org/10.3389/fcimb.2024.1397466.

[22] Weiss, S., Xu, Z. Z., Peddada, S., Amir, A., Bittinger, K., Gonzalez, A., Lozupone, C., Zaneveld, J. R., Vázquez-Baeza, Y., Birmingham, A., Hyde, E. R., & Knight, R. (2017). Normalization and microbial differential abundance strategies depend upon data characteristics. Microbiome, 5(1), 27. https://doi.org/10.1186/s40168-017-0237-y.

[23] Yang, I., Woltemate, S., Piazuelo, M. B., Bravo, L. E., Yepez, M. C., Romero-Gallo, J., Delgado, A. G., Wilson, K. T., Peek, R. M., Correa, P., Josenhans, C., Fox, J. G., & Suerbaum, S. (2016). Different gastric microbiota compositions in two human populations with high and low gastric cancer risk in Colombia. Scientific Reports, 6(1), 18594. https://doi.org/10.1038/srep18594.

[24] Zaramella, A., Arcidiacono, D., Duci, M., Benna, C., Pucciarelli, S., Fantin, A., Rosato, A., De Re, V., Cannizzaro, R., Fassan, M., & Realdon, S. (2024). Predictive Value of a Gastric Microbiota Dysbiosis Test for Stratifying Cancer Risk in Atrophic Gastritis Patients. Nutrients, 17(1), 142. https://doi.org/10.3390/nu17010142.

[25] Zeng, R., Gou, H., Lau, H. C. H., & Yu, J. (2024). Stomach microbiota in gastric cancer development and clinical implications. Gut, 73(12), 2062–2073. https://doi.org/10.1136/gutjnl-2024-332815.

[26] Zhao, H., Zhang, S., Qin, H., Liu, X., Ma, D., Han, X., Mao, J., & Liu, S. (2024). DSNetax: a deep learning species annotation method based on a deep-shallow parallel framework. Briefings in Bioinformatics, 25(3), bbae157. https://doi.org/10.1093/bib/bbae157.